Calcolo Numerico

Marco Pittarello

Contents

1 Sistemi non decimali **2**
1.1 Conversione della parte intera . . . 2
1.2 Conversione della parte frazionaria . . . 3

2 Numeri macchina **4**
2.1 Interi macchina . . . 4
2.1.1 Overflow . . . 5
2.2 Floating point e standard IEEE 754 . . . 5
2.3 Tabella riassuntiva IEEE 754 . . . 6
2.4 Arrotondamento e troncamento . . . 6

3 Errore e norme **7**
3.1 Errore assoluto e relativo . . . 7
3.2 Norma euclidea . . . 7
3.3 Norma p . . . 7
3.4 Norma infinito . . . 8
3.5 Equivalenza delle norme . . . 8
3.6 Errore relativo . . . 8
3.7 Floating point: successivo e precedente . . . 8
3.8 Errore di rappresentazione . . . 9
3.8.1 Errore dovuto al troncamento . . . 9
3.8.2 Errore dovuto all'arrotondamento . . . 9

4 Precisione di macchina **9**
4.1 Operazioni macchina . . . 9
4.2 Errore relativo della moltiplicazione . . . 10
4.3 Errore relativo della somma . . . 10
4.4 Stabilità degli algoritmi . . . 11
4.5 Condizionamento dei problemi . . . 12
4.5.1 Condizionamento di un problema ben posto . . . 13
4.5.2 Condizionamento locale relativo . . . 13
4.5.3 Condizionamento globale di ordine α . . . 14

5 Algebra Lineare Numerica **15**
5.1 Soluzione di Sistemi Quadrati . . . 15
5.2 Norma indotta . . . 16
5.2.1 Teorema Spettrale . . . 19
5.2.2 Decomposizione ai valori singolari (SVD) . . . 20
5.3 Risoluzione pratica $Ax = b$ . . . 21
5.3.1 Caso inferiore . . . 21
5.3.2 Caso superiore . . . 21
5.4 Fattorizzazione . . . 22

1 Sistemi non decimali

Definizione 1: Conversione da base N a base M

Dato $x > 0$ e nota la rappresentazione $(x)_N$, vogliamo trovare la rappresentazione $(x)_M$.
Scriviamo:

$$\begin{aligned} x &= x_n N^n + x_{n-1} N^{n-1} + \cdots + x_0 + x_{-1} N^{-1} + \cdots + x_{-r} N^{-r} \\ &= y_m M^m + y_{m-1} M^{m-1} + \cdots + y_0 + y_{-1} M^{-1} + \cdots + y_{-q} M^{-q}. \end{aligned}$$

Si procede separatamente per la parte intera e per la parte frazionaria.

1.1 Conversione della parte intera

Per convertire la parte intera si itera lo schema della divisione intera per M:

$$\begin{aligned} y_0 &:= x \bmod M & x &= q_0 M + y_0 \\ y_1 &:= q_0 \bmod M & q_0 &= q_1 M + y_1 \\ &\vdots \\ y_m &:= q_{m-1} \bmod M & q_{m-1} &= y_m < M \end{aligned}$$

OSSERVAZIONE: $x \bmod M$ indica il resto della divisione intera di x per M.

I resti ottenuti sono le cifre della rappresentazione in base M, lette dal basso verso l'alto. Pertanto:

$$(x_{\text{int}})_M = y_m y_{m-1} \dots y_1 y_0$$

Esempio 1: Conversione da base 2 a base 10

Convertiamo

$$(10011010010)_2$$

in base 10.
Si ha:

$$\begin{aligned} (10011010010)_2 &= 1 \cdot 2^{10} + 0 \cdot 2^9 + 0 \cdot 2^8 + 1 \cdot 2^7 + 1 \cdot 2^6 \\ &\quad + 0 \cdot 2^5 + 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 \\ &= 2^{10} + 2^7 + 2^6 + 2^4 + 2^1 \\ &= 1024 + 128 + 64 + 16 + 2 \\ &= 1234 \end{aligned}$$

Quindi:

$$\boxed{(10011010010)_2 = (1234)_{10}}$$

Esempio 2: Conversione da base 10 a base 2

Convertiamo

$$(1234)_{10}$$

in base 2 utilizzando divisioni successive per 2:

$$\begin{aligned}
1234 &= 617 \cdot 2 + 0 \\
617 &= 308 \cdot 2 + 1 \\
308 &= 154 \cdot 2 + 0 \\
154 &= 77 \cdot 2 + 0 \\
77 &= 38 \cdot 2 + 1 \\
38 &= 19 \cdot 2 + 0 \\
19 &= 9 \cdot 2 + 1 \\
9 &= 4 \cdot 2 + 1 \\
4 &= 2 \cdot 2 + 0 \\
2 &= 1 \cdot 2 + 0 \\
1 &= 0 \cdot 2 + 1
\end{aligned}$$

Leggendo i resti dal basso verso l'alto otteniamo:

$$10011010010$$

Pertanto:

$$\boxed{(1234)_{10} = (10011010010)_2}$$

1.2 Conversione della parte frazionaria

Per convertire la parte frazionaria si procede moltiplicando successivamente per M.

Sia

$$x_{\text{fraz}} \in [0, 1).$$

Si calcola:

$$Mx_{\text{fraz}} = y_{-1} + r_1, \qquad 0 \leq r_1 < 1,$$

dove y_{-1} è la parte intera del risultato.

Si ripete poi il procedimento:

$$Mr_1 = y_{-2} + r_2,$$

$$Mr_2 = y_{-3} + r_3,$$

e così via.

In generale:

$$Mr_k = y_{-(k+1)} + r_{k+1}, \qquad 0 \leq r_{k+1} < 1.$$

Se per qualche k si ottiene

$$r_k = 0,$$

il procedimento termina e la rappresentazione frazionaria è finita.

Le cifre ottenute, questa volta, si leggono dall'alto verso il basso:

$$(x_{\text{fraz}})_M = (0.y_{-1}y_{-2}y_{-3}\dots)_M.$$

Esempio 3: Conversione di una frazione decimale in binario

Convertiamo

$$(0.0625)_{10}$$

in base 2.
Moltiplichiamo successivamente per 2:

$$\begin{aligned} 0.0625 \cdot 2 &= 0.125 &&\longrightarrow 0 \\ 0.1250 \cdot 2 &= 0.250 &&\longrightarrow 0 \\ 0.2500 \cdot 2 &= 0.500 &&\longrightarrow 0 \\ 0.5000 \cdot 2 &= 1.000 &&\longrightarrow 1 \end{aligned}$$

La parte frazionaria successiva è 0, quindi il procedimento termina.
Pertanto:

$$\boxed{(0.0625)_{10} = (0.0001)_2}$$

Esempio 4: Un numero frazionario periodico

Consideriamo il numero

$$(0.1)_{10}.$$

Procedendo come sopra:

$$\begin{aligned} 0.1 \cdot 2 &= 0.2 &&\longrightarrow 0 \\ 0.2 \cdot 2 &= 0.4 &&\longrightarrow 0 \\ 0.4 \cdot 2 &= 0.8 &&\longrightarrow 0 \\ 0.8 \cdot 2 &= 1.6 &&\longrightarrow 1 \\ 0.6 \cdot 2 &= 1.2 &&\longrightarrow 1 \\ 0.2 \cdot 2 &= 0.4 &&\longrightarrow 0 \end{aligned}$$

e da questo punto la sequenza si ripete.
Quindi:

$$\boxed{(0.1)_{10} = (0.0001100110011\dots)_2}$$

Il numero ha quindi una rappresentazione binaria infinita e periodica.
OSSERVAZIONE: Un calcolatore binario non può rappresentare esattamente, in generale, un numero come 0.1 utilizzando un numero finito di bit.

2 Numeri macchina

2.1 Interi macchina

I tipi interi macchina più comuni utilizzano 32 o 64 bit, ad esempio `int32` e `int64`.

NOTA: Gli interi macchina a 32 o 64 bit non fanno parte dello standard IEEE 754, che riguarda invece la rappresentazione dei numeri in virgola mobile.

Se il primo bit è riservato al segno:

$$0 \longrightarrow + \qquad 1 \longrightarrow -$$

Con n bit e rappresentazione segno-modulo, il massimo intero positivo rappresentabile è:

$$I_{\max,n} = (011\ldots1)_2 = \sum_{i=0}^{n-2} 2^i = 2^{n-1} - 1$$

Per una rappresentazione senza segno, invece:

$$I_{\max,n} = (111\ldots1)_2 = \sum_{i=0}^{n-1} 2^i = 2^n - 1$$

2.1.1 Overflow

Si verifica un overflow quando il risultato di un'operazione non è rappresentabile con il numero di bit disponibili.

Esempio 5: Overflow con interi macchina

Consideriamo interi macchina a 4 bit in rappresentazione segno-modulo.
Calcoliamo:

$$7 + 2$$

Abbiamo:

$$7 = (0111)_2 \qquad 2 = (0010)_2$$

La somma produce:

$$\begin{array}{r} 0111 \\ 0010 \\ \hline 1001 \end{array}$$

Il risultato ottenuto è:

$$(1001)_2 = -1$$

nella rappresentazione segno-modulo.
Quindi la macchina produce:

$$\boxed{7 + 2 = -1}$$

anziché 9.
Questo fenomeno prende il nome di overflow.

2.2 Floating point e standard IEEE 754

Usando la notazione binaria, un numero reale $x \neq 0$ può essere scritto, in forma normalizzata, come:

$$(x)_2 = (-1)^s \cdot 2^{e-b} \cdot (1.f)$$

dove:

- s è il bit di segno;
- e è l'esponente memorizzato;
- b è il bias, cioè la deviazione utilizzata per memorizzare anche esponenti negativi;
- $e - b$ è l'esponente effettivo;
- $1.f$ è la significanda (spesso chiamata informalmente mantissa).

Per un numero normalizzato, il bit iniziale 1 è sempre presente e quindi non è necessario memorizzarlo esplicitamente: si parla di hidden bit.

Il valore 0 richiede invece una convenzione particolare.

2.3 Tabella riassuntiva IEEE 754

	32 bit	**64 bit**
Bit totali	32	64
Bit segno	1	1
Bit esponente	8	11
Bit frazione	23	52
Bias b	127	1023
Intervallo e normalizzato	$0 < e < 255$	$0 < e < 2047$
$e = 0,\ f = 0$	± 0	± 0
$e = 0,\ f > 0$	denormalizzato	denormalizzato
$e = 255,\ f = 0$	$\pm\infty$	$\pm\infty$
$e = 255,\ f > 0$	NaN	NaN

2.4 Arrotondamento e troncamento

Quando il numero possiede più cifre di quante ne possano essere memorizzate, è necessario decidere cosa fare delle cifre in eccesso.

Definizione 2: Troncamento

Con il troncamento, le cifre oltre la precisione disponibile vengono semplicemente eliminate.

Definizione 3: Arrotondamento

Con l'arrotondamento, si considera la prima cifra che non può essere memorizzata e si modifica l'ultima cifra memorizzabile in funzione del suo valore.
Nel caso binario:
- se la cifra successiva è 1, si aumenta di 1 l'ultima cifra memorizzata;
- se la cifra successiva è 0, l'ultima cifra non viene modificata.

3 Errore e norme

Definizione 4: Approssimazione

Supponiamo di voler rappresentare o calcolare un valore $x \in \mathbb{R}$ (o $\in \mathbb{R}^m$), ma invece calcolo o ottengo un'approssimazione:

$$\widetilde{x} \approx x$$

3.1 Errore assoluto e relativo

Se $x \in \mathbb{R}$, definiamo l'errore assoluto come:

$$\boxed{|\widetilde{x} - x|}$$

Se, invece, $x \in \mathbb{R}^n$, per rappresentare l'errore assoluto, si utilizza:

$$\boxed{\|\widetilde{x} - x\|}$$

Dove $\|\cdot\|$ è una norma su $\mathbb{R}^m$.

Se $x \in \mathbb{R} \setminus \{0\}$, allora definisco l'errore relativo come:

$$\boxed{\frac{|\widetilde{x} - x|}{|x|}}$$

Definizione 5: Norma

Sia V uno spazio vettoriale e sia:

$$\|\cdot\| : V \longrightarrow \mathbb{R}_{\geq 0}$$

La funzione $\|\cdot\|$ è una norma se soddisfa, per ogni $u, v \in V$ e per ogni $\lambda \in \mathbb{R}$:

1. **omogeneità**: $\|\lambda v\| = |\lambda| \, \|v\|$
2. **definitezza**: $\|v\| = 0 \implies v = 0_V$
3. **disuguaglianza triangolare**: $\|u + v\| \leq \|u\| + \|v\|$

3.2 Norma euclidea

Per

$$v = (v_1, \ldots, v_n)^T \in \mathbb{R}^n$$

la norma euclidea è definita da:

$$\boxed{\|v\| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2} = \left(\sum_{d=1}^{n} v_d^2 \right)^{1/2}}$$

3.3 Norma p

Per $p \geq 1$ si definisce la norma p come:

$$\boxed{\|v\|_p = \left(\sum_{d=1}^{n} |v_d|^p \right)^{1/p}}$$

3.4 Norma infinito

Definizione 6: Norma infinito

La norma infinito è definita come:

$$\|v\|_\infty := \max_i |v_i|$$

3.5 Equivalenza delle norme

Sia $\{v_k\}$ una successione in $\mathbb{R}^n$ e siano $\|\cdot\|_a,\ \|\cdot\|_b$ due norme.

In $\mathbb{R}^n$ tutte le norme sono equivalenti. In particolare:

$$\begin{aligned} &v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_a \quad \left(\text{ossia } \lim_{k\to+\infty} ||v_k - v||_a = 0\right) \\ &\Updownarrow \\ &v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_b \quad \left(\text{ossia } \lim_{k\to+\infty} ||v_k - v||_b = 0\right) \end{aligned}$$

3.6 Errore relativo

Per $v \in \mathbb{R}^m$ e $\tilde{v}$ appross. di v definiamo l'errore relativo rispetto alla norma $\|\cdot\|$ su $\mathbb{R}^m$ come:

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(\widetilde{v}, \|\cdot\|) = \frac{\|\widetilde{v} - v\|}{\|v\|}}$$

3.7 Floating point: successivo e precedente

Poiché $\mathbb{F}_{32}$ e $\mathbb{F}_{64}$ sono insiemi finiti e ordinati, possiamo definire:

Definizione 7: Successivo e precedente

Il successivo di x:

$$\mathrm{succ}(x) = \min\{y \in \mathbb{F} : y > x\} \quad \forall x \in \mathbb{F} \setminus \{\max \mathbb{F}\}$$

Il precedente di x:

$$\mathrm{prec}(x) = \max\{y \in \mathbb{F} : y < x\} \quad \forall x \in \mathbb{F} \setminus \{\min \mathbb{F}\}$$

Quanto vale $\mathrm{succ}(x) - x$?

Pongo

$$x = (-1)^s \cdot 2^{e-b} \cdot 1.f$$

$$\mathrm{succ}(x) = \begin{cases} (-1)^s \cdot 2^{e-b} \cdot 1.f + (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00\ldots0}^{m-1}1 & , s = 0 \\ x - (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00\ldots0}^{m-1}1 & , s = 1 \end{cases}$$

Dato che f contiene n bit, allora la distanza tra due numeri floating point consecutivi, nello stesso intervallo di esponente, è:

$$\boxed{\mathrm{succ}(x) - x = 2^{e-b-n}}$$

3.8 Errore di rappresentazione

$$|x - \mathrm{fl}^T(x)| \leq \begin{cases} \mathrm{succ}(\widetilde{x}) - \widetilde{x} & x > 0 \\ \widetilde{x} - \mathrm{succ}(\widetilde{x}) & x < 0 \end{cases} = |\mathrm{succ}(\widetilde{x}) - \widetilde{x}| = 2^{e-b-n}$$

3.8.1 Errore dovuto al troncamento

$$\frac{\left|x - \mathrm{fl}^T(x)\right|}{|x|} \leq \frac{\left|x - \mathrm{fl}^T(x)\right|}{\left|\mathrm{fl}^T(x)\right|} \leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.f}$$

$$\leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.0} = \boxed{2^{-n}}$$

Pertanto:

$$\boxed{\frac{\left|x - \mathrm{fl}^T(x)\right|}{|x|} \leq 2^{-n}}$$

3.8.2 Errore dovuto all'arrotondamento

L'arrotondamento fa meglio perchè:

$$\left|x - \mathrm{fl}^A(x)\right| \leq \frac{1}{2}|\mathrm{succ}(\widetilde{x}) - \widetilde{x}| = \frac{1}{2} \cdot 2^{e-b-n} = 2^{e-b-n-1}$$

Dividendo per $|x| \geq 2^{e-b}$ otteniamo:

$$\left|\frac{x - \mathrm{fl}^A(x)}{x}\right| \leq \frac{2^{e-b-n-1}}{2^{e-b}} = 2^{-n-1}$$

Pertanto:

$$\boxed{\frac{\left|x - \mathrm{fl}^A(x)\right|}{|x|} \leq 2^{-n-1}}$$

4 Precisione di macchina

Definizione 8: Precisione macchina

Definiamo la precisione di macchina come il più piccolo numero positivo ϵ tale che, se sommato a 1 in virgola mobile, da un risultato diverso da 1.

$$\epsilon_{\mathrm{mach}} := \min\{\epsilon > 0 : \mathrm{fl}(1 + \epsilon) > 1\}$$

4.1 Operazioni macchina

Siano definite le operazioni esatte:

$$\begin{aligned} \Delta : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{R}, & (+, \cdot) \\ \mathbb{R} \times (\mathbb{R} \setminus \{0\}) &\longrightarrow \mathbb{R}, & (:) \end{aligned}$$

Operazione macchina associata $\textcircled{\Delta}$:

$$\begin{aligned} \textcircled{\Delta} \quad & \mathbb{R} \times \mathbb{R} \longrightarrow \mathbb{F} \\ & (x, y) \longrightarrow \textcircled{\Delta}(x, y) = \mathrm{fl}\left(\mathrm{fl}(x) \Delta \cdot \mathrm{fl}(y)\right) \end{aligned}$$

4.2 Errore relativo della moltiplicazione

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(x \odot y) = \frac{|x \odot y - xy|}{|xy|} = \frac{|\mathrm{fl}\left(\mathrm{fl}(x)\,\mathrm{fl}(y)\right) - xy|}{|xy|}}$$

N.B. : noi supponiamo che

$$\frac{|x \cdot y - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} \leq \epsilon_{\mathrm{mach}} \begin{cases} 2^{-n} \\ 2^{-n-1} \end{cases}$$

$z = x \cdot y$

$$\begin{aligned}
\mathrm{Err}_{\mathrm{rel}}(x \odot y) &= \frac{|\mathrm{fl}\left(\mathrm{fl}(x) \cdot \mathrm{fl}(y)\right) - \mathrm{fl}(x \cdot y) + \mathrm{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \\
&\leq \frac{|\mathrm{fl}(\mathrm{fl}(x) \cdot \mathrm{fl}(y)) - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} + \frac{\overbrace{|\mathrm{fl}(x \cdot y) - x \cdot y|}^{\epsilon_{\mathrm{mach}}}}{|x \cdot y|} \\
&= \frac{\overbrace{|\mathrm{fl}\left(\mathrm{fl}(x) \cdot \mathrm{fl}(y)\right) - \mathrm{fl}(x) \cdot \mathrm{fl}(y)|}^{1} + \overbrace{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - \mathrm{fl}(x \cdot y)|}^{2}}{|x \cdot y|} + \epsilon_{\mathrm{mach}} \\
&\leq^{1} \frac{|\mathrm{fl}\left(\mathrm{fl}(x) \cdot \mathrm{fl}(y)\right) - \mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|} \cdot \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|} \\
&\leq \epsilon_{\mathrm{mach}} \cdot \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|} \\
&\leq^{2} \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y + x \cdot y - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} \\
&\leq \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} + \frac{|\mathrm{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \leq \epsilon_{\mathrm{mach}} \\
&\leq \epsilon_{\mathrm{mach}} + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} \\
1 + 2 &\leq \epsilon_{\mathrm{mach}} \left(1 + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|}\right) + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} \\
&\leq \epsilon_{\mathrm{mach}} \left(1 + \epsilon_{\mathrm{mach}} \underbrace{(\ldots\ldots)}_{\text{dipende da } x,\, y}\right)
\end{aligned}$$

Al primo ordine, il comportamento dell'errore relativo non dipende dai valori specifici di x e y.
L'errore relativo della moltiplicazione macchina u: $\epsilon + M\epsilon$.
La moltiplicazione è quindi considerata stabile, ossia l'errore relativo in output è controllato da quello in input.

4.3 Errore relativo della somma

L'errore relativo della somma macchina è:

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(x \oplus y) = \frac{|\mathrm{fl}\left(\mathrm{fl}(x) + \mathrm{fl}(y)\right) - (x + y)|}{|x + y|} = \frac{|x \oplus y - (x + y)|}{|x + y|}}$$

Se x e y hanno segno opposto e sono molto vicini tra loro, può verificarsi una forte cancellazione numerica, ossia la perdita di cifre significative.

Esempio 6: Cancellazione Numerica

Ipotesi in cui x e y si annullano fra loro lasciando solo un ϵ_{mach}:

$$y = -x + \epsilon_{\mathrm{mach}}$$

Svolgimento:

$$\begin{aligned}\mathrm{Err}_{\mathrm{rel}}(x \oplus y) &\leq \epsilon_{\mathrm{mach}} \left(1 + \frac{|x|+|y|}{|x+y|} + \epsilon_{\mathrm{mach}} \frac{|x|+|y|}{|x+y|}\right) \\ &= \epsilon_{\mathrm{mach}} \left(1 + \frac{2|x| + \epsilon_{\mathrm{mach}}}{\epsilon_{\mathrm{mach}}} + 2|x| + \epsilon_{\mathrm{mach}}\right) \\ &= \left(\epsilon_{\mathrm{mach}} + 2|x| + \epsilon_{\mathrm{mach}} + 2|x|\epsilon_{\mathrm{mach}} + \epsilon_{\mathrm{mach}}^2\right) \\ &= 2\left(|x| + \epsilon_{\mathrm{mach}}\right) + \dots\end{aligned}$$

I $\dots$ assorbono $\epsilon_{\mathrm{mach}}^2$ e $2|x|\epsilon_{\mathrm{mach}}$ che sono numeri talmente piccoli rispetto agli altri da essere irrilevanti. Significa che se x è grande, anche l'errore relativo è enorme.

4.4 Stabilità degli algoritmi

Esempio 7: Calcolo dell'integrale col metodo iterativo

$$I_n = \frac{1}{e} \int_0^1 e^x \cdot x^n \cdot dx$$

Svolgimento: Conoscendo il valore di I_0 ossia:

$$I_0 = \frac{1}{e} \int_0^1 e^x \cdot dx = \frac{1}{e} \left[e^x\right]_0^1 = \frac{e-1}{e}$$

Inoltre si può integrare per parti I_n:

$$\begin{aligned}I_n &= \frac{1}{e} \left[\left(e^x x^n\right)_0^1 - \int_0^1 e^x \cdot n x^{n-1} \cdot dx\right] \\ &= \frac{1}{e} \left[e - n \int_0^1 e^x \cdot x^{n-1} \cdot dx\right] \\ &= 1 - n \frac{1}{e} \int_0^1 e^x \cdot x^{n-1} \cdot dx \\ &= 1 - n \cdot I_{n-1}\end{aligned}$$

Di conseguenza conosco la successione definita per ricorsione:

$$\boxed{\begin{cases} I_0 = \frac{e-1}{e} \\ I_n = 1 - n \cdot I_{n-1} \end{cases}}$$

In realtà I_{n-1} viene calcolato con un errore, quindi supponiamo di aver calcolato $\widetilde{I}_{n-1} = I_{n-1} + \epsilon_{n-1}$. Quindi per calcolare I_n:

$$\begin{aligned}I_n &= 1 - n \cdot I_{n-1} \\ \widetilde{I}_n &= 1 - n \cdot \widetilde{I}_{n-1} = \underbrace{1 - n I_{n-1}}\, - n\epsilon_{n-1} \\ &= \boxed{I_n - n\epsilon_{n-1}}\end{aligned}$$

Questo risultato è iterabile dato che si verifica per ogni n, inoltre so che $\epsilon_n = -n\epsilon_{n-1}$.
Iterando n volte ottengo:

$$\boxed{\epsilon_n = (-1)^n \cdot n! \cdot \epsilon_0}$$

L'errore assoluto è quindi:

$$|\widetilde{I}_n - I_n| = n! \cdot |\epsilon_0| = n! \cdot \mathrm{fl}\left(\frac{e-1}{e}\right) - \frac{e-1}{e}$$

Da cui ottengo:

$$= n! \cdot \underbrace{\frac{|\,\mathrm{fl}\left(\frac{e-1}{e}\right) - \frac{e-1}{e}|}{\frac{e-1}{e}}}_{\leq \epsilon_{\text{mach}}} \cdot \underbrace{\frac{e-1}{e}}_{\leq 1}$$

La frazione è l'errore relativo di rappresentazione di un numero reale
L'errore assoluto è dominato da:

$$\boxed{\leq n! \cdot \epsilon_{\text{mach}}}$$

Adesso stimiamo quanto è I_n:

$$I_n = \frac{1}{e}\int_0^1 x^n e^x \cdot dx = O(\frac{1}{n})$$

Dimostriamo che è vero:

Posso stimarlo da sopra con un integrale $\leq$

$$nI_n = \frac{1}{e}\int_0^1 nx^n e^x \cdot dx \leq \frac{1}{e}\int_0^1 enx^n \cdot dx = \frac{n}{n+1}\left[x^{n+1}\right]_0^1 = \frac{n}{n+1}$$

E posso stimarlo da sotto con un'integrale $\geq$

$$nI_n = \frac{1}{e}\int_0^1 nx^n e^x \cdot dx \geq \frac{1}{e}\int_0^1 nx^n \cdot dx = \frac{n}{n+1} \cdot \frac{1}{e}$$

Abbiamo quindi scoperto che $I_n \approx \frac{1}{n+1}$
Adesso possiamo dire che l'errore relativo:

$$\frac{|\widetilde{I}_n - I_n|}{|I_n|} \leq \frac{n!\epsilon_{\text{mach}}}{\frac{1}{n+1}} = (n+1)n!\epsilon_{\text{mach}} = \boxed{(n+1)!\epsilon_{\text{mach}}}$$

Questo algoritmo si dice **instabile**.

Definizione 9: Algoritmo Stabile

Un algoritmo si dice **stabile** se non amplifica in modo incontrollato gli errori presenti sui parametri di input e i dati. In generale, si dice **stabile** un algoritmo per cui vale:

$$\mathrm{Err}^{\mathrm{rel}}(\text{output}) \leq C_{\text{stab}}\,\mathrm{Err}^{\mathrm{rel}}(\text{input})$$

Dove C_{stab} è la costante di stabilità.

4.5 Condizionamento dei problemi

Per ogni problema abbiamo x^* che è la soluzione, su $F : X \times D \to \mathbb{R}$ (o $\mathbb{R}^m$) dove, X è il dominio della soluzione e D è l'insieme dei dati ammissibili.

Definizione 10: Problema ben posto

Un problema si dice **ben posto** se:
1. $\forall d \in D \quad \exists\, x^* \in X : \mathrm{F}(x^*, d) = 0$ esiste una **soluzione**
2. x^*, la soluzione è **unica**
3. x^* varia con **continuità** rispetto ai dati

La soluzione è data dalla **mappa soluzione**:

$$d \mapsto x^*(d) \;:\; \mathrm{F}(x^*(d), d) = 0 \quad x^* \;:\; D \to X$$

I **problemi inversi**, ossia quando dato l'output si vuole ricavare l'input, **non** sono ben posti; dato che più input possono avere lo stesso output. Vengono quindi **regolarizzati**, ossia si modifica il problema in modo da penalizzare soluzioni "non fisiche" o "di bassa energia".

Definizione 11: Condizionamento Numerico

È dato dal rapporto tra l'errore commesso sul risultato di un calcolo e l'incertezza sui dati in ingresso. Un problema si dice **ben condizionato** se la soluzione del problema con delle piccole variazioni, non cambia di molto la soluzione del problema originale. Un problema è **mal condizionato** se la soluzione è molto sensibile a piccole variazioni dei dati iniziali.

4.5.1 Condizionamento di un problema ben posto

$$\frac{\text{cond. locale}}{\text{assoluto}} \quad \mathrm{k}(d) := \limsup_{\widetilde{d}\to d} \frac{\left|x(d)-x(\widetilde{d})\right|}{\left|d-\widetilde{d}\right|}$$

Quindi $\mathrm{k}(d)$ è rappresentato dal limite da i dati approssimati $\widetilde{d}$ verso il dato vero d del condizionamento assoluto diviso l'errore sul dato. Questo limite rappresenta il rapporto incrementale, come nelle derivate.

$$\limsup_{\widetilde{d}\to d} f(\widetilde{d}) = \lim_{r\to 0^+} \sup_{\widetilde{d}\in\,]d-r,d+r[} f(\widetilde{d})$$

Ossia prendo l'intorno del dato d e trovo il sup diminuendo r, in questo modo mi avvicino a d tenendo f più grande possibile.

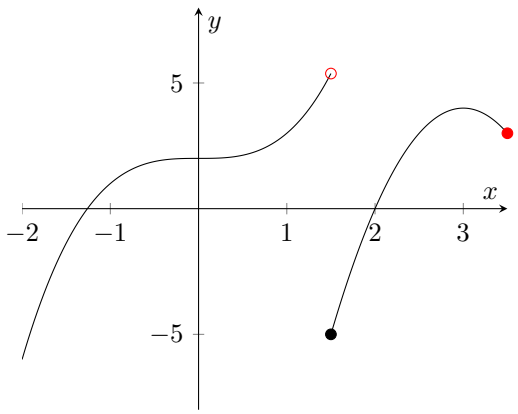
$\mathrm{k}(d)$ è la pendenza del grafico di $x(d)$ **massima in modulo**. Se abbiamo una pendenza $\mathrm{k}(d)$, allora vuol dire che $\forall\,\epsilon>0\ \exists r>0$ tale che:

$$\frac{\left|x(\widetilde{d})-x(d)\right|}{|\widetilde{d}-d|} < \mathrm{k}(d)+\epsilon \quad \forall \widetilde{d}\in\,]d-r,d+r[$$

È quindi una stima dall'alto di d che vale localmente, ossia su un'intorno di d. Per questo si usa il $\limsup$.

Si verifica un problema quando $\mathrm{k}(d) >> 1$ (quindi grande rispetto al contesto). Un **errore assoluto** piccolo su d può implicare un **errore assoluto** enorme su x. **Problema mal condizionato**.

Grafico:



4.5.2 Condizionamento locale relativo

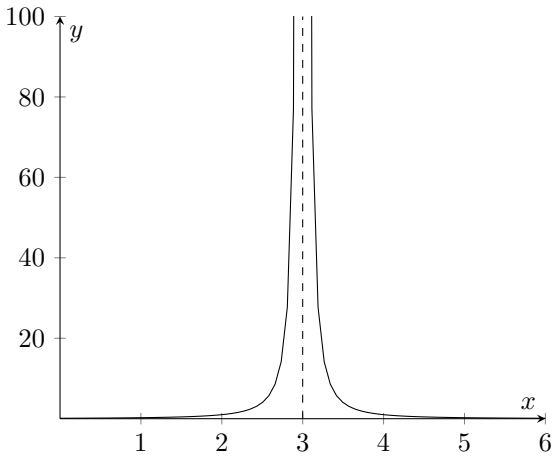
$$\mathrm{k}^{\mathrm{rel}}(d) := \boxed{\limsup_{\widetilde{d}\to d} \underbrace{\frac{\left|x(\widetilde{d})-x(d)\right|}{|x(d)|}}_{\text{pendenza mappa sol.}} \cdot \frac{|d|}{\left|\widetilde{d}-d\right|}}$$

Ci sono problemi in cui il condizionamento non dipende dal dato d, ma è uguale dappertutto.

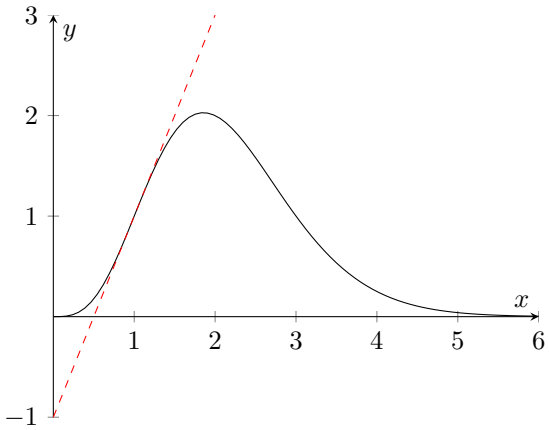
Può succedere che $\exists K\ (K^{\mathrm{rel}})$ tale per cui $\mathrm{k}(d)\le K\ \left(\mathrm{k}^{\mathrm{rel}}(d)\le K^{\mathrm{rel}}\right)\ \forall d\in D$. Dove D è l'insieme di dati ammissibili. In tal caso si parla di condizionamento assoluto/relativo **globale** e si ha:

$$\mathrm{k} = \sup_{d,\widetilde{d}\in D} \frac{\left|x(\widetilde{d})-x(d)\right|}{|\widetilde{d}-d|} \quad \blacktriangle$$

No cond. globale



Si cond. globale



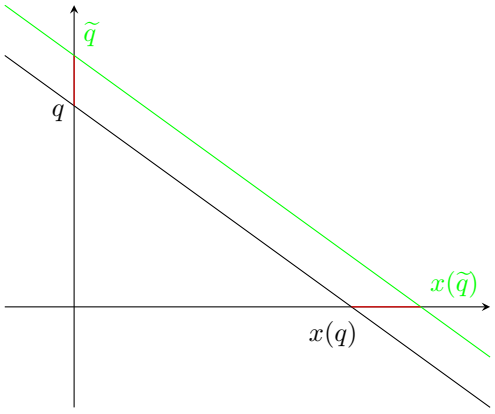
▲ $\left|x(\widetilde{d}) - x(d)\right| \leq \mathrm{K}\left|\widetilde{d} - d\right| \quad \forall\, d, \widetilde{d} \in D$

Ho un fattore moltiplicativo nel caso dell'errore assoluto.
Mentre per il relativo, l'errore varia per ϵ_{mach} moltiplicato a K^{rel}:

$$\frac{\left|x(\widetilde{d}) - x(d)\right|}{|x(d)|} \leq \mathrm{K}^{\text{rel}} \frac{\left|\widetilde{d} - d\right|}{|d|}$$

Se $\mathrm{K}^{\text{rel}} \approx \frac{1}{\epsilon_{\text{mach}}} \Rightarrow \frac{|x(\widetilde{d}) - x(d)|}{|x(d)|} \approx 1 = 100\%$ Quindi un'errore relativo di circa 1 vuol dire che la soluzione è completamente diversa da quella vera.

Esempio :

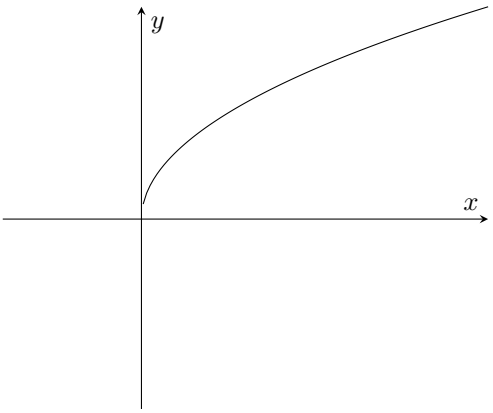


Con il grafico si nota come un minore errore su q crea un errore maggiore su $x(q)$.

4.5.3 Condizionamento globale di ordine α

Esempio 8: Cosa succede quando la pendenza "esplode"?

Dato $d \in D$, la cui mappa soluzione è $d \mapsto x(d)$ con $D = [0, +\infty[$ e $x(d) = \sqrt{d}$.



In questo la caso la pendenza vicino a 0 tende a ∞.
Quindi:

$$\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\widetilde{d}-d\right|}=\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\left(\sqrt{\widetilde{d}}-\sqrt{d}\right)\left(\sqrt{\widetilde{d}}+\sqrt{d}\right)\right|}=\frac{1}{\left|\sqrt{\widetilde{d}}+\sqrt{d}\right|}$$

Ossia abbiamo che:

$$\limsup_{\widetilde{d}\to d}\frac{1}{2\sqrt{d}}\begin{cases}d\neq 0 & \checkmark\\ d=0 & +\infty\end{cases}$$

Quindi avvicinandomi a $d=0$ non riesco a fare delle stime quantitative.
Si introduce quindi il **condizionamento globale assoluto** di **ordine** $\alpha\in(0,1)$

$$\mathrm{k}_\alpha=\boxed{\sup_{d,\widetilde{d}}\frac{\left|x(\widetilde{d})-x(d)\right|}{\left|\widetilde{d}-d\right|^\alpha}}$$

Lo usiamo per studiare problemi **molto mal condizionati**.

Nell'esempio $\alpha=\frac{1}{2}$:

$$=\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\widetilde{d}-d\right|^{\frac{1}{2}}}$$

$$=\frac{\epsilon}{\left(\epsilon(2\sqrt{d}+\epsilon)\right)^{\frac{1}{2}}}=\frac{\epsilon}{\left(\epsilon^2+2\epsilon\sqrt{d}\right)^{\frac{1}{2}}}\quad \text{se } d=0\to\frac{\epsilon}{\epsilon}=1$$

se $d>0$ si mostra che è limitata.

Se vale:

$$\sup_{d,\widetilde{d}}\frac{\left|x(\widetilde{d})-x(d)\right|}{\left|\widetilde{d}-d\right|^\alpha}\leq \mathrm{k}_\alpha$$

$$\left|x(\widetilde{d})-x(d)\right|\leq \mathrm{k}_\alpha\left|\widetilde{d}-d\right|^\alpha\quad\forall d,\widetilde{d}\in D$$

Nota: $\alpha<1\quad\left|\widetilde{d}-d\right|<<1\Rightarrow\left|\widetilde{d}-d\right|^\alpha>>\left|\widetilde{d}-d\right|$.

5 Algebra Lineare Numerica

5.1 Soluzione di Sistemi Quadrati

Problema: $A\in M_{n\times n}(\mathbb{R}), b\in\mathbb{R}^n$ con A invertibile.
Trovare $x\in\mathbb{R}^m$ tale che $\underbrace{Ax-b=0}_{\mathrm{F}(x,d)=0}$ funzione che prende un vettore reale e ne ritorna un'altro.

Dominio di $F\quad \underset{x}{\mathbb{R}^n}\times\underset{A}{M_{n\times n}(\mathbb{R})}\times\underset{b}{\mathbb{R}^n}\to\underset{Ax-b}{\mathbb{R}^n}$

Osservazione: A invertibile $\Rightarrow$ esiste ed è unica $x: \ Ax = b$, quindi la mappa soluzione è:

$$x = A^{-1}b$$

Manca sapere se la mappa soluzione è continua, serve quindi una norma sul dominio e una sul codominio. Su $\mathbb{R}^n$ prendiamo una norma qualsiasi.

5.2 Norma indotta

Definizione 12: Norma Indotta

Se $\|\cdot\|$ è una norma su $\mathbb{R}^m$ esiste una norma detta **naturale** su $M_{m\times m}(\mathbb{R})$ **indotta** da $\|\cdot\|$:

$$\|A\|_* = \sup_{x\in\mathbb{R}^m\setminus\{0\}} \frac{\|Ax\|}{\|x\|}$$

Questa norma indicata è $\|\cdot\|_*$

Proposizione: $\|\cdot\|_*$ è una norma.

Dimostrazione: Devo dimostrare che rispetta le proprietà di una norma.

1. Omogeneità di grado 1. Prendiamo $\lambda \in \mathbb{R}\setminus\{0\}$ allora:

$$\begin{aligned}\|\lambda A\|_* &= \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|\lambda(Ax)\|_*}{\|x\|} = \sup_{x\in\mathbb{R}\setminus\{0\}} |\lambda|\cdot\frac{\|Ax\|}{\|x\|} \\ &= |\lambda| \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|Ax\|}{\|x\|} = |\lambda|\cdot\|A\|_* \quad \checkmark\end{aligned}$$

2. Una norma è $=0$ se e solo se è$\|0\|$. Quindi supponiamo che la norma sai uguale a 0:

$$0 = \|A\|_* = \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|Ax\|}{\|x\|} \Rightarrow \|Ax\| = 0 \quad \forall\, x\in\mathbb{R}^m$$

$$Ax = \begin{pmatrix}0\\ \vdots \\ 0\end{pmatrix} \quad \forall\, x\in\mathbb{R}^m \qquad \text{Quindi è un vettore nullo}$$

$$\underset{i\text{-esima colonna}}{A(:,i)} = A_{ei} = \begin{pmatrix}0\\ \vdots \\ 0\end{pmatrix} \quad \forall\, i \quad \Rightarrow \quad A = \begin{pmatrix}0 & \dots & 0\\ \vdots & & \vdots \\ 0 & \dots & 0\end{pmatrix} \quad \checkmark$$

3. Disuguaglianza triangolare:

Ho dimostrato che è una norma dato che rispetta tutte e tre le proprietà.

Che norma si usa su $V\times W$ con V e W che hanno le norme $\|\cdot\|_v, \|\cdot\|_w$?

$$\|(v,w)\|_{v\times w} := \|v\|_v + \|w\|_w \quad \text{Per esempio}$$

La mappa soluzione: $x(A,b) = A^{-1}b$ è continua?

$\forall\epsilon > 0 \ \exists\delta > 0$ tale che

$$\left\|x\left(\widetilde{A},\widetilde{b}\right) - x\left(A,b\right)\right\| < \epsilon \quad \text{se} \quad \left\|\left(\widetilde{A},\widetilde{b}\right) - (A,b)\right\|_{\mathbb{M}_{m\times m}(\mathbb{R})\times\mathbb{R}^m} < \delta$$

Osservazione: È composizione di $A \mapsto A^{-1}$ continua sulle matrici invertibili.
E $\left(A^{-1}, b\right) \mapsto A^{-1}b$ continua.
Dunque la mappa soluzione è continua in (A, b) se A è invertibile.

Come è condizionato il problema?

- Considero il caso in cui A sia fissa ed "esatta".

  $b \mapsto x(A,b) = A^{-1}b$
  $A(x+\delta x) = b + \delta b \quad x+\delta x$ soluzione del sistema, con termine noto perturbato
  $Ax = b$

  Ci interessa quindi l'errore relativo: $\dfrac{\|\delta x\|}{\|x\|} \leq \cdots \dfrac{\|\delta b\|}{\|b\|}$

  $\underset{=b}{Ax} + A\delta x = b + \delta b$
  $\delta x = A^{-1}\delta b \Rightarrow$ Se due vettori sono uguali hanno anche norme uguali: $\|\delta x\| = \left\|A^{-1}\delta b\right\|$
  $\Rightarrow \quad \|\delta x\| = \left\|A^{-1}\delta b\right\| \leq \left\|A^{-1}\right\|_* \|\delta b\| \quad \circledast$

> **Nota 1**
>
> Dato che
> $$\frac{\|Ax\|}{\|x\|} \leq \sup_y \frac{\|Ay\|}{\|y\|} = \|A\|_* \quad \forall x \in \mathbb{R}^n$$
> Allora:
> $$\boxed{\|Ax\| \underset{\forall x \in \mathbb{R}^n}{\leq} \|A\|_* \cdot \|x\|}$$

Su $\circledast$ sto misurando in termini assoluti, devo invece misurare in termini <u>relativi</u> dividendo per $\|x\|$:

$\dfrac{\|\delta x\|}{\|x\|} \leq \left\|A^{-1}\right\|_* \|\delta b\| \cdot \dfrac{1}{\|x\|}$ $\triangle$ Mi serve poter stimare da sopra $\|x\| \geq \ldots$ qualcosa

$\circledast \quad \|x\| \geq \dfrac{\|b\|}{\|A\|_*} \Leftarrow \begin{cases} Ax = b \Rightarrow \|Ax\| = \|b\| \\ \|Ax\| \leq \|A\|_* \|x\| \quad \text{Nota 1} \end{cases}$

$\triangle + \circledast \quad \dfrac{\|\delta x\|}{\|x\|} \leq \left\|A^{-1}\right\|_* \|A\|_* \cdot \dfrac{\|\delta b\|}{\|b\|} \; \forall b \in \mathbb{R}^n$

Dove $\left\|A^{-1}\right\|_* \|A\|_*$ è l'indice di condizionamento globale del problema semplificato.

- Ora considero di perturbare anche A:

$$\begin{cases} (A+\delta A)(x+\delta x) = b + \delta b \\ Ax = b \end{cases}$$
$$(A+\delta A)\delta x = b + \delta b - (A+\delta A)x = \delta b - \delta A x \quad \odot$$

Noto che se $\frac{\|\delta A\|_*}{\|A\|_*} < \frac{1}{\|A\|_* \|A^{-1}\|_*}$, allora $\mathbb{1} + A^{-1}\delta A$ è **invertibile**.

Dimostrazione: Suppongo per assurdo che $\mathbb{1} + A^{-1}\delta A$ non sia invertibile

$\exists y \neq 0$ tale che $\left(\mathbb{1} + A^{-1}\delta A\right) y = 0$ cioè $A^{-1}\delta A y = -y$
$\Rightarrow \left\|A^{-1}\delta A y\right\| = \|y\|$
$1 = \dfrac{\left\|A^{-1}\delta A y\right\|}{\|y\|} \leq \underset{x \in \mathbb{R}^n \; x \neq 0}{\sup} \dfrac{\left\|A^{-1}\delta A x\right\|}{\|x\|} \underset{\text{Nota 1}}{=} \left\|A^{-1}\delta A\right\|_*$
$1 \leq \left\|A^{-1}\delta A\right\|_* \underset{\text{Nota 1}}{\leq} \left\|A^{-1}\right\|_* \|\delta A\|_* = \left\|A^{-1}\right\|_* \|A\|_* \cdot \dfrac{\|\delta A\|_*}{\|A\|_*}$
$\dfrac{1}{\|A\|_* \|A^{-1}\|_*} \leq \underset{\text{Perturbazione rel.}}{\dfrac{\|\delta A\|_*}{\|A\|_*}}$ **Assurdo** contraddice l'ipotesi. ✓

Da $\odot$ segue che:

$$\begin{aligned}(A+\delta A)\delta x &= \delta b - \delta A x\\ A(\mathbb{1}+A^{-1}\delta A)\delta x &= \delta b - \delta A x\\ \delta x &= (\mathbb{1}+A^{-1}\delta A)^{-1}\cdot A^{-1}(\delta b - \delta A x)\\ &= (\mathbb{1}+A^{-1}\delta A)^{-1}\cdot A^{-1}(\delta b - \delta A A^{-1} b)\end{aligned}$$

Passiamo alle norme

$$\begin{aligned}\|\delta x\| = \cdots &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left\|\delta b - \delta A A^{-1} b\right\|\\ &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left(\|\delta b\| + \left\|\delta A A^{-1} b\right\|\right)\\ &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left(\|\delta b\| + \|\delta A\|_* \left\|A^{-1}\right\|_* \|b\|\right)\end{aligned}$$

Prima abbiamo usato $\frac{1}{\|x\|} \le \frac{\|A\|_*}{\|b\|}$. Quindi Per l'errore relativo:

$$\frac{\|\delta x\|}{\|x\|} \le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \|A\|_* \left(\frac{\|\delta b\|}{\|b\|} + \left\|A^{-1}\right\|_* \|\delta A\|_*\right)$$

$\|\delta A\|_*$ è un errore assoluto, noi stiamo usando solo errori relativi, quindi divido e moltiplico per $\|A\|_*$

$$\frac{\|\delta x\|}{\|x\|} \le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \boxed{\left\|A^{-1}\right\|_* \|A\|_*} \left(\frac{\|\delta b\|}{\|b\|} + \boxed{\left\|A^{-1}\right\|_* \|A\|_*} \frac{\|\delta A\|_*}{\|A\|_*}\right) \quad \circledast$$

Definizione 13: Numero di condizionamento

La quantità $\left\|A^{-1}\right\|_* \|A\|_*$ è detta numero di condizionamento della matrice A rispetto alla norma $\|\cdot\|$ si denota con $k(A,\|\cdot\|)$ o $\mathrm{Cond}(A,\|\cdot\|)$

La stima $\circledast$ è una stima di condizionamento **relativo locale**.

Tipicamente per matrici grandi $\begin{cases}\text{Piene} & n > 10^4\\ \text{Sparse} & n > 10^6\end{cases}$

$\mathrm{Cond}(A,\|\cdot\|)$ è facilmente $\approx 10^4\ 10^5$ in casi buoni.
Sbagliare A di 10^{-16} relativo, implica avere un errore relativo su x di 10^{-8}. Quindi su 16 cifre significative ne calcolo solo 8 correttamente: questo è un caso buono per le matrici grandi.
Salvezza: In generale tutti i $\le$ mostrati finora sono in realtà stretti, per ottenere l'uguaglianza, ossia l'errore massimo bisogna prendere il peggior dato con la peggior perturbazione (**molto improbabile**).

Riprendiamo il caso in cui A è fissa ed esatta dove abbiamo $Ax = b$ ossia, perturbando A:

$$\begin{aligned}A(x+\delta x) = b + \delta b \ &\to\ \frac{\|\delta x\|}{\|x\|} \le \mathrm{k}(A,\|\cdot\|)\frac{\|\delta b\|}{\|b\|}\\ \mathrm{k}(A,\|\cdot\|) &= \|A\|_* \left\|A^{-1}\right\|_*\end{aligned}$$

Si tratta di una disequazione sharp? (potrebbe esistere il caso di uguaglianza)

Suppongo di usare $\|\cdot\| = \|\cdot\|_2$, ossia la **norma euclidea** $\|v\|_2 = \left(\sum v_i^2\right)^{1/2}$.
Chi è la **Norma indotta** su $M_{n\times n}(\mathbb{R})$?

$$\|A\|_* = \max_{x\neq 0}\frac{\|Ax\|_2}{\|x\|_2} = \left(\max_{x\neq 0}\frac{\sum (Ax)_i^2}{\sum x_i^2}\right)^{\frac{1}{2}}$$

Ricordiamo la proprietà del prodotto riga x colonna tra vettori: $\boxed{\sum y_i^2 = y^T\cdot y}$

$$= \left[\max_{x\neq 0}\frac{x^T A^T A x}{x^T x}\right]^{\frac{1}{2}} \quad \circledast \quad G = A^T A = G^T \text{ matrice simmetrica}$$

Nota 2

M è una matrice quadrata, se è diagonalizzabile allora:

$$M = P\Lambda P^{-1}$$

Dove λ è la matrice diagonale con gli autovalori di M e P è una matrice invertibile le cui colonne sono autovettori di M.

5.2.1 Teorema Spettrale

Teorema 1: Teorema Spettrale

Ho $G \in M_{n\times n}(\mathbb{R})$ **simmetrica** allora: $\exists\ \lambda_1, \lambda_2, \dots, \lambda_n$ e $Q \in M_{n\times n(\mathbb{R})}$ matrice **ortogonale** ($Q^TQ = QQ^T = \mathbb{1}_n$) tali che:

$$\boxed{G = Q\Lambda Q^T} \quad \Lambda = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{pmatrix}$$

Quindi:

$x^TA^TAx = x^TGx \geq 0$ dato che è uguale a $\|Ax\|_2^2$

È $= 0$ solo se $Ax = 0$ se A è di rango pieno ciò implica che $x = 0$

$\Rightarrow \lambda_i > 0$ se A è invertibile

G si dice quindi, **simmetrica strettamente definita positiva**, ossia tutti i suoi autovalori sono maggiori stretti di 0.

$$\circledast \|A\|_*^2 = \max_{x\neq 0} \frac{x^TGx}{x^Tx} \underset{\text{Teo. spett.}}{=} \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^Tx}$$

$$= \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^T\underbrace{\mathbb{1}}_{=QQ^T}x} = \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^TQQ^Tx}$$

Dato che Q è invertibile, allora posso fare un cambio di variabile: $y = Q^Tx \quad x = 0 \Leftrightarrow y = 0$

$$= \max_{y\neq 0} \frac{y^T\Lambda y}{y^Ty} = \max_{y\neq 0} \left(\frac{y}{\|y\|}\right)^T \Lambda \frac{y}{\|y\|}$$

Sono quindi passato da una generica matrice positiva ad un matrice diagonale con diagonale positiva.

$= max_{z:\ \|z\|_2=1} z^T\Lambda z$

Vogliamo, quindi, risolvere:

$max \sum_{i=1}^n \lambda_i z_i^2 \quad$ con $\quad \sum_{i=1}^n z_i^2 = 1$

Ossia voglio trovare il massimo autovalore di G

Provo con: $z = e_{\underline{i}} \ :\ \lambda_{\underline{i}} \geq \lambda_i\ \forall i = 1 \dots n \quad$ suppongo: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$

$$\sum_{i=1}^n \lambda_i z_i^2 = \lambda_1 \underbrace{\left(z_1^2 + \sum_{i=2}^n \frac{\lambda_i}{\lambda_1} z_i^2\right)}_{\text{Separo il primo termine}} \leq \lambda_1 \underbrace{\left(z_1^2 + \sum_{i=2}^n z_i^2\right)}_{=1} = \lambda_1$$

Se prendo $z = e_1$ (primo vettore della base canonica) ottengo:

$$\sum_{i=1}^n \lambda_i z_i^2 = \lambda_1 \cdot 1^2 + \lambda_2 \cdot 0^2 + \dots + \lambda_n \cdot 0^2 = \boxed{\lambda_1}$$

Quindi vale:

$$\|A\|_*^2 = \max_{z:\ \|z\|_2=1} \frac{z^T G z}{z^T z} = \lambda_{\max}(G) \text{ autovalore massimo}$$

$$\boxed{\|A\|_* = \sqrt{\lambda_{\max}\left(A^T A\right)} \text{ se } \|\cdot\| = \|\cdot\|_2}$$

5.2.2 Decomposizione ai valori singolari (SVD)

Teorema 2

Se $A \in M_{n\times n}(\mathbb{R})$ di rango pieno allora $\exists\, U, \Sigma\, V$ con U, V **ortogonali** $n\times n\ \Sigma = \begin{pmatrix} \sigma_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_n \end{pmatrix}$ **diagonale**

con $\sigma_i > 0$. Tale per cui:

$$\boxed{A = U\Sigma V^T}$$

Adesso vediamo cosa sono U, Σ, V:

$$A^T A = V\Sigma U^T \cdot U\Sigma V^T = V\Sigma \cdot \Sigma V^T = V\Sigma^2 V^T \Rightarrow \sigma_i^2 \text{ autovalore di } A^T A$$

Si nota che le colonne di V sono gli autovettori di $A^T A$. Per dimostrarlo, prendiamo una colonna di V, la moltiplichiamo e vediamo se otteniamo λ volte la stessa colonna (proprietà **autovalore**).
$V(:, j)$ è la j-esima colonna.

$$A^T A \cdot V(:, j) = V\Sigma^2 \underbrace{V^T V(:, j)}_{w}$$

$$w_i = V^T(i, :)V(:\, j) = V(:, i)^T V(:, j) = \left(V^T V\right)(i, j) = \mathbb{1}(i, j) \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

$$A^T A \cdot V(:, j) = V\Sigma^2 e_j = V\sigma_j^2 e_j = \sigma_j^2 V e_j = \underset{\text{autovalore}}{\sigma_j^2}\ \underset{\text{autovettore}}{V(:, j)}$$

Questo spiega cos'è V e Σ^2. Ora vediamo cos'è la matrice U:

$$AA^T = U\Sigma V^T \cdot V\Sigma U^T = U\Sigma^2 U^T$$

Adesso non serve rifare i conti, sono gli stessi ma con nomi diversi. Quindi ottengo:

$\Rightarrow \sigma_j^2$ sono anche autovalori di AA^T

$\Rightarrow$ Gli autovettori di AA^T sono le colonne di U

Adesso continuiamo con il condizionamento in norma 2 e nel vedere se la disequazione è sharp:

$$\|A\|_* = \sqrt{\lambda_{\max}\left(A^T A\right)} = \sqrt{\lambda_{\max}\left(V\Sigma^2 V^T\right)} = \sqrt{\max \sigma_i^2} = \sigma_{\max}$$

Per il condizionamento serve anche:

$$\left\|A^{-1}\right\|_* = \sqrt{\lambda_{\max}\left(A^{-T} A^{-1}\right)}$$

$$A = U\Sigma V^T \Rightarrow A^{-1} = V\Sigma^{-1} U^T \qquad \Sigma^{-1} = \begin{pmatrix} \frac{1}{\sigma_1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \frac{1}{\sigma_n} \end{pmatrix}$$

$$A^{-T} A^{-1} = U\Sigma^{-1} V^T \cdot V\Sigma^{-1} U^T = U\Sigma^{-2} U^T$$

$$\left\|A^{-1}\right\|_* = \sqrt{\lambda_{\max}\left(U\Sigma^{-2} U^T\right)} = \max \frac{1}{\sigma_i} = \frac{1}{\sigma_{\min}}$$

$$\boxed{\mathrm{k}\left(A, \|\cdot\|_2\right) = \|A\|_* \left\|A^{-1}\right\|_* = \frac{\sigma_{\max}}{\sigma_{\min}}}$$

$\|A\|_*$ nel caso $\|\cdot\| = \|\cdot\|_2$ su $\mathbb{R}^n$ viene denotata con $\|A\|_2$.

Torniamo a domandarci se:

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \mathrm{k}\left(A, \|\cdot\|_2\right) \frac{\|\delta b\|_2}{\|b\|_2}$$

è irrealistica, cioè esiste l'uguaglianza?
Per dimostrarla abbiamo usato 2 stime:

1. $\|b\|_2 = \|Ax\|_2 \leq \|A\|_2 \|x\|_2$ Può valere nel caso di uguaglianza?

$$\|Ax\|_2^2 = x^T V \Sigma U^T \cdot U \Sigma V^T x = x^T V \Sigma^2 V^T x$$
$$y = V^T x \quad \Rightarrow \quad y^T \Sigma^2 y$$
$$\|x\|_2^2 = \left\|V^T x\right\|_2^2 = \|y\|_2^2$$

> **Nota 3: Ragionamento**
>
> Il $\max \frac{\|Ax\|_2^2}{\|x\|_2^2}$ è raggiunto se x è proporzionale all'autovettore relativo all'autovalore massimo di $A^T A$, ossia $\sigma_{\max}^2$ cioè la prima colonna di V. Quindi esiste l'uguaglianza.

Se $x = c \cdot V(:,1) \quad Ax = b \Rightarrow b = c \cdot A^{-1} V(:,1) = c \cdot V \Sigma^{-1} U^T V(:,1)$ allora:

$$\|b\|_2 = \|A\|_2 \|x\|_2 \qquad \text{(esiste l'uguaglianza)}$$

2. $\|\delta x\|_2 = \left\|A^{-1} \delta b\right\|_2 \leq \left\|A^{-1}\right\|_2 \|\delta b\|_2$ Esiste l'uguaglianza?

   Usando nuovamente la nota 3 il caso di uguaglianza, si verifica se il vettore δb è proporzionale all'autovettore relativo all'autovalore massimo di $A^{-T} A^{-1} \Rightarrow \frac{1}{\sigma_{\min}}$. Dunque $\delta b = \epsilon U(:,n)$.

Quindi la stima è sharp, cioè ottimale dato che esiste l'uguale. In generale, è una stima pessimistica.

5.3 Risoluzione pratica $Ax = b$

Osservazione:

Se la matrice A è triangolare superiore $\begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$ o inferiore $\begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}$: So risolvere il problema.

5.3.1 Caso inferiore

$$a_{11} x_1 = b_1 \Rightarrow x_1 = \frac{b_1}{a_{11}} \qquad \text{(Sto ignorando i valori } 0\text{)}$$
$$a_{21} x_1 + a_{22} x_2 = b_2 \Rightarrow x_2 = \frac{b_2 - a_{21} x_1}{a_{22}}$$
$$\text{In generale: } x_1 = \frac{b_1}{a_1} \quad x_k = \boxed{\frac{b_k - \sum_{j=1}^{k-1} a_{k,j} x_j}{a_{k,k}}} \qquad \text{(algoritmo di sostituzione in avanti)}$$

5.3.2 Caso superiore

$$a_{nn} x_n = b_n \Rightarrow x_n = \frac{b_n}{a_{nn}}$$
$$\text{In generale: } x_k = \boxed{\frac{b_k - \sum_{j=k+1}^{n} a_{k,j} x_j}{a_{k,k}}} \qquad \text{(algoritmo sostituzione all'indietro)}$$

5.4 Fattorizzazione

Dato che le matrici triangolari sono poche, si usa il metodo di eliminazione gaussiana, per ottenerne di più.

Nota 4: Fattorizzazione

Il metodo di eliminazione gaussiana si può vedere come **fattorizazzione** di matrice. La fattorizzazione LU tale che $A = LU$ dove L sta per "lower triangular" invertibile e U "upper triangular" invertibile.

A cosa serve una fattorizzazione di questo tipo?

$$Ax = b \Leftrightarrow \underset{\text{associativo}}{LUx} = b$$

Faccio un cambio di variabile $y = Ux$ e ottengo:

- $Ly = b$ posso calcolare y con la sostituzione in avanti.
- $Ux = y$ posso calcolare x con la sostituzione all'indietro.

Rendiamo algoritmico il metodo di eliminazione gaussiana (MEG):

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) = \mathbb{1} - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \quad m^{(k)} \in \mathbb{R}^{n-k}$$

Nota 5

È colonna $\times$ riga, ossia $\left(u\ v^T\right)_{i,j} = u_i v_j$

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & 1 & \vdots \\ 0 & -m^{(k)} & 1 \end{pmatrix}$$

Nella k-esima colonna ci metto $-m^{(k)}$ per questo è lunga $n-k$, sono gli elementi sotto la diagonale.

Cosa succede se faccio $\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) \cdot A$?

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) A = \left(\mathbb{1}_n - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T\right) A \underset{prop.assoc.}{=} A - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} \underbrace{e_k^T A}_{k\text{-esima riga di } A}$$

$$= A - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} A(k,:) = A - \begin{pmatrix} 0 & \dots & 0 \\ 0 & \dots & k \text{ righe} \\ m_1^k A(k,1) & \dots & m_1^k A(k,n) \\ \vdots & & \vdots \\ m_{n-k}^k A(k,1) & \dots & m_{n-k}^k A(k,n) \end{pmatrix}$$

Ossia ad ogni riga di A da $k+1$ a n togliamo la k-esima riga di A moltiplicata per $m_1^k, \dots, m_{n-k}^k$ (**moltiplicatori**). Nel MEG scelgo i moltiplicatori per eliminare tutta la parte sottodiagonale di A nella colonna k-esima.

La colonna k-esima di $\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) A$ è:

$$A(:,k) - \begin{pmatrix} 0 \\ k \text{ volte} \\ 0 \\ m_1 A(k,k) \\ \vdots \\ m_{n-k}^k A(k,k) \end{pmatrix} = \left(\begin{array}{c} A(1,k) \\ \vdots \\ A(k,k) \\ \hline A(k+1,k) - m_1^k A(k,k) \\ \vdots \\ A(n,k) - m_{n-k}^k A(k,k) \end{array}\right)$$

La parte bassa è quella che voglio annullare. Per far ciò devo "scegliere" m nel seguente modo:

$$\circledast \quad m_l^k = \frac{A(k+l,k)}{A(k,k)}$$

Devo verificare che $A(k,k) \neq 0$, ossia la diagonale diversa da zero, perchè potrebbe esserci il caso:

Esempio 9: Problema Diagonale $= 0$

$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ $\det(A) = -1$ La matrice è invertibile nonostante la diagonale $= 0$.

Ipotesi : Per il momento supponiamo che $A(k,k) \neq 0$.
Poniamo $\widetilde{\mathrm{L}}^{(k)} = \widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)$ con m^k scelto come in $\circledast$.

Algoritmo :

$A^{(1)} = A$

$A^{(k)} = \widetilde{\mathrm{L}}^{(k-1)} A^{(k-1)}$ Quello k-esimo è dato da quello $(k-1)$-esimo

Se vale l'ipotesi ad ogni passo: $\boxed{A^{(k-1)}(k-1,k-1) \neq 0}$. Dopo $n-1$ passi avrò:

$$A^n = \widetilde{\mathrm{L}}^{(n-1)} A^{(n-1)} = \widetilde{\mathrm{L}}^{(n-1)} \widetilde{\mathrm{L}}^{(n-2)} A^{(n-2)} \cdots = \widetilde{\mathrm{L}}^{(n-1)} \ldots \widetilde{\mathrm{L}}^{(1)} A$$

La matrice A^n sarà, quindi, una triangolare superiore; perchè al primo passo abbiamo preso la colonna 1 di A ed eliminato la sua parte sotto la diagonale. Quindi $A^{(2)}$ ha la colonna 1 con la parte sottodiagonale **nulla**. Poi $A^{(3)} = \widetilde{\mathrm{L}}^{(2)} A^2 = \left(\mathbb{1} - \begin{pmatrix} 0 \\ m^2 \end{pmatrix} e_2^T\right) A^2 = A^2 - \begin{pmatrix} 0 \\ m^2 \end{pmatrix} e_2^T A^{(2)}$ e dato che A^2 ha la prima colonna sottodiagonale 0 e viene sottratta ad una cosa che ha la prima colonna tutto 0. Quindi anche $A^{(3)}$ ha la prima colonna sottodiagonale 0 e in più anche la seconda colonna ha la stessa proprietà per $\circledast$.
Iterando questo ragionamento otteniamo che $A^{(n)}$ ha le colonne $1, 2, \ldots, n-1$ che rispettano la stessa proprietà. Di conseguenza è **triangolare superiore**.

Pongo $U = A^{(n)}$