

# Calcolo Numerico

Marco Pittarello

## Contents

|          |                                                   |          |
|----------|---------------------------------------------------|----------|
| <b>1</b> | <b>Sistemi non decimali</b>                       | <b>2</b> |
| 1.1      | Conversione della parte intera . . . . .          | 2        |
| 1.2      | Conversione della parte frazionaria . . . . .     | 3        |
| <b>2</b> | <b>Numeri macchina</b>                            | <b>4</b> |
| 2.1      | Interi macchina . . . . .                         | 4        |
| 2.1.1    | Overflow . . . . .                                | 5        |
| 2.2      | Floating point e standard IEEE 754 . . . . .      | 5        |
| 2.3      | Tabella riassuntiva IEEE 754 . . . . .            | 6        |
| 2.4      | Arrotondamento e troncamento . . . . .            | 6        |
| <b>3</b> | <b>Errore e norme</b>                             | <b>7</b> |
| 3.1      | Errore assoluto e relativo . . . . .              | 7        |
| 3.2      | Norma euclidea . . . . .                          | 7        |
| 3.3      | Norma $p$ . . . . .                               | 7        |
| 3.4      | Norma infinito . . . . .                          | 8        |
| 3.5      | Equivalenza delle norme . . . . .                 | 8        |
| 3.6      | Errore relativo . . . . .                         | 8        |
| 3.7      | Floating point: successivo e precedente . . . . . | 8        |
| 3.8      | Errore di rappresentazione . . . . .              | 9        |
| 3.8.1    | Errore dovuto al troncamento . . . . .            | 9        |
| 3.8.2    | Errore dovuto all'arrotondamento . . . . .        | 9        |
| <b>4</b> | <b>Precisione di macchina</b>                     | <b>9</b> |
| 4.1      | Operazioni macchina . . . . .                     | 9        |
| 4.2      | Errore relativo della moltiplicazione . . . . .   | 10       |
| 4.3      | Errore relativo della somma . . . . .             | 10       |

# 1 Sistemi non decimali

## Definizione 1: Conversione da base $N$ a base $M$

Dato  $x > 0$  e nota la rappresentazione  $(x)_N$ , vogliamo trovare la rappresentazione  $(x)_M$ .  
Scriviamo:

$$\begin{aligned}x &= x_n N^n + x_{n-1} N^{n-1} + \dots + x_0 + x_{-1} N^{-1} + \dots + x_{-r} N^{-r} \\ &= y_m M^m + y_{m-1} M^{m-1} + \dots + y_0 + y_{-1} M^{-1} + \dots + y_{-q} M^{-q}.\end{aligned}$$

Si procede separatamente per la parte intera e per la parte frazionaria.

## 1.1 Conversione della parte intera

Per convertire la parte intera si itera lo schema della divisione intera per  $M$ :

$$\begin{array}{ll}y_0 := x \bmod M & x = q_0 M + y_0 \\ y_1 := q_0 \bmod M & q_0 = q_1 M + y_1 \\ \vdots & \\ y_m := q_{m-1} \bmod M & q_{m-1} = y_m < M\end{array}$$

**OSSERVAZIONE:**  $x \bmod M$  indica il resto della divisione intera di  $x$  per  $M$ .

I resti ottenuti sono le cifre della rappresentazione in base  $M$ , lette dal basso verso l'alto. Pertanto:

$$(x_{\text{int}})_M = y_m y_{m-1} \dots y_1 y_0$$

## Esempio 1: Conversione da base 2 a base 10

Convertiamo

$$(10011010010)_2$$

in base 10.

Si ha:

$$\begin{aligned}(10011010010)_2 &= 1 \cdot 2^{10} + 0 \cdot 2^9 + 0 \cdot 2^8 + 1 \cdot 2^7 + 1 \cdot 2^6 \\ &\quad + 0 \cdot 2^5 + 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 \\ &= 2^{10} + 2^7 + 2^6 + 2^4 + 2^1 \\ &= 1024 + 128 + 64 + 16 + 2 \\ &= 1234\end{aligned}$$

Quindi:

$$(10011010010)_2 = (1234)_{10}$$

## Esempio 2: Conversione da base 10 a base 2

Convertiamo

$$(1234)_{10}$$

in base 2 utilizzando divisioni successive per 2:

$$1234 = 617 \cdot 2 + 0$$

$$617 = 308 \cdot 2 + 1$$

$$308 = 154 \cdot 2 + 0$$

$$154 = 77 \cdot 2 + 0$$

$$77 = 38 \cdot 2 + 1$$

$$38 = 19 \cdot 2 + 0$$

$$19 = 9 \cdot 2 + 1$$

$$9 = 4 \cdot 2 + 1$$

$$4 = 2 \cdot 2 + 0$$

$$2 = 1 \cdot 2 + 0$$

$$1 = 0 \cdot 2 + 1$$

Leggendo i resti dal basso verso l'alto otteniamo:

$$10011010010$$

Pertanto:

$$(1234)_{10} = (10011010010)_2$$

## 1.2 Conversione della parte frazionaria

Per convertire la parte frazionaria si procede moltiplicando successivamente per  $M$ .

Sia

$$x_{\text{fraz}} \in [0, 1).$$

Si calcola:

$$Mx_{\text{fraz}} = y_{-1} + r_1, \quad 0 \leq r_1 < 1,$$

dove  $y_{-1}$  è la parte intera del risultato.

Si ripete poi il procedimento:

$$Mr_1 = y_{-2} + r_2,$$

$$Mr_2 = y_{-3} + r_3,$$

e così via.

In generale:

$$Mr_k = y_{-(k+1)} + r_{k+1}, \quad 0 \leq r_{k+1} < 1.$$

Se per qualche  $k$  si ottiene

$$r_k = 0,$$

il procedimento termina e la rappresentazione frazionaria è finita.

Le cifre ottenute, questa volta, si leggono dall'alto verso il basso:

$$(x_{\text{fraz}})_M = (0.y_{-1}y_{-2}y_{-3} \dots)_M.$$

### Esempio 3: Conversione di una frazione decimale in binario

Convertiamo

$$(0.0625)_{10}$$

in base 2.

Moltiplichiamo successivamente per 2:

|                          |                 |
|--------------------------|-----------------|
| $0.0625 \cdot 2 = 0.125$ | $\rightarrow 0$ |
| $0.1250 \cdot 2 = 0.250$ | $\rightarrow 0$ |
| $0.2500 \cdot 2 = 0.500$ | $\rightarrow 0$ |
| $0.5000 \cdot 2 = 1.000$ | $\rightarrow 1$ |

La parte frazionaria successiva è 0, quindi il procedimento termina.  
Pertanto:

$$(0.0625)_{10} = (0.0001)_2$$

### Esempio 4: Un numero frazionario periodico

Consideriamo il numero

$$(0.1)_{10}.$$

Procedendo come sopra:

|                     |                 |
|---------------------|-----------------|
| $0.1 \cdot 2 = 0.2$ | $\rightarrow 0$ |
| $0.2 \cdot 2 = 0.4$ | $\rightarrow 0$ |
| $0.4 \cdot 2 = 0.8$ | $\rightarrow 0$ |
| $0.8 \cdot 2 = 1.6$ | $\rightarrow 1$ |
| $0.6 \cdot 2 = 1.2$ | $\rightarrow 1$ |
| $0.2 \cdot 2 = 0.4$ | $\rightarrow 0$ |

e da questo punto la sequenza si ripete.  
Quindi:

$$(0.1)_{10} = (0.0001100110011 \dots)_2$$

Il numero ha quindi una rappresentazione binaria infinita e periodica.

**OSSERVAZIONE:** Un calcolatore binario non può rappresentare esattamente, in generale, un numero come 0.1 utilizzando un numero finito di bit.

## 2 Numeri macchina

### 2.1 Interi macchina

I tipi interi macchina più comuni utilizzano 32 o 64 bit, ad esempio `int32` e `int64`.

**NOTA:** Gli interi macchina a 32 o 64 bit non fanno parte dello standard IEEE 754, che riguarda invece la rappresentazione dei numeri in virgola mobile.

Se il primo bit è riservato al segno:

$$0 \longrightarrow + \quad 1 \longrightarrow -$$

Con  $n$  bit e rappresentazione segno-modulo, il massimo intero positivo rappresentabile è:

$$I_{\max,n} = (011 \dots 1)_2 = \sum_{i=0}^{n-2} 2^i = 2^{n-1} - 1$$

Per una rappresentazione senza segno, invece:

$$I_{\max,n} = (111 \dots 1)_2 = \sum_{i=0}^{n-1} 2^i = 2^n - 1$$

### 2.1.1 Overflow

Si verifica un overflow quando il risultato di un'operazione non è rappresentabile con il numero di bit disponibili.

#### Esempio 5: Overflow con interi macchina

Consideriamo interi macchina a 4 bit in rappresentazione segno-modulo.  
Calcoliamo:

$$7 + 2$$

Abbiamo:

$$7 = (0111)_2 \quad 2 = (0010)_2$$

La somma produce:

$$\begin{array}{r} 0111 \\ 0010 \\ \hline 1001 \end{array}$$

Il risultato ottenuto è:

$$(1001)_2 = -1$$

nella rappresentazione segno-modulo.

Quindi la macchina produce:

$$\boxed{7 + 2 = -1}$$

anziché 9.

Questo fenomeno prende il nome di overflow.

## 2.2 Floating point e standard IEEE 754

Usando la notazione binaria, un numero reale  $x \neq 0$  può essere scritto, in forma normalizzata, come:

$$(x)_2 = (-1)^s \cdot 2^{e-b} \cdot (1.f)$$

dove:

- $s$  è il bit di segno;
- $e$  è l'esponente memorizzato;
- $b$  è il bias, cioè la deviazione utilizzata per memorizzare anche esponenti negativi;
- $e - b$  è l'esponente effettivo;
- $1.f$  è la significanda (spesso chiamata informalmente mantissa).

Per un numero normalizzato, il bit iniziale 1 è sempre presente e quindi non è necessario memorizzarlo esplicitamente: si parla di hidden bit.

Il valore 0 richiede invece una convenzione particolare.

## 2.3 Tabella riassuntiva IEEE 754

|                             | 32 bit         | 64 bit         |
|-----------------------------|----------------|----------------|
| Bit totali                  | 32             | 64             |
| Bit segno                   | 1              | 1              |
| Bit esponente               | 8              | 11             |
| Bit frazione                | 23             | 52             |
| Bias $b$                    | 127            | 1023           |
| Intervallo $e$ normalizzato | $0 < e < 255$  | $0 < e < 2047$ |
| $e = 0, f = 0$              | $\pm 0$        | $\pm 0$        |
| $e = 0, f > 0$              | denormalizzato | denormalizzato |
| $e = 255, f = 0$            | $\pm \infty$   | $\pm \infty$   |
| $e = 255, f > 0$            | NaN            | NaN            |

## 2.4 Arrotondamento e troncamento

Quando il numero possiede più cifre di quante ne possano essere memorizzate, è necessario decidere cosa fare delle cifre in eccesso.

### Definizione 2: Troncamento

Con il troncamento, le cifre oltre la precisione disponibile vengono semplicemente eliminate.

### Definizione 3: Arrotondamento

Con l'arrotondamento, si considera la prima cifra che non può essere memorizzata e si modifica l'ultima cifra memorizzabile in funzione del suo valore.

Nel caso binario:

- se la cifra successiva è 1, si aumenta di 1 l'ultima cifra memorizzata;
- se la cifra successiva è 0, l'ultima cifra non viene modificata.

### 3 Errore e norme

#### Definizione 4: Approssimazione

Supponiamo di voler rappresentare o calcolare un valore  $x \in \mathbb{R}$  (o  $\in \mathbb{R}^m$ ), ma invece calcolo o ottengo un'approssimazione:

$$\tilde{x} \approx x$$

#### 3.1 Errore assoluto e relativo

Se  $x \in \mathbb{R}$ , definiamo l'errore assoluto come:

$$|\tilde{x} - x|$$

Se, invece,  $x \in \mathbb{R}^n$ , per rappresentare l'errore assoluto, si utilizza:

$$\|\tilde{x} - x\|$$

Dove  $\|\cdot\|$  è una norma su  $\mathbb{R}^m$ .

#### Definizione 5: Norma

Sia  $V$  uno spazio vettoriale e sia:

$$\|\cdot\| : V \longrightarrow \mathbb{R}_{\geq 0}$$

La funzione  $\|\cdot\|$  è una norma se soddisfa, per ogni  $u, v \in V$  e per ogni  $\lambda \in \mathbb{R}$ :

1. **omogeneità:**  $\|\lambda v\| = |\lambda| \|v\|$
2. **definitezza:**  $\|v\| = 0 \implies v = 0_V$
3. **disuguaglianza triangolare:**  $\|u + v\| \leq \|u\| + \|v\|$

#### 3.2 Norma euclidea

Per

$$v = (v_1, \dots, v_n)^T \in \mathbb{R}^n$$

la norma euclidea è definita da:

$$\|v\| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2} = \left( \sum_{d=1}^n v_d^2 \right)^{1/2}$$

#### 3.3 Norma $p$

Per  $p \geq 1$  si definisce la norma  $p$  come:

$$\|v\|_p = \left( \sum_{d=1}^n |v_d|^p \right)^{1/p}$$

### 3.4 Norma infinito

#### Definizione 6: Norma infinito

La norma infinito è definita come:

$$\|v\|_{\infty} := \max_i |v_i|$$

### 3.5 Equivalenza delle norme

Sia  $\{v_k\}$  una successione in  $\mathbb{R}^n$  e siano  $\|\cdot\|_a, \|\cdot\|_b$  due norme.

In  $\mathbb{R}^n$  tutte le norme sono equivalenti. In particolare:

$$\begin{aligned} v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_a & \quad \left( \text{ossia } \lim_{k \rightarrow +\infty} \|v_k - v\|_a = 0 \right) \\ \Updownarrow \\ v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_b & \quad \left( \text{ossia } \lim_{k \rightarrow +\infty} \|v_k - v\|_b = 0 \right) \end{aligned}$$

### 3.6 Errore relativo

Per  $v \in \mathbb{R}^m$  e  $\tilde{v}$  appross. di  $v$  definiamo l'errore relativo rispetto alla norma  $\|\cdot\|$  su  $\mathbb{R}^m$  come:

$$\text{Err}_{\text{rel}}(\tilde{v}, \|\cdot\|) = \frac{\|\tilde{v} - v\|}{\|v\|}$$

### 3.7 Floating point: successivo e precedente

Poiché  $\mathbb{F}_{32}$  e  $\mathbb{F}_{64}$  sono insiemi finiti e ordinati, possiamo definire:

#### Definizione 7: Successivo e precedente

Il successivo di  $x$ :

$$\text{succ}(x) = \min\{y \in \mathbb{F} : y > x\} \quad \forall x \in \mathbb{F} \setminus \{\max \mathbb{F}\}$$

Il precedente di  $x$ :

$$\text{prec}(x) = \max\{y \in \mathbb{F} : y < x\} \quad \forall x \in \mathbb{F} \setminus \{\min \mathbb{F}\}$$

Quanto vale  $\text{succ}(x) - x$ ?

Pongo

$$\begin{aligned} x &= (-1)^s \cdot 2^{e-b} \cdot 1.f \\ \text{succ}(x) &= \begin{cases} (-1)^s \cdot 2^{e-b} \cdot 1.f + (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00 \dots 0}^{m-1} 1 & , s = 0 \\ x - (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00 \dots 0}^{m-1} 1 & , s = 1 \end{cases} \end{aligned}$$

Dato che  $f$  contiene  $n$  bit, allora la distanza tra due numeri floating point consecutivi, nello stesso intervallo di esponente, è:

$$\text{succ}(x) - x = 2^{e-b-n}$$

### 3.8 Errore di rappresentazione

$$|x - \text{fl}^T(x)| \leq \begin{cases} \text{succ}(\tilde{x}) - \tilde{x} & x > 0 \\ \tilde{x} - \text{succ}(\tilde{x}) & x < 0 \end{cases} = |\text{succ}(\tilde{x}) - \tilde{x}| = 2^{e-b-n}$$

#### 3.8.1 Errore dovuto al troncamento

$$\begin{aligned} \frac{|x - \text{fl}^T(x)|}{|x|} &\leq \frac{|x - \text{fl}^T(x)|}{|\text{fl}^T(x)|} \leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.f} \\ &\leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.0} = \boxed{2^{-n}} \end{aligned}$$

Pertanto:

$$\boxed{\frac{|x - \text{fl}^T(x)|}{|x|} \leq 2^{-n}}$$

#### 3.8.2 Errore dovuto all'arrotondamento

L'arrotondamento fa meglio perchè:

$$|x - \text{fl}^A(x)| \leq \frac{1}{2} |\text{succ}(\tilde{x}) - \tilde{x}| = \frac{1}{2} \cdot 2^{e-b-n} = 2^{e-b-n-1}$$

Dividendo per  $|x| \geq 2^{e-b}$  otteniamo:

$$\left| \frac{x - \text{fl}^A(x)}{x} \right| \leq \frac{2^{e-b-n-1}}{2^{e-b}} = 2^{-n-1}$$

Pertanto:

$$\boxed{\frac{|x - \text{fl}^A(x)|}{|x|} \leq 2^{-n-1}}$$

## 4 Precisione di macchina

### Definizione 8: Precisione macchina

Definiamo la precisione di macchina come il più piccolo numero positivo  $\epsilon$  tale che, se sommato a 1 in virgola mobile, da un risultato diverso da 1.

$$\epsilon_{\text{mach}} := \min \{ \epsilon > 0 : \text{fl}(1 + \epsilon) > 1 \}$$

### 4.1 Operazioni macchina

Siano definite le operazioni esatte:

$$\begin{aligned} \Delta : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{R}, & (+, \cdot) \\ \mathbb{R} \times (\mathbb{R} \setminus \{0\}) &\longrightarrow \mathbb{R}, & (:) \end{aligned}$$

Operazione macchina associata  $\oplus$ :

$$\begin{aligned} \oplus : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{F} \\ (x, y) &\longrightarrow \oplus(x, y) = \text{fl}(\text{fl}(x) \Delta \cdot \text{fl}(y)) \end{aligned}$$

## 4.2 Errore relativo della moltiplicazione

$$\text{Err}_{\text{rel}}(x \odot y) = \frac{|x \odot y - xy|}{|xy|} = \frac{|\text{fl}(\text{fl}(x) \text{fl}(y)) - xy|}{|xy|}$$

**N.B.:** noi supponiamo che

$$\frac{|x \cdot y - \text{fl}(x \cdot y)|}{|x \cdot y|} \leq \epsilon_{\text{mach}} \begin{cases} 2^{-n} \\ 2^{-n-1} \end{cases}$$

$$z = x \cdot y$$

$$\begin{aligned} \text{Err}_{\text{rel}}(x \odot y) &= \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x \cdot y) + \text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \\ &\leq \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x \cdot y)|}{|x \cdot y|} + \overbrace{\frac{|\text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|}}^{\epsilon_{\text{mach}}} \\ &= \frac{\overbrace{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x) \cdot \text{fl}(y)|}^1 + \overbrace{|\text{fl}(x) \cdot \text{fl}(y) - \text{fl}(x \cdot y)|}^2}{|x \cdot y|} + \epsilon_{\text{mach}} \\ &\leq \overbrace{1}^1 \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x) \cdot \text{fl}(y)|}{|\text{fl}(x) \cdot \text{fl}(y)|} \cdot \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \\ &\leq \epsilon_{\text{mach}} \cdot \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \\ &\leq \overbrace{2}^2 \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y + x \cdot y - \text{fl}(x \cdot y)|}{|x \cdot y|} \\ &\leq \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} + \frac{|\text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \leq \epsilon_{\text{mach}} \\ &\leq \epsilon_{\text{mach}} + \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} \\ \textcolor{red}{1} + \textcolor{blue}{2} &\leq \epsilon_{\text{mach}} \left( 1 + \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \right) + \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} \\ &\leq \epsilon_{\text{mach}} \left( 1 + \underbrace{\epsilon_{\text{mach}}(\dots\dots\dots)}_{\text{dipende da } x, y} \right) \end{aligned}$$

Al primo ordine, il comportamento dell'errore relativo non dipende dai valori specifici di  $x$  e  $y$ .

L'errore relativo della moltiplicazione macchina  $u$ :  $\epsilon + M\epsilon$ .

La moltiplicazione è quindi considerata **stabile**, ossia l'errore relativo in output è controllato da quello in input.

## 4.3 Errore relativo della somma

L'errore relativo della somma macchina è:

$$\text{Err}_{\text{rel}}(x \oplus y) = \frac{|\text{fl}(\text{fl}(x) + \text{fl}(y)) - (x + y)|}{|x + y|} = \frac{|x \oplus y - (x + y)|}{|x + y|}$$

Se  $x$  e  $y$  hanno segno opposto e sono molto vicini tra loro, può verificarsi una forte cancellazione numerica, ossia la perdita di cifre significative.

### Esempio 6: Cancellazione Numerica

Ipotesi in cui  $x$  e  $y$  si annullano fra loro lasciando solo un  $\epsilon_{\text{mach}}$ :

$$y = -x + \epsilon_{\text{mach}}$$

Svolgimento:

$$\begin{aligned}\text{Err}_{\text{rel}}(x \oplus y) &\leq \epsilon_{\text{mach}} \left( 1 + \frac{|x| + |y|}{|x + y|} + \epsilon_{\text{mach}} \frac{|x| + |y|}{|x + y|} \right) \\ &= \epsilon_{\text{mach}} \left( 1 + \frac{2|x| + \epsilon_{\text{mach}}}{\epsilon_{\text{mach}}} + 2|x| + \epsilon_{\text{mach}} \right) \\ &= (\epsilon_{\text{mach}} + 2|x| + \epsilon_{\text{mach}} + 2|x|\epsilon_{\text{mach}} + \epsilon_{\text{mach}}^2) \\ &= 2(|x| + \epsilon_{\text{mach}}) + \dots\end{aligned}$$

I ... assorbono  $\epsilon_{\text{mach}}^2$  e  $2|x|\epsilon_{\text{mach}}$  che sono numeri talmente piccoli rispetto agli altri da essere irrilevanti. Significa che se  $x$  è grande, anche l'errore relativo è enorme.

#### Definizione 9: Algoritmo Stabile

Un algoritmo si dice **stabile** se non amplifica in modo incontrollato gli errori presenti sui parametri di input e i dati. In generale, si dice **stabile** un algoritmo per cui vale:

$$\text{Err}^{\text{rel}}(\text{output}) \leq C_{\text{stab}} \text{Err}^{\text{rel}}(\text{input})$$

Dove  $C_{\text{stab}}$  è la costante di stabilità.