

Calcolo Numerico

Marco Pittarello

Contents

1	Sistemi non decimali	2
1.1	Conversione della parte intera	2
1.2	Conversione della parte frazionaria	3
2	Numeri macchina	4
2.1	Interi macchina	4
2.1.1	Overflow	5
2.2	Floating point e standard IEEE 754	5
2.3	Tabella riassuntiva IEEE 754	6
2.4	Arrotondamento e troncamento	6
3	Errore e norme	7
3.1	Errore assoluto e relativo	7
3.2	Norma euclidea	7
3.3	Norma p	7
3.4	Norma infinito	8
3.5	Equivalenza delle norme	8
3.6	Errore relativo	8
3.7	Floating point: successivo e precedente	8
3.8	Errore di rappresentazione	9
3.8.1	Errore dovuto al troncamento	9
3.8.2	Errore dovuto all'arrotondamento	9
4	Precisione di macchina	9
4.1	Operazioni macchina	9
4.2	Errore relativo della moltiplicazione	10
4.3	Errore relativo della somma	10

1 Sistemi non decimali

Definizione 1: Conversione da base N a base M

Dato $x > 0$ e nota la rappresentazione $(x)_N$, vogliamo trovare la rappresentazione $(x)_M$.
Scriviamo:

$$\begin{aligned}x &= x_n N^n + x_{n-1} N^{n-1} + \dots + x_0 + x_{-1} N^{-1} + \dots + x_{-r} N^{-r} \\ &= y_m M^m + y_{m-1} M^{m-1} + \dots + y_0 + y_{-1} M^{-1} + \dots + y_{-q} M^{-q}.\end{aligned}$$

Si procede separatamente per la parte intera e per la parte frazionaria.

1.1 Conversione della parte intera

Per convertire la parte intera si itera lo schema della divisione intera per M :

$$\begin{aligned}y_0 &:= x \bmod M, & x &= q_0 M + y_0, \\ y_1 &:= q_0 \bmod M, & q_0 &= q_1 M + y_1, \\ &\vdots & & \\ y_m &:= q_{m-1} \bmod M, & q_{m-1} &= y_m < M.\end{aligned}$$

OSSERVAZIONE: $x \bmod M$ indica il resto della divisione intera di x per M .

I resti ottenuti sono le cifre della rappresentazione in base M , lette dal basso verso l'alto. Pertanto:

$$(x_{\text{int}})_M = y_m y_{m-1} \dots y_1 y_0.$$

Esempio 1: Conversione da base 2 a base 10

Convertiamo

$$(10011010010)_2$$

in base 10.

Si ha:

$$\begin{aligned}(10011010010)_2 &= 1 \cdot 2^{10} + 0 \cdot 2^9 + 0 \cdot 2^8 + 1 \cdot 2^7 + 1 \cdot 2^6 \\ &\quad + 0 \cdot 2^5 + 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 \\ &= 2^{10} + 2^7 + 2^6 + 2^4 + 2^1 \\ &= 1024 + 128 + 64 + 16 + 2 \\ &= 1234.\end{aligned}$$

Quindi:

$$(10011010010)_2 = (1234)_{10}.$$

Esempio 2: Conversione da base 10 a base 2

Convertiamo

$$(1234)_{10}$$

in base 2 utilizzando divisioni successive per 2:

$$1234 = 617 \cdot 2 + 0,$$

$$617 = 308 \cdot 2 + 1,$$

$$308 = 154 \cdot 2 + 0,$$

$$154 = 77 \cdot 2 + 0,$$

$$77 = 38 \cdot 2 + 1,$$

$$38 = 19 \cdot 2 + 0,$$

$$19 = 9 \cdot 2 + 1,$$

$$9 = 4 \cdot 2 + 1,$$

$$4 = 2 \cdot 2 + 0,$$

$$2 = 1 \cdot 2 + 0,$$

$$1 = 0 \cdot 2 + 1.$$

Leggendo i resti dal basso verso l'alto otteniamo:

$$10011010010.$$

Pertanto:

$$(1234)_{10} = (10011010010)_2.$$

1.2 Conversione della parte frazionaria

Per convertire la parte frazionaria si procede moltiplicando successivamente per M .

Sia

$$x_{\text{fraz}} \in [0, 1).$$

Si calcola:

$$Mx_{\text{fraz}} = y_{-1} + r_1, \quad 0 \leq r_1 < 1,$$

dove y_{-1} è la parte intera del risultato.

Si ripete poi il procedimento:

$$Mr_1 = y_{-2} + r_2,$$

$$Mr_2 = y_{-3} + r_3,$$

e così via.

In generale:

$$Mr_k = y_{-(k+1)} + r_{k+1}, \quad 0 \leq r_{k+1} < 1.$$

Se per qualche k si ottiene

$$r_k = 0,$$

il procedimento termina e la rappresentazione frazionaria è finita.

Le cifre ottenute, questa volta, si leggono dall'alto verso il basso:

$$(x_{\text{fraz}})_M = (0.y_{-1}y_{-2}y_{-3} \dots)_M.$$

Esempio 3: Conversione di una frazione decimale in binario

Convertiamo

$$(0.0625)_{10}$$

in base 2.

Moltiplichiamo successivamente per 2:

$$\begin{array}{ll} 0.0625 \cdot 2 = 0.125 & \longrightarrow 0, \\ 0.1250 \cdot 2 = 0.250 & \longrightarrow 0, \\ 0.2500 \cdot 2 = 0.500 & \longrightarrow 0, \\ 0.5000 \cdot 2 = 1.000 & \longrightarrow 1. \end{array}$$

La parte frazionaria successiva è 0, quindi il procedimento termina.
Pertanto:

$$(0.0625)_{10} = (0.0001)_2.$$

Esempio 4: Un numero frazionario periodico

Consideriamo il numero

$$(0.1)_{10}.$$

Procedendo come sopra:

$$\begin{array}{ll} 0.1 \cdot 2 = 0.2 & \longrightarrow 0, \\ 0.2 \cdot 2 = 0.4 & \longrightarrow 0, \\ 0.4 \cdot 2 = 0.8 & \longrightarrow 0, \\ 0.8 \cdot 2 = 1.6 & \longrightarrow 1, \\ 0.6 \cdot 2 = 1.2 & \longrightarrow 1, \\ 0.2 \cdot 2 = 0.4 & \longrightarrow 0, \end{array}$$

e da questo punto la sequenza si ripete.
Quindi:

$$(0.1)_{10} = (0.0001100110011\dots)_2.$$

Il numero ha quindi una rappresentazione binaria infinita e periodica.

OSSERVAZIONE: Un calcolatore binario non può rappresentare esattamente, in generale, un numero come 0.1 utilizzando un numero finito di bit.

2 Numeri macchina

2.1 Interi macchina

I tipi interi macchina più comuni utilizzano 32 o 64 bit, ad esempio `int32` e `int64`.

NOTA: Gli interi macchina a 32 o 64 bit non fanno parte dello standard IEEE 754, che riguarda invece la rappresentazione dei numeri in virgola mobile.

Se il primo bit è riservato al segno:

$$0 \longrightarrow +, \quad 1 \longrightarrow -.$$

Con n bit e rappresentazione segno-modulo, il massimo intero positivo rappresentabile è:

$$I_{\max,n} = (011 \dots 1)_2 = \sum_{i=0}^{n-2} 2^i = 2^{n-1} - 1.$$

Per una rappresentazione senza segno, invece:

$$I_{\max,n} = (111 \dots 1)_2 = \sum_{i=0}^{n-1} 2^i = 2^n - 1.$$

2.1.1 Overflow

Si verifica un overflow quando il risultato di un'operazione non è rappresentabile con il numero di bit disponibili.

Esempio 5: Overflow con interi macchina

Consideriamo interi macchina a 4 bit in rappresentazione segno-modulo.
Calcoliamo:

$$7 + 2.$$

Abbiamo:

$$7 = (0111)_2, \quad 2 = (0010)_2.$$

La somma produce:

$$\begin{array}{r} 0111 \\ 0010 \\ \hline 1001 \end{array}$$

Il risultato ottenuto è:

$$(1001)_2 = -1$$

nella rappresentazione segno-modulo.
Quindi la macchina produce:

$$7 + 2 = -1$$

anziché 9.

Questo fenomeno prende il nome di overflow.

2.2 Floating point e standard IEEE 754

Usando la notazione binaria, un numero reale $x \neq 0$ può essere scritto, in forma normalizzata, come:

$$(x)_2 = (-1)^s \cdot 2^{e-b} \cdot (1.f),$$

dove:

- s è il bit di segno;
- e è l'esponente memorizzato;
- b è il bias, cioè la deviazione utilizzata per memorizzare anche esponenti negativi;
- $e - b$ è l'esponente effettivo;
- $1.f$ è la significanda (spesso chiamata informalmente mantissa).

Per un numero normalizzato, il bit iniziale 1 è sempre presente e quindi non è necessario memorizzarlo esplicitamente: si parla di hidden bit.

Il valore 0 richiede invece una convenzione particolare.

2.3 Tabella riassuntiva IEEE 754

	32 bit	64 bit
Bit totali	32	64
Bit segno	1	1
Bit esponente	8	11
Bit frazione	23	52
Bias b	127	1023
Intervallo e normalizzato	$0 < e < 255$	$0 < e < 2047$
$e = 0, f = 0$	± 0	± 0
$e = 0, f > 0$	denormalizzato	denormalizzato
$e = 255, f = 0$	$\pm \infty$	$\pm \infty$
$e = 255, f > 0$	NaN	NaN

2.4 Arrotondamento e troncamento

Quando il numero possiede più cifre di quante ne possano essere memorizzate, è necessario decidere cosa fare delle cifre in eccesso.

Definizione 2: Troncamento

Con il troncamento, le cifre oltre la precisione disponibile vengono semplicemente eliminate.

Definizione 3: Arrotondamento

Con l'arrotondamento, si considera la prima cifra che non può essere memorizzata e si modifica l'ultima cifra memorizzabile in funzione del suo valore.

Nel caso binario:

- se la cifra successiva è 1, si aumenta di 1 l'ultima cifra memorizzata;
- se la cifra successiva è 0, l'ultima cifra non viene modificata.

3 Errore e norme

Definizione 4: Approssimazione

Supponiamo di voler rappresentare o calcolare un valore $x \in \mathbb{R}$ (o $\in \mathbb{R}^m$), ma invece calcolo o ottengo un'approssimazione:

$$\tilde{x} \approx x.$$

3.1 Errore assoluto e relativo

Se $x \in \mathbb{R}$, definiamo l'errore assoluto come:

$$|\tilde{x} - x|.$$

Se, invece, $x \in \mathbb{R}^n$, per rappresentare l'errore assoluto, si utilizza:

$$\|\tilde{x} - x\|.$$

Dove $\|\cdot\|$ è una norma su $\mathbb{R}^m$.

Definizione 5: Norma

Sia V uno spazio vettoriale e sia:

$$\|\cdot\| : V \longrightarrow \mathbb{R}_{\geq 0}.$$

La funzione $\|\cdot\|$ è una norma se soddisfa, per ogni $u, v \in V$ e per ogni $\lambda \in \mathbb{R}$:

1. **omogeneità:** $\|\lambda v\| = |\lambda| \|v\|$
2. **definitezza:** $\|v\| = 0 \implies v = 0_V$
3. **disuguaglianza triangolare:** $\|u + v\| \leq \|u\| + \|v\|$

3.2 Norma euclidea

Per

$$v = (v_1, \dots, v_n)^T \in \mathbb{R}^n$$

la norma euclidea è definita da:

$$\|v\| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2} = \left(\sum_{d=1}^n v_d^2 \right)^{1/2}$$

3.3 Norma p

Per $p \geq 1$ si definisce la norma p come:

$$\|v\|_p = \left(\sum_{d=1}^n |v_d|^p \right)^{1/p}.$$

3.4 Norma infinito

Definizione 6: Norma infinito

La norma infinito è definita come:

$$\|v\|_{\infty} := \max_i |v_i|$$

3.5 Equivalenza delle norme

Sia $\{v_k\}$ una successione in $\mathbb{R}^n$ e siano $\|\cdot\|_a, \|\cdot\|_b$ due norme.

In $\mathbb{R}^n$ tutte le norme sono equivalenti. In particolare:

$$\begin{aligned} v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_a & \quad \left(\text{ossia } \lim_{k \rightarrow +\infty} \|v_k - v\|_a = 0 \right) \\ \Updownarrow \\ v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_b & \quad \left(\text{ossia } \lim_{k \rightarrow +\infty} \|v_k - v\|_b = 0 \right) \end{aligned}$$

3.6 Errore relativo

Per $v \in \mathbb{R}^m$ e $\tilde{v}$ appross. di v definiamo l'errore relativo rispetto alla norma $\|\cdot\|$ su $\mathbb{R}^m$ come:

$$\text{Err}_{\text{rel}}(\tilde{v}, \|\cdot\|) = \frac{\|\tilde{v} - v\|}{\|v\|}.$$

3.7 Floating point: successivo e precedente

Poiché $\mathbb{F}_{32}$ e $\mathbb{F}_{64}$ sono insiemi finiti e ordinati, possiamo definire:

Definizione 7: Successivo e precedente

Il successivo di x :

$$\text{succ}(x) = \min\{y \in \mathbb{F} : y > x\} \quad \forall x \in \mathbb{F} \setminus \{\max \mathbb{F}\}$$

Il precedente di x :

$$\text{prec}(x) = \max\{y \in \mathbb{F} : y < x\} \quad \forall x \in \mathbb{F} \setminus \{\min \mathbb{F}\}$$

Quanto vale $\text{succ}(x) - x$?

Pongo

$$\begin{aligned} x &= (-1)^s \cdot 2^{e-b} \cdot 1.f \\ \text{succ}(x) &= \begin{cases} (-1)^s \cdot 2^{e-b} \cdot 1.f + (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00 \dots 0}^{m-1} 1 & , s = 0 \\ x - (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00 \dots 0}^{m-1} 1 & , s = 1 \end{cases} \end{aligned}$$

Dato che f contiene n bit, allora la distanza tra due numeri floating point consecutivi, nello stesso intervallo di esponente, è:

$$\text{succ}(x) - x = 2^{e-b-n}.$$

3.8 Errore di rappresentazione

$$|x - \text{fl}^T(x)| \leq \begin{cases} \text{succ}(\tilde{x}) - \tilde{x} & x > 0 \\ \tilde{x} - \text{succ}(\tilde{x}) & x < 0 \end{cases} = |\text{succ}(\tilde{x}) - \tilde{x}| = 2^{e-b-n}$$

3.8.1 Errore dovuto al troncamento

$$\begin{aligned} \frac{|x - \text{fl}^T(x)|}{|x|} &\leq \frac{|x - \text{fl}^T(x)|}{|\text{fl}^T(x)|} \leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.f} \\ &\leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.0} = \boxed{2^{-n}} \end{aligned}$$

Pertanto:

$$\boxed{\frac{|x - \text{fl}^T(x)|}{|x|} \leq 2^{-n}}$$

3.8.2 Errore dovuto all'arrotondamento

L'arrotondamento fa meglio perchè:

$$|x - \text{fl}^A(x)| \leq \frac{1}{2} |\text{succ}(\tilde{x}) - \tilde{x}| = \frac{1}{2} \cdot 2^{e-b-n} = 2^{e-b-n-1}$$

Dividendo per $|x| \geq 2^{e-b}$ otteniamo:

$$\left| \frac{x - \text{fl}^A(x)}{x} \right| \leq \frac{2^{e-b-n-1}}{2^{e-b}} = 2^{-n-1}$$

Pertanto:

$$\boxed{\frac{|x - \text{fl}^A(x)|}{|x|} \leq 2^{-n-1}}$$

4 Precisione di macchina

Definizione 8: Precisione macchina

Definiamo la precisione di macchina come il più piccolo numero positivo ϵ tale che, se sommato a 1 in virgola mobile, dà un risultato diverso da 1.

$$\epsilon_{\text{mach}} := \min \{ \epsilon > 0 : \text{fl}(1 + \epsilon) > 1 \}$$

4.1 Operazioni macchina

Siano definite le operazioni esatte:

$$\begin{aligned} \Delta : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{R}, & (+, \cdot) \\ \mathbb{R} \times (\mathbb{R} \setminus \{0\}) &\longrightarrow \mathbb{R}, & (:) \end{aligned}$$

Operazione macchina associata $\oplus$:

$$\begin{aligned} \oplus : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{F} \\ (x, y) &\longrightarrow \oplus(x, y) = \text{fl}(\text{fl}(x) \Delta \cdot \text{fl}(y)) \end{aligned}$$

4.2 Errore relativo della moltiplicazione

$$\text{Err}_{\text{rel}}(x \odot y) = \frac{|x \odot y - xy|}{|xy|} = \frac{|\text{fl}(\text{fl}(x) \text{fl}(y)) - xy|}{|xy|}$$

N.B.: noi supponiamo che

$$\frac{|x \cdot y - \text{fl}(x \cdot y)|}{|x \cdot y|} \leq \epsilon_{\text{mach}} \begin{cases} 2^{-n} \\ 2^{-n-1} \end{cases}$$

$$z = x \cdot y$$

$$\begin{aligned} \text{Err}_{\text{rel}}(x \odot y) &= \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x \cdot y) + \text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \\ &\leq \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x \cdot y)|}{|x \cdot y|} + \overbrace{\frac{|\text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|}}^{\epsilon_{\text{mach}}} \\ &= \overbrace{\frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|}}^{\text{1}} + \overbrace{\frac{|\text{fl}(x) \cdot \text{fl}(y) - \text{fl}(x \cdot y)|}{|x \cdot y|}}^{\text{2}} + \epsilon_{\text{mach}} \\ &\leq \text{1} \frac{|\text{fl}(\text{fl}(x) \cdot \text{fl}(y)) - \text{fl}(x) \cdot \text{fl}(y)|}{|\text{fl}(x) \cdot \text{fl}(y)|} \cdot \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \\ &\leq \epsilon_{\text{mach}} \cdot \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \\ &\leq \text{2} \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y + x \cdot y - \text{fl}(x \cdot y)|}{|x \cdot y|} \\ &\leq \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} + \frac{|\text{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \leq \epsilon_{\text{mach}} \\ &\leq \epsilon_{\text{mach}} + \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} \\ \text{1} + \text{2} &\leq \epsilon_{\text{mach}} \left(1 + \frac{|\text{fl}(x) \cdot \text{fl}(y)|}{|x \cdot y|} \right) + \frac{|\text{fl}(x) \cdot \text{fl}(y) - x \cdot y|}{|x \cdot y|} \\ &\leq \epsilon_{\text{mach}} \left(1 + \epsilon_{\text{mach}} \left(\underbrace{\dots\dots\dots}_{\text{dipende da } x, y} \right) \right) \end{aligned}$$

Al primo ordine, il comportamento dell'errore relativo non dipende dai valori specifici di x e y .

L'errore relativo della moltiplicazione macchina u : $\epsilon + M\epsilon$.

La moltiplicazione è quindi considerata stabile, ossia l'errore relativo in output è controllato da quello in input.

4.3 Errore relativo della somma

L'errore relativo della somma macchina è:

$$\text{Err}_{\text{rel}}(x \oplus y) = \frac{|\text{fl}(\text{fl}(x) + \text{fl}(y)) - (x + y)|}{|x + y|} = \frac{|x \oplus y - (x + y)|}{|x + y|}$$

Se x e y hanno segno opposto e sono molto vicini tra loro, può verificarsi una forte cancellazione numerica, ossia la perdita di cifre significative.

In questo caso:

$$|x + y| \ll |x| + |y|,$$

e quindi anche un errore assoluto piccolo può corrispondere a un errore relativo grande.

OSSERVAZIONE: La cancellazione numerica è particolarmente pericolosa quando si misura l'errore relativo rispetto al risultato $x + y$, che può essere molto più piccolo dei termini che lo compongono.