# Calcolo Numerico

Marco Pittarello

## Contents

**1 Sistemi non decimali** **3**
1.1 Conversione della parte intera . . . 3
1.2 Conversione della parte frazionaria . . . 4

**2 Numeri macchina** **5**
2.1 Interi macchina . . . 5
2.1.1 Overflow . . . 6
2.2 Floating point e standard IEEE 754 . . . 6
2.3 Tabella riassuntiva IEEE 754 . . . 7
2.4 Arrotondamento e troncamento . . . 7

**3 Errore e norme** **8**
3.1 Errore assoluto e relativo . . . 8
3.2 Norma euclidea . . . 8
3.3 Norma $p$ . . . 8
3.4 Norma infinito . . . 9
3.5 Equivalenza delle norme . . . 9
3.6 Errore relativo . . . 9
3.7 Floating point: successivo e precedente . . . 9
3.8 Errore di rappresentazione . . . 10
3.8.1 Errore dovuto al troncamento . . . 10
3.8.2 Errore dovuto all'arrotondamento . . . 10

**4 Precisione di macchina** **10**
4.1 Operazioni macchina . . . 10
4.2 Errore relativo della moltiplicazione . . . 11
4.3 Errore relativo della somma . . . 11
4.4 Stabilità degli algoritmi . . . 12
4.5 Condizionamento dei problemi . . . 13
4.5.1 Condizionamento di un problema ben posto . . . 14
4.5.2 Condizionamento locale relativo . . . 14
4.5.3 Condizionamento globale di ordine $\alpha$ . . . 15

**5 Sistemi Lineari** **16**
5.1 Soluzione di Sistemi Quadrati . . . 16
5.2 Norma indotta . . . 17
5.2.1 Teorema Spettrale . . . 20
5.2.2 Decomposizione ai valori singolari (SVD) . . . 21
5.3 Risoluzione pratica $Ax = b$ . . . 22
5.3.1 Caso inferiore . . . 22
5.3.2 Caso superiore . . . 22
5.4 Fattorizzazione . . . 23
5.4.1 Algoritmo Instabile . . . 24
5.5 Fattorizzazione con Pivoting . . . 27
5.5.1 Complessità Fattorizzazione $LU$ . . . 28
5.6 Metodi per sistemi lineari . . . 29
5.6.1 Convergenza metodo di Richardson . . . 31

5.7 Splitting Classico . . . . . 34
5.7.1 Metodo di Jacobi . . . . . 34
5.7.2 Metodo di Gauss-Seidel . . . . . 35
5.7.3 I Teoremi di Gershgorin . . . . . 35
5.8 Prodotto Scalare . . . . . 37
5.8.1 Rapporto tra prodotti e matrici . . . . . 38
5.9 Sistemi Lineari Sovradeterminati . . . . . 39
5.9.1 Soluzione ai minimi quadrati . . . . . 39
5.9.2 Teorema delle Proiezioni Ortogonali . . . . . 40

# 1 Sistemi non decimali

**Definizione 1: Conversione da base $N$ a base $M$**

Dato $x > 0$ e nota la rappresentazione $(x)_N$, vogliamo trovare la rappresentazione $(x)_M$.
Scriviamo:

$$\begin{aligned} x &= x_n N^n + x_{n-1} N^{n-1} + \cdots + x_0 + x_{-1} N^{-1} + \cdots + x_{-r} N^{-r} \\ &= y_m M^m + y_{m-1} M^{m-1} + \cdots + y_0 + y_{-1} M^{-1} + \cdots + y_{-q} M^{-q}. \end{aligned}$$

Si procede separatamente per la parte intera e per la parte frazionaria.

## 1.1 Conversione della parte intera

Per convertire la parte intera si itera lo schema della divisione intera per $M$:

$$\begin{aligned} y_0 &:= x \bmod M & x &= q_0 M + y_0 \\ y_1 &:= q_0 \bmod M & q_0 &= q_1 M + y_1 \\ &\vdots \\ y_m &:= q_{m-1} \bmod M & q_{m-1} &= y_m < M \end{aligned}$$

**OSSERVAZIONE:** $x \bmod M$ indica il resto della divisione intera di $x$ per $M$.

I resti ottenuti sono le cifre della rappresentazione in base $M$, lette dal basso verso l'alto. Pertanto:

$$(x_{\text{int}})_M = y_m y_{m-1} \dots y_1 y_0$$

**Esempio 1: Conversione da base $2$ a base $10$**

Convertiamo

$$(10011010010)_2$$

in base $10$.
Si ha:

$$\begin{aligned} (10011010010)_2 &= 1 \cdot 2^{10} + 0 \cdot 2^9 + 0 \cdot 2^8 + 1 \cdot 2^7 + 1 \cdot 2^6 \\ &\quad + 0 \cdot 2^5 + 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 \\ &= 2^{10} + 2^7 + 2^6 + 2^4 + 2^1 \\ &= 1024 + 128 + 64 + 16 + 2 \\ &= 1234 \end{aligned}$$

Quindi:

$$\boxed{(10011010010)_2 = (1234)_{10}}$$

**Esempio 2: Conversione da base $10$ a base $2$**

Convertiamo

$$(1234)_{10}$$

in base $2$ utilizzando divisioni successive per $2$:

$$\begin{aligned}
1234 &= 617 \cdot 2 + 0 \\
617 &= 308 \cdot 2 + 1 \\
308 &= 154 \cdot 2 + 0 \\
154 &= 77 \cdot 2 + 0 \\
77 &= 38 \cdot 2 + 1 \\
38 &= 19 \cdot 2 + 0 \\
19 &= 9 \cdot 2 + 1 \\
9 &= 4 \cdot 2 + 1 \\
4 &= 2 \cdot 2 + 0 \\
2 &= 1 \cdot 2 + 0 \\
1 &= 0 \cdot 2 + 1
\end{aligned}$$

Leggendo i resti dal basso verso l'alto otteniamo:

$$10011010010$$

Pertanto:

$$\boxed{(1234)_{10} = (10011010010)_2}$$

## 1.2 Conversione della parte frazionaria

Per convertire la parte frazionaria si procede moltiplicando successivamente per $M$.

Sia

$$x_{\text{fraz}} \in [0, 1).$$

Si calcola:

$$Mx_{\text{fraz}} = y_{-1} + r_1, \qquad 0 \leq r_1 < 1,$$

dove $y_{-1}$ è la parte intera del risultato.

Si ripete poi il procedimento:

$$Mr_1 = y_{-2} + r_2,$$

$$Mr_2 = y_{-3} + r_3,$$

e così via.

In generale:

$$Mr_k = y_{-(k+1)} + r_{k+1}, \qquad 0 \leq r_{k+1} < 1.$$

Se per qualche $k$ si ottiene

$$r_k = 0,$$

il procedimento termina e la rappresentazione frazionaria è finita.

Le cifre ottenute, questa volta, si leggono dall'alto verso il basso:

$$(x_{\text{fraz}})_M = (0.y_{-1}y_{-2}y_{-3}\dots)_M.$$

**Esempio 3: Conversione di una frazione decimale in binario**

Convertiamo

$$(0.0625)_{10}$$

in base $2$.
Moltiplichiamo successivamente per $2$:

$$\begin{aligned} 0.0625 \cdot 2 &= 0.125 &&\longrightarrow 0 \\ 0.1250 \cdot 2 &= 0.250 &&\longrightarrow 0 \\ 0.2500 \cdot 2 &= 0.500 &&\longrightarrow 0 \\ 0.5000 \cdot 2 &= 1.000 &&\longrightarrow 1 \end{aligned}$$

La parte frazionaria successiva è $0$, quindi il procedimento termina.
Pertanto:

$$\boxed{(0.0625)_{10} = (0.0001)_2}$$

**Esempio 4: Un numero frazionario periodico**

Consideriamo il numero

$$(0.1)_{10}.$$

Procedendo come sopra:

$$\begin{aligned} 0.1 \cdot 2 &= 0.2 &&\longrightarrow 0 \\ 0.2 \cdot 2 &= 0.4 &&\longrightarrow 0 \\ 0.4 \cdot 2 &= 0.8 &&\longrightarrow 0 \\ 0.8 \cdot 2 &= 1.6 &&\longrightarrow 1 \\ 0.6 \cdot 2 &= 1.2 &&\longrightarrow 1 \\ 0.2 \cdot 2 &= 0.4 &&\longrightarrow 0 \end{aligned}$$

e da questo punto la sequenza si ripete.
Quindi:

$$\boxed{(0.1)_{10} = (0.0001100110011\dots)_2}$$

Il numero ha quindi una rappresentazione binaria infinita e periodica.
**OSSERVAZIONE:** Un calcolatore binario non può rappresentare esattamente, in generale, un numero come $0.1$ utilizzando un numero finito di bit.

# 2 Numeri macchina

## 2.1 Interi macchina

I tipi interi macchina più comuni utilizzano $32$ o $64$ bit, ad esempio `int32` e `int64`.

**NOTA:** Gli interi macchina a $32$ o $64$ bit non fanno parte dello standard IEEE 754, che riguarda invece la rappresentazione dei numeri in virgola mobile.

Se il primo bit è riservato al segno:

$$0 \longrightarrow + \qquad 1 \longrightarrow -$$

Con $n$ bit e rappresentazione segno-modulo, il massimo intero positivo rappresentabile è:

$$I_{\max,n} = (011\ldots1)_2 = \sum_{i=0}^{n-2} 2^i = 2^{n-1} - 1$$

Per una rappresentazione senza segno, invece:

$$I_{\max,n} = (111\ldots1)_2 = \sum_{i=0}^{n-1} 2^i = 2^n - 1$$

### 2.1.1 Overflow

Si verifica un overflow quando il risultato di un'operazione non è rappresentabile con il numero di bit disponibili.

**Esempio 5: Overflow con interi macchina**

Consideriamo interi macchina a $4$ bit in rappresentazione segno-modulo.
Calcoliamo:

$$7 + 2$$

Abbiamo:

$$7 = (0111)_2 \qquad 2 = (0010)_2$$

La somma produce:

$$\begin{array}{r} 0111 \\ 0010 \\ \hline 1001 \end{array}$$

Il risultato ottenuto è:

$$(1001)_2 = -1$$

nella rappresentazione segno-modulo.
Quindi la macchina produce:

$$\boxed{7 + 2 = -1}$$

anziché $9$.
Questo fenomeno prende il nome di overflow.

## 2.2 Floating point e standard IEEE 754

Usando la notazione binaria, un numero reale $x \neq 0$ può essere scritto, in forma normalizzata, come:

$$(x)_2 = (-1)^s \cdot 2^{e-b} \cdot (1.f)$$

dove:

- $s$ è il bit di segno;
- $e$ è l'esponente memorizzato;
- $b$ è il bias, cioè la deviazione utilizzata per memorizzare anche esponenti negativi;
- $e - b$ è l'esponente effettivo;
- $1.f$ è la significanda (spesso chiamata informalmente mantissa).

Per un numero normalizzato, il bit iniziale $1$ è sempre presente e quindi non è necessario memorizzarlo esplicitamente: si parla di hidden bit.

Il valore $0$ richiede invece una convenzione particolare.

## 2.3 Tabella riassuntiva IEEE 754

| | **32 bit** | **64 bit** |
|---|---|---|
| Bit totali | 32 | 64 |
| Bit segno | 1 | 1 |
| Bit esponente | 8 | 11 |
| Bit frazione | 23 | 52 |
| Bias $b$ | 127 | 1023 |
| Intervallo $e$ normalizzato | $0 < e < 255$ | $0 < e < 2047$ |
| $e = 0,\ f = 0$ | $\pm 0$ | $\pm 0$ |
| $e = 0,\ f > 0$ | denormalizzato | denormalizzato |
| $e = 255,\ f = 0$ | $\pm\infty$ | $\pm\infty$ |
| $e = 255,\ f > 0$ | NaN | NaN |

## 2.4 Arrotondamento e troncamento

Quando il numero possiede più cifre di quante ne possano essere memorizzate, è necessario decidere cosa fare delle cifre in eccesso.

**Definizione 2: Troncamento**

Con il troncamento, le cifre oltre la precisione disponibile vengono semplicemente eliminate.

**Definizione 3: Arrotondamento**

Con l'arrotondamento, si considera la prima cifra che non può essere memorizzata e si modifica l'ultima cifra memorizzabile in funzione del suo valore.
Nel caso binario:
- se la cifra successiva è $1$, si aumenta di $1$ l'ultima cifra memorizzata;
- se la cifra successiva è $0$, l'ultima cifra non viene modificata.

# 3 Errore e norme

**Definizione 4: Approssimazione**

Supponiamo di voler rappresentare o calcolare un valore $x \in \mathbb{R}$ (o $\in \mathbb{R}^m$), ma invece calcolo o ottengo un'approssimazione:

$$\widetilde{x} \approx x$$

## 3.1 Errore assoluto e relativo

Se $x \in \mathbb{R}$, definiamo l'errore assoluto come:

$$\boxed{|\widetilde{x} - x|}$$

Se, invece, $x \in \mathbb{R}^n$, per rappresentare l'errore assoluto, si utilizza:

$$\boxed{\|\widetilde{x} - x\|}$$

Dove $\|\cdot\|$ è una norma su $\mathbb{R}^m$.

Se $x \in \mathbb{R} \setminus \{0\}$, allora definisco l'errore relativo come:

$$\boxed{\frac{|\widetilde{x} - x|}{|x|}}$$

**Definizione 5: Norma**

Sia $V$ uno spazio vettoriale e sia:

$$\|\cdot\| : V \longrightarrow \mathbb{R}_{\geq 0}$$

La funzione $\|\cdot\|$ è una norma se soddisfa, per ogni $u, v \in V$ e per ogni $\lambda \in \mathbb{R}$:

1. **omogeneità**: $\|\lambda v\| = |\lambda| \, \|v\|$
2. **definitezza**: $\|v\| = 0 \implies v = 0_V$
3. **disuguaglianza triangolare**: $\|u + v\| \leq \|u\| + \|v\|$

## 3.2 Norma euclidea

Per

$$v = (v_1, \ldots, v_n)^T \in \mathbb{R}^n$$

la norma euclidea è definita da:

$$\boxed{\|v\| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2} = \left( \sum_{d=1}^{n} v_d^2 \right)^{1/2}}$$

## 3.3 Norma $p$

Per $p \geq 1$ si definisce la norma $p$ come:

$$\boxed{\|v\|_p = \left( \sum_{d=1}^{n} |v_d|^p \right)^{1/p}}$$

## 3.4 Norma infinito

**Definizione 6: Norma infinito**

La norma infinito è definita come:

$$\|v\|_\infty := \max_i |v_i|$$

## 3.5 Equivalenza delle norme

Sia $\{v_k\}$ una successione in $\mathbb{R}^n$ e siano $\|\cdot\|_a,\ \|\cdot\|_b$ due norme.

In $\mathbb{R}^n$ tutte le norme sono equivalenti. In particolare:

$$\begin{aligned} &v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_a \quad \left(\text{ossia } \lim_{k\to+\infty} ||v_k - v||_a = 0\right) \\ &\Updownarrow \\ &v_k \longrightarrow v \quad \text{rispetto a } \|\cdot\|_b \quad \left(\text{ossia } \lim_{k\to+\infty} ||v_k - v||_b = 0\right) \end{aligned}$$

## 3.6 Errore relativo

Per $v \in \mathbb{R}^m$ e $\tilde{v}$ appross. di $v$ definiamo l'errore relativo rispetto alla norma $\|\cdot\|$ su $\mathbb{R}^m$ come:

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(\widetilde{v}, \|\cdot\|) = \frac{\|\widetilde{v} - v\|}{\|v\|}}$$

## 3.7 Floating point: successivo e precedente

Poiché $\mathbb{F}_{32}$ e $\mathbb{F}_{64}$ sono insiemi finiti e ordinati, possiamo definire:

**Definizione 7: Successivo e precedente**

Il successivo di $x$:

$$\mathrm{succ}(x) = \min\{y \in \mathbb{F} : y > x\} \quad \forall x \in \mathbb{F} \setminus \{\max \mathbb{F}\}$$

Il precedente di $x$:

$$\mathrm{prec}(x) = \max\{y \in \mathbb{F} : y < x\} \quad \forall x \in \mathbb{F} \setminus \{\min \mathbb{F}\}$$

Quanto vale $\mathrm{succ}(x) - x$?

Pongo

$$x = (-1)^s \cdot 2^{e-b} \cdot 1.f$$

$$\mathrm{succ}(x) = \begin{cases} (-1)^s \cdot 2^{e-b} \cdot 1.f + (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00\ldots0}^{m-1}1 & , s = 0 \\ x - (-1)^s \cdot 2^{e-b} \cdot 0.\overbrace{00\ldots0}^{m-1}1 & , s = 1 \end{cases}$$

Dato che $f$ contiene $n$ bit, allora la distanza tra due numeri floating point consecutivi, nello stesso intervallo di esponente, è:

$$\boxed{\mathrm{succ}(x) - x = 2^{e-b-n}}$$

## 3.8 Errore di rappresentazione

$$|x - \mathrm{fl}^T(x)| \leq \begin{cases} \mathrm{succ}(\widetilde{x}) - \widetilde{x} & x > 0 \\ \widetilde{x} - \mathrm{succ}(\widetilde{x}) & x < 0 \end{cases} = |\mathrm{succ}(\widetilde{x}) - \widetilde{x}| = 2^{e-b-n}$$

### 3.8.1 Errore dovuto al troncamento

$$\frac{\left|x - \mathrm{fl}^T(x)\right|}{|x|} \leq \frac{\left|x - \mathrm{fl}^T(x)\right|}{\left|\mathrm{fl}^T(x)\right|} \leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.f}$$

$$\leq \frac{2^{e-b-n}}{2^{e-b} \cdot 1.0} = \boxed{2^{-n}}$$

Pertanto:

$$\boxed{\frac{\left|x - \mathrm{fl}^T(x)\right|}{|x|} \leq 2^{-n}}$$

### 3.8.2 Errore dovuto all'arrotondamento

L'arrotondamento fa meglio perchè:

$$\left|x - \mathrm{fl}^A(x)\right| \leq \frac{1}{2}|\mathrm{succ}(\widetilde{x}) - \widetilde{x}| = \frac{1}{2} \cdot 2^{e-b-n} = 2^{e-b-n-1}$$

Dividendo per $|x| \geq 2^{e-b}$ otteniamo:

$$\left|\frac{x - \mathrm{fl}^A(x)}{x}\right| \leq \frac{2^{e-b-n-1}}{2^{e-b}} = 2^{-n-1}$$

Pertanto:

$$\boxed{\frac{\left|x - \mathrm{fl}^A(x)\right|}{|x|} \leq 2^{-n-1}}$$

# 4 Precisione di macchina

**Definizione 8: Precisione macchina**

Definiamo la precisione di macchina come il più piccolo numero positivo $\epsilon$ tale che, se sommato a $1$ in virgola mobile, da un risultato diverso da $1$.

$$\epsilon_{\mathrm{mach}} := \min\{\epsilon > 0 : \mathrm{fl}(1 + \epsilon) > 1\}$$

## 4.1 Operazioni macchina

Siano definite le operazioni esatte:

$$\begin{aligned} \Delta : \mathbb{R} \times \mathbb{R} &\longrightarrow \mathbb{R}, & (+, \cdot) \\ \mathbb{R} \times (\mathbb{R} \setminus \{0\}) &\longrightarrow \mathbb{R}, & (:) \end{aligned}$$

Operazione macchina associata $\textcircled{\Delta}$:

$$\begin{aligned} \textcircled{\Delta} \quad & \mathbb{R} \times \mathbb{R} \longrightarrow \mathbb{F} \\ & (x, y) \longrightarrow \textcircled{\Delta}(x, y) = \mathrm{fl}\left(\mathrm{fl}(x) \Delta \cdot \mathrm{fl}(y)\right) \end{aligned}$$

## 4.2 Errore relativo della moltiplicazione

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(x \odot y) = \frac{|x \odot y - xy|}{|xy|} = \frac{|\mathrm{fl}\,(\mathrm{fl}(x)\,\mathrm{fl}(y)) - xy|}{|xy|}}$$

N.B. : noi supponiamo che

$$\frac{|x \cdot y - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} \leq \epsilon_{\mathrm{mach}} \begin{cases} 2^{-n} \\ 2^{-n-1} \end{cases}$$

$z = x \cdot y$

$$\begin{aligned}
\mathrm{Err}_{\mathrm{rel}}(x \odot y) &= \frac{|\mathrm{fl}\,(\mathrm{fl}(x) \cdot \mathrm{fl}(y)) - \mathrm{fl}(x \cdot y) + \mathrm{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \\
&\leq \frac{|\mathrm{fl}(\mathrm{fl}(x) \cdot \mathrm{fl}(y)) - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} + \frac{\overbrace{|\mathrm{fl}(x \cdot y) - x \cdot y|}^{\epsilon_{\mathrm{mach}}}}{|x \cdot y|} \\
&= \frac{\overbrace{|\mathrm{fl}\,(\mathrm{fl}(x) \cdot \mathrm{fl}(y)) - \mathrm{fl}(x) \cdot \mathrm{fl}(y)|}^{1} + \overbrace{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - \mathrm{fl}(x \cdot y)|}^{2}}{|x \cdot y|} + \epsilon_{\mathrm{mach}} \\
&\leq^{1} \frac{|\mathrm{fl}\,(\mathrm{fl}(x) \cdot \mathrm{fl}(y)) - \mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|} \cdot \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|} \\
&\leq \epsilon_{\mathrm{mach}} \cdot \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|} \\
&\leq^{2} \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y + x \cdot y - \mathrm{fl}(x \cdot y)|}{|x \cdot y|} \\
&\leq \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} + \frac{|\mathrm{fl}(x \cdot y) - x \cdot y|}{|x \cdot y|} \leq \epsilon_{\mathrm{mach}} \\
&\leq \epsilon_{\mathrm{mach}} + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} \\
1 + 2 &\leq \epsilon_{\mathrm{mach}} \left(1 + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y)|}{|x \cdot y|}\right) + \frac{|\mathrm{fl}(x) \cdot \mathrm{fl}(y) - x \cdot y|}{|x \cdot y|} \\
&\leq \epsilon_{\mathrm{mach}} \left(1 + \epsilon_{\mathrm{mach}} \underbrace{(\ldots\ldots)}_{\text{dipende da } x,\, y}\right)
\end{aligned}$$

Al primo ordine, il comportamento dell'errore relativo non dipende dai valori specifici di $x$ e $y$.
L'errore relativo della moltiplicazione macchina $u$: $\epsilon + M\epsilon$.
La moltiplicazione è quindi considerata stabile, ossia l'errore relativo in output è controllato da quello in input.

## 4.3 Errore relativo della somma

L'errore relativo della somma macchina è:

$$\boxed{\mathrm{Err}_{\mathrm{rel}}(x \oplus y) = \frac{|\mathrm{fl}\,(\mathrm{fl}(x) + \mathrm{fl}(y)) - (x + y)|}{|x + y|} = \frac{|x \oplus y - (x + y)|}{|x + y|}}$$

Se $x$ e $y$ hanno segno opposto e sono molto vicini tra loro, può verificarsi una forte cancellazione numerica, ossia la perdita di cifre significative.

**Esempio 6: Cancellazione Numerica**

Ipotesi in cui $x$ e $y$ si annullano fra loro lasciando solo un $\epsilon_{\mathrm{mach}}$:

$$y = -x + \epsilon_{\mathrm{mach}}$$

Svolgimento:

$$\begin{aligned}\mathrm{Err}_{\mathrm{rel}}(x \oplus y) &\leq \epsilon_{\mathrm{mach}} \left(1 + \frac{|x|+|y|}{|x+y|} + \epsilon_{\mathrm{mach}} \frac{|x|+|y|}{|x+y|}\right) \\ &= \epsilon_{\mathrm{mach}} \left(1 + \frac{2|x| + \epsilon_{\mathrm{mach}}}{\epsilon_{\mathrm{mach}}} + 2|x| + \epsilon_{\mathrm{mach}}\right) \\ &= \left(\epsilon_{\mathrm{mach}} + 2|x| + \epsilon_{\mathrm{mach}} + 2|x|\epsilon_{\mathrm{mach}} + \epsilon_{\mathrm{mach}}^2\right) \\ &= 2\left(|x| + \epsilon_{\mathrm{mach}}\right) + \dots\end{aligned}$$

I $\dots$ assorbono $\epsilon_{\mathrm{mach}}^2$ e $2|x|\epsilon_{\mathrm{mach}}$ che sono numeri talmente piccoli rispetto agli altri da essere irrilevanti. Significa che se $x$ è grande, anche l'errore relativo è enorme.

## 4.4 Stabilità degli algoritmi

**Esempio 7: Calcolo dell'integrale col metodo iterativo**

$$I_n = \frac{1}{e} \int_0^1 e^x \cdot x^n \cdot dx$$

Svolgimento: Conoscendo il valore di $I_0$ ossia:

$$I_0 = \frac{1}{e} \int_0^1 e^x \cdot dx = \frac{1}{e} \left[e^x\right]_0^1 = \frac{e-1}{e}$$

Inoltre si può integrare per parti $I_n$:

$$\begin{aligned}I_n &= \frac{1}{e} \left[\left(e^x x^n\right)_0^1 - \int_0^1 e^x \cdot n x^{n-1} \cdot dx\right] \\ &= \frac{1}{e} \left[e - n \int_0^1 e^x \cdot x^{n-1} \cdot dx\right] \\ &= 1 - n \frac{1}{e} \int_0^1 e^x \cdot x^{n-1} \cdot dx \\ &= 1 - n \cdot I_{n-1}\end{aligned}$$

Di conseguenza conosco la successione definita per ricorsione:

$$\boxed{\begin{cases} I_0 = \frac{e-1}{e} \\ I_n = 1 - n \cdot I_{n-1} \end{cases}}$$

In realtà $I_{n-1}$ viene calcolato con un errore, quindi supponiamo di aver calcolato $\widetilde{I}_{n-1} = I_{n-1} + \epsilon_{n-1}$. Quindi per calcolare $I_n$:

$$\begin{aligned}I_n &= 1 - n \cdot I_{n-1} \\ \widetilde{I}_n &= 1 - n \cdot \widetilde{I}_{n-1} = \underbrace{1 - n I_{n-1}}_{} - n\epsilon_{n-1} \\ &= \boxed{I_n - n\epsilon_{n-1}}\end{aligned}$$

Questo risultato è iterabile dato che si verifica per ogni $n$, inoltre so che $\epsilon_n = -n\epsilon_{n-1}$.
Iterando $n$ volte ottengo:

$$\boxed{\epsilon_n = (-1)^n \cdot n! \cdot \epsilon_0}$$

L'errore assoluto è quindi:

$$|\widetilde{I}_n - I_n| = n! \cdot |\epsilon_0| = n! \cdot \mathrm{fl}\left(\frac{e-1}{e}\right) - \frac{e-1}{e}$$

Da cui ottengo:

$$= n! \cdot \underbrace{\frac{|\,\mathrm{fl}\left(\frac{e-1}{e}\right) - \frac{e-1}{e}|}{\frac{e-1}{e}}}_{\leq \epsilon_{\text{mach}}} \cdot \underbrace{\frac{e-1}{e}}_{\leq 1}$$

La frazione è l'errore relativo di rappresentazione di un numero reale
L'errore assoluto è dominato da:

$$\boxed{\leq n! \cdot \epsilon_{\text{mach}}}$$

Adesso stimiamo quanto è $I_n$:

$$I_n = \frac{1}{e}\int_0^1 x^n e^x \cdot dx = O(\frac{1}{n})$$

Dimostriamo che è vero:

Posso stimarlo da sopra con un integrale $\leq$

$$nI_n = \frac{1}{e}\int_0^1 nx^n e^x \cdot dx \leq \frac{1}{e}\int_0^1 enx^n \cdot dx = \frac{n}{n+1}\left[x^{n+1}\right]_0^1 = \frac{n}{n+1}$$

E posso stimarlo da sotto con un'integrale $\geq$

$$nI_n = \frac{1}{e}\int_0^1 nx^n e^x \cdot dx \geq \frac{1}{e}\int_0^1 nx^n \cdot dx = \frac{n}{n+1} \cdot \frac{1}{e}$$

Abbiamo quindi scoperto che $I_n \approx \frac{1}{n+1}$
Adesso possiamo dire che l'errore relativo:

$$\frac{|\widetilde{I}_n - I_n|}{|I_n|} \leq \frac{n!\epsilon_{\text{mach}}}{\frac{1}{n+1}} = (n+1)n!\epsilon_{\text{mach}} = \boxed{(n+1)!\epsilon_{\text{mach}}}$$

Questo algoritmo si dice **instabile**.

**Definizione 9: Algoritmo Stabile**

Un algoritmo si dice **stabile** se non amplifica in modo incontrollato gli errori presenti sui parametri di input e i dati. In generale, si dice **stabile** un algoritmo per cui vale:

$$\mathrm{Err}^{\mathrm{rel}}(\text{output}) \leq C_{\text{stab}}\,\mathrm{Err}^{\mathrm{rel}}(\text{input})$$

Dove $C_{\text{stab}}$ è la costante di stabilità.

## 4.5 Condizionamento dei problemi

Per ogni problema abbiamo $x^*$ che è la soluzione, su $F : X \times D \to \mathbb{R}$ (o $\mathbb{R}^m$) dove, $X$ è il dominio della soluzione e $D$ è l'insieme dei dati ammissibili.

**Definizione 10: Problema ben posto**

Un problema si dice **ben posto** se:
1. $\forall d \in D \quad \exists\, x^* \in X : \mathrm{F}(x^*, d) = 0$ esiste una **soluzione**
2. $x^*$, la soluzione è **unica**
3. $x^*$ varia con **continuità** rispetto ai dati

La soluzione è data dalla **mappa soluzione**:

$$d \mapsto x^*(d) \;:\; \mathrm{F}(x^*(d), d) = 0 \quad x^* \;:\; D \to X$$

I **problemi inversi**, ossia quando dato l'output si vuole ricavare l'input, **non** sono ben posti; dato che più input possono avere lo stesso output. Vengono quindi **regolarizzati**, ossia si modifica il problema in modo da penalizzare soluzioni "non fisiche" o "di bassa energia".

**Definizione 11: Condizionamento Numerico**

È dato dal rapporto tra l'errore commesso sul risultato di un calcolo e l'incertezza sui dati in ingresso. Un problema si dice **ben condizionato** se la soluzione del problema con delle piccole variazioni, non cambia di molto la soluzione del problema originale. Un problema è **mal condizionato** se la soluzione è molto sensibile a piccole variazioni dei dati iniziali.

### 4.5.1 Condizionamento di un problema ben posto

$$\frac{\text{cond. locale}}{\text{assoluto}} \quad \mathrm{k}(d) := \limsup_{\widetilde{d}\to d} \frac{\left|x(d)-x(\widetilde{d})\right|}{\left|d-\widetilde{d}\right|}$$

Quindi $\mathrm{k}(d)$ è rappresentato dal limite da i dati approssimati $\widetilde{d}$ verso il dato vero $d$ del condizionamento assoluto diviso l'errore sul dato. Questo limite rappresenta il rapporto incrementale, come nelle derivate.

$$\limsup_{\widetilde{d}\to d} f(\widetilde{d}) = \lim_{r\to 0^+} \sup_{\widetilde{d}\in\,]d-r,d+r[} f(\widetilde{d})$$

Ossia prendo l'intorno del dato $d$ e trovo il sup diminuendo $r$, in questo modo mi avvicino a $d$ tenendo $f$ più grande possibile.

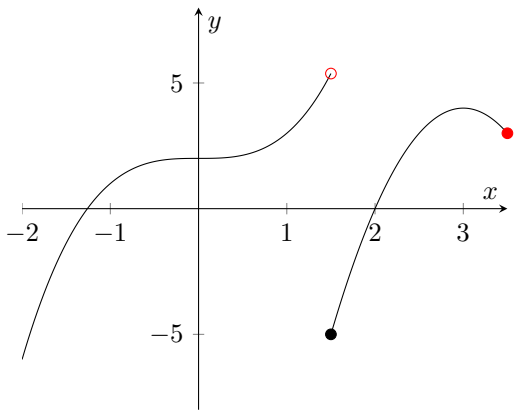
$\mathrm{k}(d)$ è la pendenza del grafico di $x(d)$ **massima in modulo**. Se abbiamo una pendenza $\mathrm{k}(d)$, allora vuol dire che $\forall\,\epsilon>0\ \exists r>0$ tale che:

$$\frac{\left|x(\widetilde{d})-x(d)\right|}{|\widetilde{d}-d|} < \mathrm{k}(d)+\epsilon \quad \forall \widetilde{d}\in\,]d-r,d+r[$$

È quindi una stima dall'alto di $d$ che vale localmente, ossia su un'intorno di $d$. Per questo si usa il $\limsup$.

Si verifica un problema quando $\mathrm{k}(d) >> 1$ (quindi grande rispetto al contesto). Un **errore assoluto** piccolo su $d$ può implicare un **errore assoluto** enorme su $x$. **Problema mal condizionato**.

Grafico:




### 4.5.2 Condizionamento locale relativo

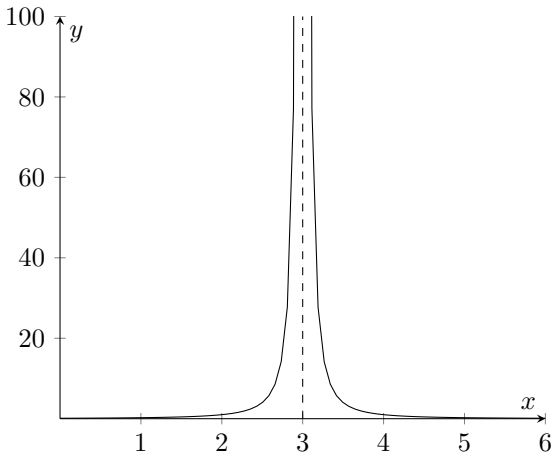
$$\mathrm{k}^{\mathrm{rel}}(d) := \boxed{\limsup_{\widetilde{d}\to d} \underbrace{\frac{\left|x(\widetilde{d})-x(d)\right|}{|x(d)|}}_{\text{pendenza mappa sol.}} \cdot \frac{|d|}{\left|\widetilde{d}-d\right|}}$$

Ci sono problemi in cui il condizionamento non dipende dal dato $d$, ma è uguale dappertutto.

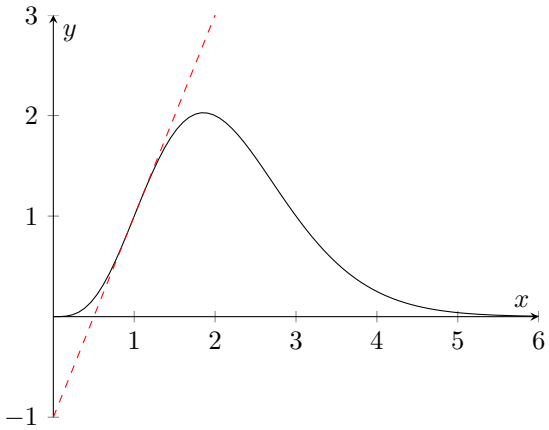
Può succedere che $\exists K\ (K^{\mathrm{rel}})$ tale per cui $\mathrm{k}(d)\le K\ \left(\mathrm{k}^{\mathrm{rel}}(d)\le K^{\mathrm{rel}}\right)\ \forall d\in D$. Dove $D$ è l'insieme di dati ammissibili. In tal caso si parla di condizionamento assoluto/relativo **globale** e si ha:

$$\mathrm{k} = \sup_{d,\widetilde{d}\in D} \frac{\left|x(\widetilde{d})-x(d)\right|}{|\widetilde{d}-d|} \quad \blacktriangle$$

No cond. globale




Si cond. globale



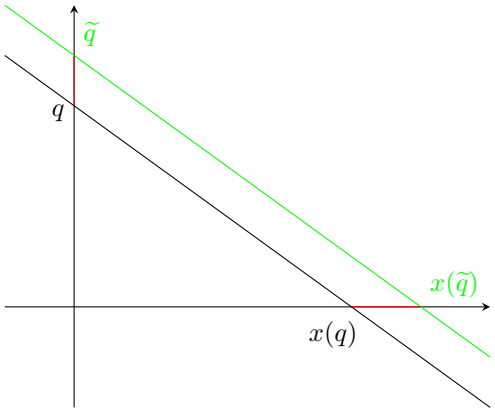

▲ $\left|x(\widetilde{d}) - x(d)\right| \leq \mathrm{K}\left|\widetilde{d} - d\right| \quad \forall\, d, \widetilde{d} \in D$

Ho un fattore moltiplicativo nel caso dell'errore assoluto.
Mentre per il relativo, l'errore varia per $\epsilon_{\text{mach}}$ moltiplicato a $\mathrm{K}^{\text{rel}}$:

$$\frac{\left|x(\widetilde{d}) - x(d)\right|}{|x(d)|} \leq \mathrm{K}^{\text{rel}} \frac{\left|\widetilde{d} - d\right|}{|d|}$$

Se $\mathrm{K}^{\text{rel}} \approx \frac{1}{\epsilon_{\text{mach}}} \Rightarrow \frac{|x(\widetilde{d}) - x(d)|}{|x(d)|} \approx 1 = 100\%$ Quindi un'errore relativo di circa $1$ vuol dire che la soluzione è completamente diversa da quella vera.

Esempio :

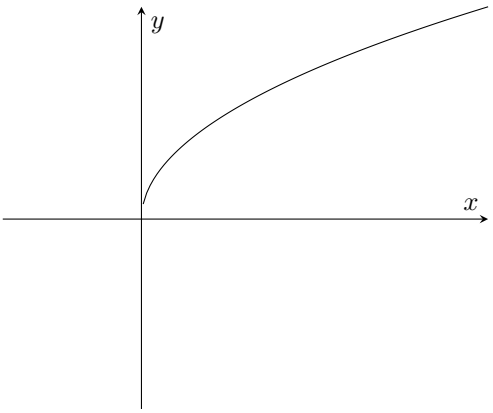



Con il grafico si nota come un minore errore su $q$ crea un errore maggiore su $x(q)$.

### 4.5.3 Condizionamento globale di ordine $\alpha$

**Esempio 8: Cosa succede quando la pendenza "esplode"?**

Dato $d \in D$, la cui mappa soluzione è $d \mapsto x(d)$ con $D = [0, +\infty[$ e $x(d) = \sqrt{d}$.




In questo la caso la pendenza vicino a $0$ tende a $\infty$.
Quindi:

$$\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\widetilde{d}-d\right|}=\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\left(\sqrt{\widetilde{d}}-\sqrt{d}\right)\left(\sqrt{\widetilde{d}}+\sqrt{d}\right)\right|}=\frac{1}{\left|\sqrt{\widetilde{d}}+\sqrt{d}\right|}$$

Ossia abbiamo che:

$$\limsup_{\widetilde{d}\to d}\frac{1}{2\sqrt{d}}\begin{cases}d\neq 0 & \checkmark\\ d=0 & +\infty\end{cases}$$

Quindi avvicinandomi a $d=0$ non riesco a fare delle stime quantitative.
Si introduce quindi il **condizionamento globale assoluto** di **ordine** $\alpha\in(0,1)$

$$\mathrm{k}_\alpha=\boxed{\sup_{d,\widetilde{d}}\frac{\left|x(\widetilde{d})-x(d)\right|}{\left|\widetilde{d}-d\right|^\alpha}}$$

Lo usiamo per studiare problemi **molto mal condizionati**.

Nell'esempio $\alpha=\frac{1}{2}$:

$$=\frac{\left|\sqrt{\widetilde{d}}-\sqrt{d}\right|}{\left|\widetilde{d}-d\right|^{\frac{1}{2}}}$$

$$=\frac{\epsilon}{\left(\epsilon(2\sqrt{d}+\epsilon)\right)^{\frac{1}{2}}}=\frac{\epsilon}{\left(\epsilon^2+2\epsilon\sqrt{d}\right)^{\frac{1}{2}}}\quad \text{se } d=0\to\frac{\epsilon}{\epsilon}=1$$

se $d>0$ si mostra che è limitata.

Se vale:

$$\sup_{d,\widetilde{d}}\frac{\left|x(\widetilde{d})-x(d)\right|}{\left|\widetilde{d}-d\right|^\alpha}\leq \mathrm{k}_\alpha$$

$$\left|x(\widetilde{d})-x(d)\right|\leq \mathrm{k}_\alpha\left|\widetilde{d}-d\right|^\alpha\quad\forall d,\widetilde{d}\in D$$

Nota: $\alpha<1\quad\left|\widetilde{d}-d\right|<<1\Rightarrow\left|\widetilde{d}-d\right|^\alpha>>\left|\widetilde{d}-d\right|$.

# 5 Sistemi Lineari

## 5.1 Soluzione di Sistemi Quadrati

Problema: $A\in M_{n\times n}(\mathbb{R}), b\in\mathbb{R}^n$ con $A$ invertibile.
Trovare $x\in\mathbb{R}^m$ tale che $\underbrace{Ax-b=0}_{\mathrm{F}(x,d)=0}$ funzione che prende un vettore reale e ne ritorna un'altro.

Dominio di $F\quad \underset{x}{\mathbb{R}^n}\times\underset{A}{M_{n\times n}(\mathbb{R})}\times\underset{b}{\mathbb{R}^n}\to\underset{Ax-b}{\mathbb{R}^n}$

Osservazione: $A$ invertibile $\Rightarrow$ esiste ed è unica $x:\ Ax = b$, quindi la mappa soluzione è:

$$x = A^{-1}b$$

Manca sapere se la mappa soluzione è continua, serve quindi una norma sul dominio e una sul codominio. Su $\mathbb{R}^n$ prendiamo una norma qualsiasi.

## 5.2 Norma indotta

**Definizione 12: Norma Indotta**

Se $\|\cdot\|$ è una norma su $\mathbb{R}^m$ esiste una norma detta **naturale** su $M_{m\times m}(\mathbb{R})$ **indotta** da $\|\cdot\|$:

$$\|A\|_* = \sup_{x\in\mathbb{R}^m\setminus\{0\}} \frac{\|Ax\|}{\|x\|}$$

Questa norma indicata è $\|\cdot\|_*$

Proposizione: $\|\cdot\|_*$ è una norma.

Dimostrazione: Devo dimostrare che rispetta le proprietà di una norma.

1. Omogeneità di grado $1$. Prendiamo $\lambda \in \mathbb{R}\setminus\{0\}$ allora:

$$\begin{aligned}\|\lambda A\|_* &= \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|\lambda(Ax)\|_*}{\|x\|} = \sup_{x\in\mathbb{R}\setminus\{0\}} |\lambda|\cdot\frac{\|Ax\|}{\|x\|} \\ &= |\lambda| \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|Ax\|}{\|x\|} = |\lambda|\cdot\|A\|_* \quad \checkmark\end{aligned}$$

2. Una norma è $=0$ se e solo se è$\|0\|$. Quindi supponiamo che la norma sai uguale a $0$:

$$0 = \|A\|_* = \sup_{x\in\mathbb{R}\setminus\{0\}} \frac{\|Ax\|}{\|x\|} \Rightarrow \|Ax\| = 0 \quad \forall\, x\in\mathbb{R}^m$$

$$Ax = \begin{pmatrix}0\\ \vdots \\ 0\end{pmatrix} \quad \forall\, x\in\mathbb{R}^m \qquad \text{Quindi è un vettore nullo}$$

$$\underset{i\text{-esima colonna}}{A(:,i)} = A_{ei} = \begin{pmatrix}0\\ \vdots \\ 0\end{pmatrix} \quad \forall\, i \quad \Rightarrow \quad A = \begin{pmatrix}0 & \dots & 0\\ \vdots & & \vdots \\ 0 & \dots & 0\end{pmatrix} \quad \checkmark$$

3. Disuguaglianza triangolare:

Ho dimostrato che è una norma dato che rispetta tutte e tre le proprietà.

Che norma si usa su $V\times W$ con $V$ e $W$ che hanno le norme $\|\cdot\|_v, \|\cdot\|_w$?

$$\|(v,w)\|_{v\times w} := \|v\|_v + \|w\|_w \quad \text{Per esempio}$$

La mappa soluzione: $x(A,b) = A^{-1}b$ è continua?

$\forall\epsilon > 0\ \exists\delta > 0$ tale che

$$\left\|x\left(\widetilde{A},\widetilde{b}\right) - x\left(A,b\right)\right\| < \epsilon \quad \text{se} \quad \left\|\left(\widetilde{A},\widetilde{b}\right) - (A,b)\right\|_{\mathbb{M}_{m\times m}(\mathbb{R})\times\mathbb{R}^m} < \delta$$

**Osservazione**: È composizione di $A \mapsto A^{-1}$ continua sulle matrici invertibili.
E $\left(A^{-1}, b\right) \mapsto A^{-1}b$ continua.
Dunque la mappa soluzione è continua in $(A, b)$ se $A$ è invertibile.

Come è condizionato il problema?

- Considero il caso in cui $A$ sia fissa ed "esatta".

  $b \mapsto x(A,b) = A^{-1}b$
  $A(x+\delta x) = b + \delta b \quad x+\delta x$ soluzione del sistema, con termine noto perturbato
  $Ax = b$

  Ci interessa quindi l'errore relativo: $\dfrac{\|\delta x\|}{\|x\|} \leq \cdots \cdot \dfrac{\|\delta b\|}{\|b\|}$

  $\underset{=b}{Ax} + A\delta x = b + \delta b$
  $\delta x = A^{-1}\delta b \Rightarrow$ Se due vettori sono uguali hanno anche norme uguali: $\|\delta x\| = \left\|A^{-1}\delta b\right\|$
  $\Rightarrow \quad \|\delta x\| = \left\|A^{-1}\delta b\right\| \leq \left\|A^{-1}\right\|_* \|\delta b\| \quad \circledast$

> **Nota 1: Norma Indotta**
>
> Dato che
> $$\frac{\|Ax\|}{\|x\|} \leq \sup_y \frac{\|Ay\|}{\|y\|} = \|A\|_* \quad \forall x \in \mathbb{R}^n$$
> Allora:
> $$\boxed{\|Ax\| \underset{\forall x \in \mathbb{R}^n}{\leq} \|A\|_* \cdot \|x\|}$$

  Su $\circledast$ sto misurando in termini assoluti, devo invece misurare in termini <u>relativi</u> dividendo per $\|x\|$:

  $\dfrac{\|\delta x\|}{\|x\|} \leq \left\|A^{-1}\right\|_* \|\delta b\| \cdot \dfrac{1}{\|x\|}$ $\triangle$ Mi serve poter stimare da sopra $\|x\| \geq \ldots$ qualcosa
  $\circledast \quad \|x\| \geq \dfrac{\|b\|}{\|A\|_*} \Leftarrow \begin{cases} Ax = b \Rightarrow \|Ax\| = \|b\| \\ \|Ax\| \leq \|A\|_* \|x\| \quad \text{Nota 1} \end{cases}$
  $\triangle + \circledast \quad \dfrac{\|\delta x\|}{\|x\|} \leq \left\|A^{-1}\right\|_* \|A\|_* \cdot \dfrac{\|\delta b\|}{\|b\|} \; \forall b \in \mathbb{R}^n$
  Dove $\left\|A^{-1}\right\|_* \|A\|_*$ è l'indice di condizionamento globale del problema semplificato.

- Ora considero di perturbare anche $A$:

$$\begin{cases} (A+\delta A)(x+\delta x) = b + \delta b \\ Ax = b \end{cases}$$
$$(A+\delta A)\delta x = b + \delta b - (A+\delta A)x = \delta b - \delta A x \quad \odot$$

  Noto che se $\frac{\|\delta A\|_*}{\|A\|_*} < \frac{1}{\|A\|_* \|A^{-1}\|_*}$, allora $\mathbb{1} + A^{-1}\delta A$ è **invertibile**.

  **Dimostrazione**: Suppongo per assurdo che $\mathbb{1} + A^{-1}\delta A$ non sia invertibile

  $\exists y \neq 0$ tale che $\quad \left(\mathbb{1} + A^{-1}\delta A\right) y = 0 \quad$ cioè $\quad A^{-1}\delta A y = -y$
  $\Rightarrow \; \left\|A^{-1}\delta A y\right\| = \|y\|$
  $1 = \dfrac{\left\|A^{-1}\delta A y\right\|}{\|y\|} \leq \sup_{x \in \mathbb{R}^n \; x \neq 0} \dfrac{\left\|A^{-1}\delta A x\right\|}{\|x\|} \underset{\text{Nota 1}}{=} \left\|A^{-1}\delta A\right\|_*$
  $1 \leq \left\|A^{-1}\delta A\right\|_* \underset{\text{Nota 1}}{\leq} \left\|A^{-1}\right\|_* \|\delta A\|_* = \left\|A^{-1}\right\|_* \|A\|_* \cdot \dfrac{\|\delta A\|_*}{\|A\|_*}$
  $\underset{\text{Perturbazione rel.}}{\dfrac{1}{\|A\|_* \|A^{-1}\|_*} \leq \dfrac{\|\delta A\|_*}{\|A\|_*}}$ **Assurdo** contraddice l'ipotesi. ✓

Da $\odot$ segue che:

$$\begin{aligned}(A+\delta A)\delta x &= \delta b - \delta A x\\ A(\mathbb{1}+A^{-1}\delta A)\delta x &= \delta b - \delta A x\\ \delta x &= (\mathbb{1}+A^{-1}\delta A)^{-1}\cdot A^{-1}(\delta b - \delta A x)\\ &= (\mathbb{1}+A^{-1}\delta A)^{-1}\cdot A^{-1}(\delta b - \delta A A^{-1} b)\end{aligned}$$

Passiamo alle norme

$$\begin{aligned}\|\delta x\| = \cdots &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left\|\delta b - \delta A A^{-1} b\right\|\\ &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left(\|\delta b\| + \left\|\delta A A^{-1} b\right\|\right)\\ &\le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \left(\|\delta b\| + \|\delta A\|_* \left\|A^{-1}\right\|_* \|b\|\right)\end{aligned}$$

Prima abbiamo usato $\frac{1}{\|x\|} \le \frac{\|A\|_*}{\|b\|}$. Quindi Per l'errore relativo:

$$\frac{\|\delta x\|}{\|x\|} \le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \left\|A^{-1}\right\|_* \|A\|_* \left(\frac{\|\delta b\|}{\|b\|} + \left\|A^{-1}\right\|_* \|\delta A\|_*\right)$$

$\|\delta A\|_*$ è un errore assoluto, noi stiamo usando solo errori relativi, quindi divido e moltiplico per $\|A\|_*$

$$\frac{\|\delta x\|}{\|x\|} \le \left\|\left(\mathbb{1}+A^{-1}\delta A\right)^{-1}\right\|_* \boxed{\left\|A^{-1}\right\|_* \|A\|_*} \left(\frac{\|\delta b\|}{\|b\|} + \boxed{\left\|A^{-1}\right\|_* \|A\|_*} \frac{\|\delta A\|_*}{\|A\|_*}\right) \quad \circledast$$

**Definizione 13: Numero di condizionamento**

La quantità $\left\|A^{-1}\right\|_* \|A\|_*$ è detta numero di condizionamento della matrice $A$ rispetto alla norma $\|\cdot\|$ si denota con $k(A,\|\cdot\|)$ o $\mathrm{Cond}(A,\|\cdot\|)$

La stima $\circledast$ è una stima di condizionamento **relativo locale**.

Tipicamente per matrici grandi $\begin{cases}\text{Piene} & n > 10^4\\ \text{Sparse} & n > 10^6\end{cases}$

$\mathrm{Cond}(A,\|\cdot\|)$ è facilmente $\approx 10^4$ $10^5$ in casi buoni.
Sbagliare $A$ di $10^{-16}$ relativo, implica avere un errore relativo su $x$ di $10^{-8}$. Quindi su 16 cifre significative ne calcolo solo 8 correttamente: questo è un caso buono per le matrici grandi.
Salvezza: In generale tutti i $\le$ mostrati finora sono in realtà stretti, per ottenere l'uguaglianza, ossia l'errore massimo bisogna prendere il peggior dato con la peggior perturbazione (**molto improbabile**).

Riprendiamo il caso in cui $A$ è fissa ed esatta dove abbiamo $Ax = b$ ossia, perturbando $A$:

$$\begin{aligned}A(x+\delta x) = b + \delta b \;\to\; \frac{\|\delta x\|}{\|x\|} &\le \mathrm{k}(A,\|\cdot\|)\frac{\|\delta b\|}{\|b\|}\\ \mathrm{k}(A,\|\cdot\|) &= \|A\|_* \left\|A^{-1}\right\|_*\end{aligned}$$

Si tratta di una disequazione sharp? (potrebbe esistere il caso di uguaglianza)

Suppongo di usare $\|\cdot\| = \|\cdot\|_2$, ossia la **norma euclidea** $\|v\|_2 = \left(\sum v_i^2\right)^{1/2}$.
Chi è la **Norma indotta** su $M_{n\times n}(\mathbb{R})$?

$$\|A\|_* = \max_{x\neq 0}\frac{\|Ax\|_2}{\|x\|_2} = \left(\max_{x\neq 0}\frac{\sum (Ax)_i^2}{\sum x_i^2}\right)^{\frac{1}{2}}$$

Ricordiamo la proprietà del prodotto riga x colonna tra vettori: $\boxed{\sum y_i^2 = y^T\cdot y}$

$$= \left[\max_{x\neq 0}\frac{x^T A^T A x}{x^T x}\right]^{\frac{1}{2}} \quad \circledast \quad G = A^T A = G^T \text{ matrice simmetrica}$$

**Nota 2**

$M$ è una matrice quadrata, se è diagonalizzabile allora:

$$M = P\Lambda P^{-1}$$

Dove $\Lambda$ è la matrice diagonale con gli autovalori di $M$ e $P$ è una matrice invertibile le cui colonne sono autovettori di $M$.

### 5.2.1 Teorema Spettrale

**Teorema 1: Teorema Spettrale**

Ho $G \in M_{n\times n}(\mathbb{R})$ **simmetrica** allora: $\exists\ \lambda_1, \lambda_2, \dots, \lambda_n$ e $Q \in M_{n\times n(\mathbb{R})}$ matrice **ortogonale** ($Q^TQ = QQ^T = \mathbb{1}_n$) tali che:

$$\boxed{G = Q\Lambda Q^T} \quad \Lambda = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{pmatrix}$$

Quindi:

$x^TA^TAx = x^TGx \geq 0$ dato che è uguale a $\|Ax\|_2^2$

È $= 0$ solo se $Ax = 0$ se $A$ è di rango pieno ciò implica che $x = 0$

$\Rightarrow \lambda_i > 0$ se $A$ è invertibile

$G$ si dice quindi, **simmetrica strettamente definita positiva**, ossia tutti i suoi autovalori sono maggiori stretti di $0$.

$$\circledast \|A\|_*^2 = \max_{x\neq 0} \frac{x^TGx}{x^Tx} \underset{\text{Teo. spett.}}{=} \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^Tx}$$

$$= \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^T\underbrace{\mathbb{1}}_{=QQ^T}x} = \max_{x\neq 0} \frac{x^TQ\Lambda Q^Tx}{x^TQQ^Tx}$$

Dato che $Q$ è invertibile, allora posso fare un cambio di variabile: $y = Q^Tx \quad x = 0 \Leftrightarrow y = 0$

$$= \max_{y\neq 0} \frac{y^T\Lambda y}{y^Ty} = \max_{y\neq 0} \left(\frac{y}{\|y\|}\right)^T \Lambda \frac{y}{\|y\|}$$

Sono quindi passato da una generica matrice positiva ad un matrice diagonale con diagonale positiva.

$= max_{z:\ \|z\|_2=1} z^T\Lambda z$

Vogliamo, quindi, risolvere:

$max \sum_{i=1}^n \lambda_i z_i^2 \quad$ con $\quad \sum_{i=1}^n z_i^2 = 1$

Ossia voglio trovare il massimo autovalore di $G$

Provo con: $z = e_{\underline{i}}\ :\ \lambda_{\underline{i}} \geq \lambda_i\ \forall i = 1 \dots n \quad$ suppongo: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$

$$\sum_{i=1}^n \lambda_i z_i^2 = \lambda_1 \underbrace{\left(z_1^2 + \sum_{i=2}^n \frac{\lambda_i}{\lambda_1} z_i^2\right)}_{\text{Separo il primo termine}} \leq \lambda_1 \underbrace{\left(z_1^2 + \sum_{i=2}^n z_i^2\right)}_{=1} = \lambda_1$$

Se prendo $z = e_1$ (primo vettore della base canonica) ottengo:

$$\sum_{i=1}^n \lambda_i z_i^2 = \lambda_1 \cdot 1^2 + \lambda_2 \cdot 0^2 + \dots + \lambda_n \cdot 0^2 = \boxed{\lambda_1}$$

Quindi vale:

$$\|A\|_*^2 = \max_{z:\ \|z\|_2=1} \frac{z^T G z}{z^T z} = \lambda_{\max}(G) \text{ autovalore massimo}$$

$$\boxed{\|A\|_* = \sqrt{\lambda_{\max}\left(A^T A\right)} \text{ se } \|\cdot\| = \|\cdot\|_2}$$

### 5.2.2 Decomposizione ai valori singolari (SVD)

**Teorema 2**

Se $A \in M_{n\times n}(\mathbb{R})$ di rango pieno allora $\exists\, U, \Sigma\, V$ con $U, V$ **ortogonali** $n\times n\ \Sigma = \begin{pmatrix} \sigma_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_n \end{pmatrix}$ **diagonale**

con $\sigma_i > 0$. Tale per cui:

$$\boxed{A = U\Sigma V^T}$$

Adesso vediamo cosa sono $U, \Sigma, V$:

$$A^T A = V\Sigma U^T \cdot U\Sigma V^T = V\Sigma \cdot \Sigma V^T = V\Sigma^2 V^T \Rightarrow \sigma_i^2 \text{ autovalore di } A^T A$$

Si nota che le colonne di $V$ sono gli autovettori di $A^T A$. Per dimostrarlo, prendiamo una colonna di $V$, la moltiplichiamo e vediamo se otteniamo $\lambda$ volte la stessa colonna (proprietà **autovalore**).
$V(:, j)$ è la $j$-esima colonna.

$$A^T A \cdot V(:, j) = V\Sigma^2 \underbrace{V^T V(:, j)}_{w}$$

$$w_i = V^T(i, :)V(:\, j) = V(:, i)^T V(:, j) = \left(V^T V\right)(i, j) = \mathbb{1}(i, j) \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

$$A^T A \cdot V(:, j) = V\Sigma^2 e_j = V\sigma_j^2 e_j = \sigma_j^2 V e_j = \underset{\text{autovalore}}{\sigma_j^2}\ \underset{\text{autovettore}}{V(:, j)}$$

Questo spiega cos'è $V$ e $\Sigma^2$. Ora vediamo cos'è la matrice $U$:

$$AA^T = U\Sigma V^T \cdot V\Sigma U^T = U\Sigma^2 U^T$$

Adesso non serve rifare i conti, sono gli stessi ma con nomi diversi. Quindi ottengo:

$\Rightarrow \sigma_j^2$ sono anche autovalori di $AA^T$

$\Rightarrow$ Gli autovettori di $AA^T$ sono le colonne di $U$

Adesso continuiamo con il condizionamento in norma $2$ e nel vedere se la disequazione è sharp:

$$\|A\|_* = \sqrt{\lambda_{\max}\left(A^T A\right)} = \sqrt{\lambda_{\max}\left(V\Sigma^2 V^T\right)} = \sqrt{\max \sigma_i^2} = \sigma_{\max}$$

Per il condizionamento serve anche:

$$\left\|A^{-1}\right\|_* = \sqrt{\lambda_{\max}\left(A^{-T} A^{-1}\right)}$$

$$A = U\Sigma V^T \Rightarrow A^{-1} = V\Sigma^{-1} U^T \qquad \Sigma^{-1} = \begin{pmatrix} \frac{1}{\sigma_1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \frac{1}{\sigma_n} \end{pmatrix}$$

$$A^{-T} A^{-1} = U\Sigma^{-1} V^T \cdot V\Sigma^{-1} U^T = U\Sigma^{-2} U^T$$

$$\left\|A^{-1}\right\|_* = \sqrt{\lambda_{\max}\left(U\Sigma^{-2} U^T\right)} = \max \frac{1}{\sigma_i} = \frac{1}{\sigma_{\min}}$$

$$\boxed{\mathrm{k}\left(A, \|\cdot\|_2\right) = \|A\|_* \left\|A^{-1}\right\|_* = \frac{\sigma_{\max}}{\sigma_{\min}}}$$

$\|A\|_*$ nel caso $\|\cdot\| = \|\cdot\|_2$ su $\mathbb{R}^n$ viene denotata con $\|A\|_2$.

Torniamo a domandarci se:

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \mathrm{k}\left(A, \|\cdot\|_2\right) \frac{\|\delta b\|_2}{\|b\|_2}$$

è irrealistica, cioè esiste l'uguaglianza?
Per dimostrarla abbiamo usato 2 stime:

1. $\|b\|_2 = \|Ax\|_2 \leq \|A\|_2 \|x\|_2$ Può valere nel caso di uguaglianza?

$$\|Ax\|_2^2 = x^T V \Sigma U^T \cdot U \Sigma V^T x = x^T V \Sigma^2 V^T x$$
$$y = V^T x \quad \Rightarrow \quad y^T \Sigma^2 y$$
$$\|x\|_2^2 = \left\|V^T x\right\|_2^2 = \|y\|_2^2$$

> **Nota 3: Ragionamento**
>
> Il $\max \frac{\|Ax\|_2^2}{\|x\|_2^2}$ è raggiunto se $x$ è proporzionale all'autovettore relativo all'autovalore massimo di $A^T A$, ossia $\sigma_{\max}^2$ cioè la prima colonna di $V$. Quindi esiste l'uguaglianza.

Se $x = c \cdot V(:,1) \quad Ax = b \Rightarrow b = c \cdot A^{-1} V(:,1) = c \cdot V \Sigma^{-1} U^T V(:,1)$ allora:

$$\|b\|_2 = \|A\|_2 \|x\|_2 \qquad \text{(esiste l'uguaglianza)}$$

2. $\|\delta x\|_2 = \left\|A^{-1} \delta b\right\|_2 \leq \left\|A^{-1}\right\|_2 \|\delta b\|_2$ Esiste l'uguaglianza?

   Usando nuovamente la nota 3 il caso di uguaglianza, si verifica se il vettore $\delta b$ è proporzionale all'autovettore relativo all'autovalore massimo di $A^{-T} A^{-1} \Rightarrow \frac{1}{\sigma_{\min}}$. Dunque $\delta b = \epsilon U(:,n)$.

Quindi la stima è sharp, cioè ottimale dato che esiste l'uguale. In generale, è una stima pessimistica.

## 5.3 Risoluzione pratica $Ax = b$

Osservazione:

Se la matrice $A$ è triangolare superiore $\begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}$ o inferiore $\begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}$: So risolvere il problema.

### 5.3.1 Caso inferiore

$$a_{11} x_1 = b_1 \Rightarrow x_1 = \frac{b_1}{a_{11}} \qquad \text{(Sto ignorando i valori } 0\text{)}$$
$$a_{21} x_1 + a_{22} x_2 = b_2 \Rightarrow x_2 = \frac{b_2 - a_{21} x_1}{a_{22}}$$
$$\text{In generale: } x_1 = \frac{b_1}{a_1} \quad x_k = \boxed{\frac{b_k - \sum_{j=1}^{k-1} a_{k,j} x_j}{a_{k,k}}} \qquad \text{(algoritmo di sostituzione in avanti)}$$

### 5.3.2 Caso superiore

$$a_{nn} x_n = b_n \Rightarrow x_n = \frac{b_n}{a_{nn}}$$
$$\text{In generale: } x_k = \boxed{\frac{b_k - \sum_{j=k+1}^{n} a_{k,j} x_j}{a_{k,k}}} \qquad \text{(algoritmo sostituzione all'indietro)}$$

## 5.4 Fattorizzazione

Dato che le matrici triangolari sono poche, si usa il metodo di eliminazione gaussiana, per ottenerne di più.

**Definizione 14: Fattorizzazione**

Il metodo di eliminazione gaussiana si può vedere come **fattorizzazzione** di matrice. La fattorizzazione $LU$ tale che $A = LU$ dove $L$ sta per "lower triangular" invertibile e $U$ "upper triangular" invertibile.

A cosa serve una fattorizzazione di questo tipo?

$$Ax = b \Leftrightarrow \underset{\text{associativo}}{LUx} = b$$

Faccio un cambio di variabile $y = Ux$ e ottengo:

- $Ly = b$ posso calcolare $y$ con la sostituzione in avanti.
- $Ux = y$ posso calcolare $x$ con la sostituzione all'indietro.

Rendiamo algoritmico il metodo di eliminazione gaussiana (MEG):

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) = \mathbb{1} - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \quad m^{(k)} \in \mathbb{R}^{n-k}$$

**Nota 4**

$\begin{pmatrix} 0 \\ \\ m^k \end{pmatrix}$ è una matrice con tutti $0$ tranne la parte sotto la diagonale della $k$-esima colonna che ha da $m_1^k$ a $m_{n-k}^k$.
Se moltiplicata con $e_k^T$, si ottiene la matrice:

$$\begin{pmatrix} 1 & 0 & \dots & \dots & 0 \\ m_1^1 & 1 & 0 & & \vdots \\ \vdots & m_1^2 & \ddots & \ddots & \vdots \\ \vdots & \vdots & \ddots & 1 & 0 \\ m_{n-1}^1 & m_{n-2}^2 & \dots & m_1^{n-1} & 1 \end{pmatrix}$$

È **triangolare superiore** e la chiamo $L$.

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & 1 & \vdots \\ 0 & -m^{(k)} & 1 \end{pmatrix}$$

Nella $k$-esima colonna ci metto $-m^{(k)}$ per questo è lunga $n-k$, sono gli elementi sotto la diagonale.

Cosa succede se faccio $\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)\cdot A$?

$$\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)A=\left(\mathbb{1}_n-\begin{pmatrix}0\\ \\ m^k\end{pmatrix}e_k^T\right)A\underset{prop.assoc.}{=}A-\begin{pmatrix}0\\ \\ m^k\end{pmatrix}\underbrace{e_k^TA}_{k\text{-esima riga di }A}$$

$$=A-\begin{pmatrix}0\\ \\ m^k\end{pmatrix}A(k,:)=A-\begin{pmatrix}0 & \dots & 0\\ 0 & \dots & k\text{ righe}\\ m_1^kA(k,1) & \dots & m_1^kA(k,n)\\ \vdots & & \vdots\\ m_{n-k}^kA(k,1) & \dots & m_{n-k}^kA(k,n)\end{pmatrix}$$

Ossia ad ogni riga di $A$ da $k+1$ a $n$ togliamo la $k$-esima riga di $A$ moltiplicata per $m_1^k,\dots,m_{n-k}^k$ (**moltiplicatori**). Nel MEG scelgo i moltiplicatori per eliminare tutta la parte sottodiagonale di $A$ nella colonna $k$-esima.

La colonna $k$-esima di $\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)A$ è:

$$A(:,k)-\begin{pmatrix}0\\ k\text{ volte}\\ 0\\ m_1A(k,k)\\ \vdots\\ m_{n-k}^kA(k,k)\end{pmatrix}=\left(\begin{array}{c}A(1,k)\\ \vdots\\ A(k,k)\\ \hline A(k+1,k)-m_1^kA(k,k)\\ \vdots\\ A(n,k)-m_{n-k}^kA(k,k)\end{array}\right)$$

La parte bassa è quella che voglio annullare. Per far ciò devo "scegliere" $m$ nel seguente modo:

$$\circledast\quad m_l^k=\frac{A(k+l,k)}{A(k,k)}$$

Devo verificare che $A(k,k)\neq 0$, ossia la diagonale diversa da zero, perchè potrebbe esserci il caso:

**Esempio 9: Problema Diagonale $=0$**

$A=\begin{pmatrix}0 & 1\\ 1 & 0\end{pmatrix}$ $\det(A)=-1$ La matrice è invertibile nonostante la diagonale $=0$.

Ipotesi: Per il momento supponiamo che $A(k,k)\neq 0$.
Poniamo $\widetilde{\mathrm{L}}^{(k)}=\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)$ con $m^k$ scelto come in $\circledast$.

### 5.4.1 Algoritmo Instabile

$A^{(1)}=A$

$A^{(k)}=\widetilde{\mathrm{L}}^{(k-1)}A^{(k-1)}$ Quello $k$-esimo è dato da quello $(k-1)$-esimo

Se vale l'ipotesi ad ogni passo: $\boxed{A^{(k-1)}(k-1,k-1)\neq 0}$. Dopo $n-1$ passi avrò:

$$A^n=\widetilde{\mathrm{L}}^{(n-1)}A^{(n-1)}=\widetilde{\mathrm{L}}^{(n-1)}\widetilde{\mathrm{L}}^{(n-2)}A^{(n-2)}\cdots=\widetilde{\mathrm{L}}^{(n-1)}\dots\widetilde{\mathrm{L}}^{(1)}A$$

La matrice $A^n$ sarà, quindi, una triangolare superiore; perchè al primo passo abbiamo preso la colonna $1$ di $A$ ed eliminato la sua parte sotto la diagonale. Quindi $A^{(2)}$ ha la colonna $1$ con la parte sottodiagonale **nulla**. Poi $A^{(3)} = \widetilde{\mathrm{L}}^{(2)} A^2 = \left( \mathbb{1} - \begin{pmatrix} 0 \\ \\ m^2 \end{pmatrix} e_2^T \right) A^2 = A^2 - \begin{pmatrix} 0 \\ \\ m^2 \end{pmatrix} e_2^T A^{(2)}$ e dato che $A^2$ ha la prima colonna sottodiagonale $0$ e viene sottratta ad una cosa che ha la prima colonna tutto $0$. Quindi anche $A^{(3)}$ ha la prima colonna sottodiagonale $0$ e in più anche la seconda colonna ha la stessa proprietà per $\circledast$.
Iterando questo ragionamento otteniamo che $A^{(n)}$ ha le colonne $1, 2, \dots, n-1$ che rispettano la stessa proprietà. Di conseguenza è **triangolare superiore**.

Pongo $U = A^{(n)}$, ossia $U = \widetilde{\mathrm{L}}^{(n-1)} \widetilde{\mathrm{L}}^{(n-2)} \dots \widetilde{\mathrm{L}}^{(1)} A$ Dato che ogni $\widetilde{\mathrm{L}}^{(k)}$ è invertibile e voglio ottenere $LU = A$, divido per $L$:

$$\left(\widetilde{\mathrm{L}}^{1}\right)^{-1} \left(\widetilde{\mathrm{L}}^{2}\right)^{-1} \dots \left(\widetilde{\mathrm{L}}^{(n-1)}\right)^{-1} U = A$$

Adesso devo:

- calcolare $\left(\widetilde{\mathrm{L}}^{(k)}\right)^{-1}$
- calcolare il prodotto
- mostrare che è triangolare inferiore

$$\widetilde{\mathrm{L}}^{(k)} = \widetilde{\mathcal{L}}^{(k)} \left(m^{(k)}\right) \text{ con } m^{(k)} \text{ scelto secondo } \circledast$$

$$\widetilde{\mathcal{L}}^{(k)} \left(m^{(k)}\right) \cdot \widetilde{\mathcal{L}}^{(k)} \left(-m^{(k)}\right) = \left( \mathbb{1} - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \right) \left( \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \right)$$

$$= \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T - \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T - \underbrace{\begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T}_{\triangle}$$

$$\begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T = \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} \underbrace{\left[ e_k^T \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} \right]}_{\text{scalare}} e_k^T$$

$$\triangle = \left[ e_k^T \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} \right] \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T$$

Cosa significa fare $e_k^T \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix}$, vuol dire: $\begin{pmatrix} 0 & \dots & 0 & \underbrace{1}_{k} & 0 & \dots & 0 \end{pmatrix} \cdot \begin{pmatrix} 0 \\ \vdots \\ \underbrace{0}_{k} \\ m_1^k \\ \vdots \\ m_{n-k}^k \end{pmatrix} = 0$

$\triangle = 0s \Rightarrow \ \widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right) \cdot \widetilde{\mathcal{L}}^{(k)}\left(-m^{(k)}\right) = \mathbb{1}$

Dunque, abbiamo dimostrato che una è l'inversa dell'altra, e

$$\mathrm{L}^{(k)} := \left(\widetilde{\mathrm{L}}^{(k)}\right)^{-1} = \left(\widetilde{\mathcal{L}}^{(k)}\left(m^{(k)}\right)\right) = \left(\widetilde{\mathcal{L}}^{(k)}\left(-m^{(k)}\right)\right) = \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T$$

Adesso passo al secondo punto, ossia calcolare i prodotti:

$$\mathrm{L}^k \cdot \mathrm{L}^{k+1} = \left(\mathbb{1} + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T\right) \cdot \left(\mathbb{1} + \begin{pmatrix} 0 \\ \\ m^{k+1} \end{pmatrix} e_{k+1}^T\right)$$

$$= \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^{k+1} \end{pmatrix} e_{k+1}^T + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T + \underbrace{\begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T \begin{pmatrix} 0 \\ \\ m^{k+1} \end{pmatrix} e_{k+1}^T}_{\text{Come prima } = 0}$$

$$\mathrm{L}^k \cdot \mathrm{L}^{k+1} = \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^k \end{pmatrix} e_k^T + \begin{pmatrix} 0 \\ \\ m^{k+1} \end{pmatrix} e_{k+1}^T$$

Volevamo calcolare:

$$\left(\widetilde{\mathrm{L}}^1\right)^{-1} \left(\widetilde{\mathrm{L}}^2\right)^{-1} \dots \left(\widetilde{\mathrm{L}}^{(n-1)}\right)^{-1} = \mathrm{L}^1 \, \mathrm{L}^2 \dots \mathrm{L}^{n-1}$$

$$= \mathbb{1} + \begin{pmatrix} 0 \\ \\ m^1 \end{pmatrix} e_1^T + \begin{pmatrix} 0 \\ \\ m^2 \end{pmatrix} e_2^T \dots \begin{pmatrix} 0 \\ \\ m^{n-1} \end{pmatrix} e_{n-1}^T$$

Se vale l'**ipotesi** iniziale ad ogni passo e scelgo gli $m$ secondo $\circledast$ ottengo $A = LU$, come volevamo ✓.

Osservazione: Se $A^{(k)}(k,k)$ detto **Pivot**, è molto piccolo in modulo. La scelta $\circledast$, causa moltiplicatori molto grandi e le sottrazioni per eliminare gli elementi sottodiagonali, diventano fortemente **instabili**.

Conclusione: $LU$ così non può essere calcolato.

Osservazione: La limitazione che deriva dall'**ipotesi** si può rimuovere scambiando la $k$-esima riga con quella $l$-esima con $l > k$. $\exists$ sicuramente $l > k : \ A^{(K)}(l,k) \neq 0$.

## 5.5 Fattorizzazione con Pivoting

**Definizione 15: Matrice di Permutazione**

Sia $P \in M_{n\times n}(\mathbb{R}) : \ P_{ij} = \begin{cases} 1 \\ 0 \end{cases}$ Tale per cui esiste una permutazione $\sigma$ dell'insieme $\{1, 2, \dots, n\}$, può essere associata alla matrice

$$P_{ij} := \begin{cases} 1 \text{ se } j = \sigma(i) \\ 0 \text{ altrimenti} \end{cases}$$

Ossia la matrice che si ottiene permutando con $\sigma$ le righe di $\mathbb{1}_n$.

Le matrici di permutazione hanno delle proprietà notevoli:

1. Se $P, Q$ sono matrici di permutazione $\Rightarrow PQ, QP$ sono di permutazione.
2. $PP^T = P^TP = \mathbb{1}_n$ sono **ortogonali**.
3. $\det P = \pm 1$ quelle con determinante positivo/negativo sono dette **pari/dispari**.
4. Se $\sigma$ è lo scambio di due elementi, allora $P$ è detta di scambio e $P = P^T = P^{-1}$

Se $P$ è una matrice di permutazione che rappresenta $\sigma$ ed $A$ ha dimensione uguale a $P$, allora

- $AP_\sigma = A$ (moltiplicazione a destra) significa permutare le colonne di $A$, ossia $(AP_\sigma)_{:,j} = A_{:,\sigma(j)}$
- $P_\sigma A = A$ (moltiplicazione a sinistra) significa permutare le righe di $A$, ossia $(P_\sigma A)_{i,:} = A_{\sigma(i),:}$

Le permutazioni più semplici sono gli scambi, se $\sigma$ è uno scambio $(k \to l, l \to k)$, allora vuole dire che $P_\sigma$ ha la diagonale con tutti $1$ e alla riga $k$ colonna $l$ ho $1$ e anche alla riga $l$ colonna $k$, mentre il resto rimane uguale. Equivale a prendere $\mathbb{1}$ ed effettuare lo scambio o su righe o su colonne.

Se si aggiunge nel vecchio algoritmo la possibilità di scambiare le righe, ossia il **pivoting parziale** $\times$ righe; si passa da:

$$\begin{aligned} A^1 &= A \\ A^k &= \widetilde{\mathrm{L}}^{(k-1)} A^{(k-1)} \quad k = 2 \dots n \end{aligned}$$

e diventa:

$$\begin{aligned} \widetilde{A}^1 &= A \\ A^1 &= P^1 A \\ \widetilde{A}^k &= \widetilde{L}^{(k-1)} A^{k-1} \\ A^k &= P^k \widetilde{A}^k \end{aligned}$$

Ossia ad ogni passo permuto e mi calcolo i moltiplicatori. Successivamente calcolo $\widetilde{L}^{(k-1)}$, poi moltiplico.

Lo scambio permette di avere la possibilità di calcolo. La strategia di scelta del **pivot** ci consente di non averne uno troppo piccolo, che nel caso non andrebbe bene dato che ci uscirebbe un moltiplicatore grande e avremmo una sottrazione tra due numeri grandi.

Scelgo, quindi, $l > k \ : \ |A(l,k)| = \max_{p>k} |A(p,k)|$, ossia scelgo la riga in modo che il suo elemento nella posizione $k$ sia massimo in modulo rispetto agli elementi sotto la diagonale in una certa colonna.

$P^k$ è una matrice che scambia la riga $k$ con una sucessiva, e sarà fatta nel seguente modo:

$$P^k = \begin{pmatrix} \mathbb{1}_{k-1} & \mathbb{0}_{k-1,n-(k-1)} \\ \mathbb{0}_{n-(k-1),k-1} & \widetilde{P}^{(k)}_{n-(k-1)} \end{pmatrix}$$

ossia le prime $k-1$ righe/colonne restano identiche si ha quindi $\mathbb{1}_{k-1}$ e il restante della riga è $0$. Ad una determinata riga $l$ alla posizione $k$ avrò un $1$ (lo stesso vale per riga $k$ elemento $l$), mentre sulla stessa riga nella

diagonale invece che $1$ ci sarà uno $0$. E il resto continua con la matrice diagonale.
La matrice di scambio, opera soltanto sulla parte inferiore della colonna dei moltiplicatori, permettendo di permutare i coefficienti di Gauss senza rovinare la struttura inferiore triangolare dell'algoritmo.

Moltiplicandolo con $\widetilde{\mathrm{L}}^{k-1}$ che ha elementi non nulli sono nella colonna $k-1$, ossia:

$$\begin{pmatrix} \mathbb{1}_{k-1} & \mathbb{0}_{k-1,n-(k-1)} \\ M^{(k-1)} & \mathbb{1}_{n-(k-1)} \end{pmatrix}$$

Ossia nella colonna $k-1$ sotto la diagonale, ci saranno i moltiplicatori $m$, ovviamente sulle colonne a sinistra dei moltiplicatori, cè $0$.

Quindi

$$P^k \cdot \widetilde{\mathrm{L}}^{k-1} = \begin{pmatrix} \mathbb{1}_{k-1} & \mathbb{0}_{k-1,n-(k-1)} \\ d & \mathbb{1}_{n-(k-1)} \end{pmatrix}$$

Il termine sotto diagonale alla colonna $k$ è $m$ con la permutazione dell'elemento $1$ con $l-k$.

$$A^n = \widetilde{\mathrm{L}}^{(n-1)}\,\mathrm{P}^{(n-1)}\,\widetilde{\mathrm{L}}^{(n-2)}\,\mathrm{P}^{(n-2)}\ldots\widetilde{\mathrm{L}}^{(1)}\,\mathrm{P}^{(1)}\,A$$
$$P^2\widetilde{\mathrm{L}}^1\,\mathrm{P}^1 = \mathrm{P}^2\,\widetilde{\mathcal{L}}(m^1)\,\mathrm{P}^1 = \widetilde{\mathcal{L}}(\widetilde{m}^1)\,\mathrm{P}^2\,\mathrm{P}^1$$

In questo passaggio $\widetilde{\mathcal{L}}(m^1) = \widetilde{\mathcal{L}}(\widetilde{m}^1)$ ho fatto la permutazione degli elementi diagonali come descritto prima.

Iterando:

$$\mathrm{P}^{n-1}\,\widetilde{\mathrm{L}}^{n-2}\ldots\mathrm{P}^2\,\widetilde{\mathrm{L}}^1\,\mathrm{P}^1 = \widetilde{\mathcal{L}}^{(n-1)}(\widetilde{m}^{(n-1)})\ldots\widetilde{\mathcal{L}}^1(\widetilde{m}^1)\,\mathrm{P}^{n-1}\ldots\mathrm{P}^1$$

Dove gli $\widetilde{m}$ sono stati permutati con tutte le permutazioni che stavano alla loro sinistra.

Nota : Le $\widetilde{\mathcal{L}}$ adesso, le so moltiplicare ed invertire.

Ottengo quindi:

$$\underbrace{\mathrm{L}^1\ \ldots\ \mathrm{L}^{(n-1)}}_{\text{Triang. inf.}}\underbrace{A^n}_{U} = \underbrace{\mathrm{P}^{n-1}\ \ldots\ \mathrm{P}^1}_{\text{Permutazione }\mathbb{P}}A$$

Dove $U$ è, ovviamente, triangolare superiore.

Abbiamo ottenuto quindi:

**Definizione 16: Pivoting**

Fattorizzazione $LU$ con pivoting parziale per righe del tipo:

$$\boxed{LU = PA}$$

Quindi

$$Ax = b \Leftrightarrow PAx = Pb \text{ e } LUx = Pb$$

Adesso risolviamo $Ly = Pb$ e poi $Ux = y$ usando la sostituzione in avanti e all'indietro.
**FINE algoritmo** con pivoting.

### 5.5.1 Complessità Fattorizzazione $LU$

La Fattorizzazione ha costo totale "pessimistico":

$$\sum_{k=1}^{n-1}\left[(n-k) + 2(n-k)^2\right] = \boxed{0(n^3)}$$

Di cui $(n-k)$ è dato dalle divisioni, mentre $2(n-k)^2$ è dato dalle moltiplicazioni $+$ le somme.

**Osservazione**: In moltissime applicazioni le matrici sono sparse, ossia molti elementi sono nulli.

**Nota 5: Matrici Sparse**

Una successione di matrici $A^{(n)} \in M_{n\times n}(\mathbb{R})$ è **sparsa** se $nz\left(A^{(n)}\right) = O(n)$, dove $nz$ sta per gli elementi non-zero.

## 5.6 Metodi per sistemi lineari

Ci sono due metodi principali: quello **diretto** come la fattorizzazione $LU$, visto in precedenza; oppure i metodi **iterativi**.

**Idea** dei metodi iterativi per la soluzione dei sistemi lineari:

> Creare una successione di approssimazioni della soluzione in modo iterativo con basso costo computazionale della singola iterazione.

**Definizione 17: Metodo iterativo lineare stazionario**

Dato un sistema lineare $Ex + q$, dove $E, q$ sono **costanti** e partendo da un vettore iniziale $x^{(0)}$. Assume la forma:

$$x^{(k+1)} = \mathrm{F}_k(x^k) = \mathrm{E}\,x^{(k)} + q$$

La matrice $\mathrm{E}$ si dice **matrice di iterazione**.

- $\exists\, x^* \in \mathbb{R}^n :\ x^{(k)} \to x^*$ se $k \to +\infty$ per qualche norma $\|\cdot\|$ si ha che:

$$\lim_{k\to+\infty} \left\|x^{(k)} - x^*\right\| = 0$$

  Se vale la convergenza in una norma allora vale per tutte perchè siamo in uno spazio vettoriale finito.

- Vogliamo che $Ax^* = b$ (**consistenza**)

Lo studio di questi aspetti avviene tramite il Lemma delle contrazioni.

**Definizione 18: Contrazione**

Sia una funzione $\mathrm{F} :\ \mathbb{R}^n \to \mathbb{R}^n$ se esiste $0 \le \mathrm{L} < 1$, tale che (per una data norma $\|\cdot\|$)

$$\|\mathrm{F}(x) - \mathrm{F}(y)\| \le \mathrm{L}\cdot\|x - y\| \quad \forall x, y \in \mathbb{R}^n$$

Allora $\mathrm{F}$ è una **contrazione** di parametro $\mathrm{L}$ rispetto alla norma $\|\cdot\|$.

**Osservazione**: Se $\mathrm{F}$ è contrazione, allora è anche continua.

**Teorema 3: Lemma delle contrazioni**

Sia $\mathrm{F} :\ \mathbb{R}^n \to \mathbb{R}^n$ contrazione rispetto alla norma $\|\cdot\|$ della costante $0 \le \mathrm{L} < 1$. Allora vale:

1. Esiste $x^* \in \mathbb{R}^n$ ed è l'unico punto fisso di $\mathrm{F}$, ossia $\mathrm{F}(x^*) = x^*$
2. $\forall x^{(0)} \in \mathbb{R}^n$ la successione $\begin{cases} x^{(0)} & \text{Dato} \\ x^{(k+1)} = \mathrm{F}(x^k) \end{cases}$ converge a $x^*$
3. Se $e^{(k)} = \left\|x^{(k)} - x^*\right\|$ vale

$$e^{(k)} \le \mathrm{L}\,e^{k-1} \le \mathrm{L}^2\,e^{(k-2)} \cdots \le \mathrm{L}^k\,e^{(0)}$$

E si chiama **convergenza geometrica lineare**, ossia ad ogni passo l'errore viene dimezzato.

**Richiami**: Ricordiamo da analisi 1 che $\mathbb{R}$ è completo ($\Rightarrow (\mathbb{R}, \|\cdot\|)$ è completo) e una:

$$\text{successione è convergente} \Leftrightarrow \text{È successione di cauchy}$$

$x^k$ è di **cauchy** in $\mathbb{R}$ se $\forall \epsilon > 0\ \exists k_\epsilon$ tale che se $l, m > k$ allora $\left|x^l - x^m\right| < \epsilon$, ossia avanzando con l'indice della successione la differenza tra gli elementi, diminuisce continuamente.

Dimostrazione: Siano $l, m > 0$ con $l > m$ interi. Studio:

$$\begin{aligned}\left\|x^{k+l} - x^{k+m}\right\| &= \left\|x^{k+l} - x^{k+l-1} + x^{k+l-1} \dots x^{k+m+1} - x^{k+m}\right\| \\ &\leq \left\|x^{k+l} - x^{k+l-1}\right\| + \left\|x^{k+l-1} - x^{k+l-2}\right\| + \dots + \left\|x^{k+m+1} - x^{k+m}\right\| \\ x^{k+1} - x^k &:= S^k \quad \text{scarto}\end{aligned}$$

Usando questa notazione, si può maggiorare la distanza tra due elementi della successione $x^{k+l}, x^{k+m}$, sommando gli scarti intermedi:

$$\boxed{\left\|x^{k+l} - x^{k+m}\right\| \leq \sum_{j=0}^{l-m-1} \left\|S^{k+m+j}\right\|} \quad \circledast$$

Come posso stimare $\left\|S^k\right\|$?

$$\begin{aligned}\left\|S^k\right\| = \left\|x^{k+1} - x^k\right\| &\underset{\text{p.2 lemma}}{=} \left\|\mathrm{F}(x^k) - \mathrm{F}(x^{k-1})\right\| \\ \text{da def. contrazione} \leq \mathrm{L}\left\|x^k - x^{k-1}\right\| &\underset{\text{p.2 lemma}}{=} \mathrm{L}\left\|\mathrm{F}(x^{k-1}) - \mathrm{F}(x^{k-2})\right\| \\ \text{da def. contrazione} \leq \underbrace{\mathrm{L}\cdot\mathrm{L}\left\|x^{k-1} - x^{k-2}\right\| \dots}_{k\text{-volte}} &\leq \boxed{\mathrm{L}^k \cdot \|S_0\|} \quad \blacktriangle\end{aligned}$$

$$\circledast \text{ unito a } \blacktriangle = \left\|x^{k+l} - x^{k+m}\right\| \leq \sum_{j=0}^{l-m-1} \mathrm{L}^{k+m+j} \cdot \|S_0\|$$

$$= \mathrm{L}^{k+m} \|S_0\| \sum_{j=0}^{l-m-1} L^j$$

Quest'ultima sommatoria è una serie geometrica che converge a $\frac{1}{1-\mathrm{L}}$ dato che la ragione è: $0 \leq \mathrm{L} < 1$.
Inoltre dato che $m$ può essere come minimo $1$, posso porre $\mathrm{L}^{k+m} \leq \mathrm{L}^{k+1}$:

$$< \mathrm{L}^{k+m} \|S_0\| \frac{1}{1-\mathrm{L}} \leq \mathrm{L}^{k+1} \frac{\|S_0\|}{1-\mathrm{L}} \quad \text{è} < \text{di } \epsilon\text{? Per un certo } k \text{ grande}$$

Adesso risolvo la disuguaglianza $\mathrm{L}^{k+1} \frac{\|S_0\|}{1-\mathrm{L}} < \epsilon$

$$\mathrm{L}^{k+1} < \frac{\epsilon(1-\mathrm{L})}{\|S_0\|}$$

uso i logaritmi

$$(k+1) \cdot \log \mathrm{L} < \log\left(\frac{\epsilon(1-\mathrm{L})}{\|S_0\|}\right)$$

$$\Rightarrow \; k+1 > \frac{\log\left(\frac{\epsilon(1-\mathrm{L})}{\|S_0\|}\right)}{\log \mathrm{L}}$$

Viene cambiato il segno da $<$ a $>$ perchè il $\log$ di $\mathrm{L}$, ossia una quantità minore di $1$ da segno negativo. Quindi $x^k$ è **successione di cauchy**, perchè se prendo un $k$ sufficientemente grande $\lim_{k\to\infty} \mathrm{L}^{k+1} = 0$ e rispetta la definizione di successione di **cauchy** dato che:

$$\left\|x^{k+l} - x^{k+m}\right\| \leq \mathrm{L}^{k+1} \frac{\|S_0\|}{1-\mathrm{L}} < \epsilon \quad \Rightarrow \left\|x^l - x^m\right\| < \epsilon \text{ (def. succ. cauchy)}$$

Sia $x^*$ il suo limite. Dimostro che $x^*$ è unico punto fisso di $\mathrm{F}$:

$$x^* \underset{\text{da def.}}{=} \lim_{k\to\infty} x^k = \lim_{k\to\infty} x^{k+1} \underset{\text{def. succ.}}{=} \lim_{k\to\infty} \mathrm{F}(x^k) \underset{\text{se F continua}}{=} \mathrm{F}\left(\lim_{k\to\infty} x^k\right)$$

So che $\mathrm{F}$ è continua dalla definizione.

$= \mathrm{F}(x^*) = x^* \quad \checkmark$

Quindi $x^*$ è punto fisso.
Adesso devo dimostrare che è unico: Sia $y^*$ punto fisso di $\mathrm{F}$

$$\underbrace{\|x^* - y^*\|}_{\text{distanza p. fissi}} = \|\mathrm{F}(x^*) - \mathrm{F}(y^*)\|$$

$$\leq \mathrm{L} \cdot \|x^* - y^*\| < \|x^* - y^*\| \quad \textbf{assurdo}$$

Quindi $x^* = y^*$, ossia $x^*$ è unico punto fisso di $\mathrm{F}$.

Dimostro che l'errore di una qualsiasi iterazione rispetto al limite della successione decresce:

$$\begin{aligned} e^{(k)} &= \left\|x^k - x^*\right\| = \left\|\mathrm{F}(x^{k-1}) - \mathrm{F}(x^*)\right\| \\ &\leq \mathrm{L}\left\|x^{k-1} - x^*\right\| = \mathrm{L}\left\|\mathrm{F}\left(x^{k-2}\right) - \mathrm{F}\left(x^*\right)\right\| \\ &\leq \mathrm{L}^2\left\|x^{k-2} - x^*\right\| \leq \ldots\ \mathrm{L}^k\left\|x^0 - x^*\right\| = \mathrm{L}^k\, e^{(0)} \quad \checkmark \end{aligned}$$

Io voglio approssimare la soluzione del sistema lineare $Ax = b$ con $A \in M_{n\times n}(\mathbb{R})$ invertibile e $b \in \mathbb{R}^n$ dati. Dal fatto che $A$ è invertibile ottengo che $x = A^{-1}b$ voglio scrivere $\mathrm{F}$ in modo che questo sia il suo punto fisso. Quindi:

$$Ex + q = x$$
$$EA^{-1}b + q = A^{-1}b \Rightarrow \underset{\text{condizione per consistenza}}{(\mathbb{1} - E)\,A^{-1}b = q}$$

Soluzione banale: $E = \mathbb{1} - A \quad q = b$ (metodo di **Richardson**) consistenza verificata

### 5.6.1 Convergenza metodo di Richardson

Per la **convergenza**: Data una norma $\|\cdot\|$ su $\mathbb{R}^n$ e con $\mathrm{F}$ di Richardson

$$\begin{aligned} \|\mathrm{F}(x) - \mathrm{F}(y)\| &= \|Ex + q - Ey - q\| = \|E(x-y)\| \\ &\underset{\text{prop. norma ind.}}{\leq} \|E\|_*\,\|x - y\| \end{aligned}$$

Esiste il caso sharp, quindi la miglior costante $\mathrm{L}$ è $\|E\|_* = \|\mathbb{1} - A\|_* < 1$.

Il lemma delle contrazioni mi dice che ho convergenza se $A$ non è troppo distante da $\mathbb{1}$ (condizione molto stringente).

Usando **Richardson**, inoltre se $\|E\|_* < 1 \Rightarrow \forall x^0 \in \mathbb{R}^n \quad x^{(k)} \to x^*$ con $x^{(k)}$ punto fisso unico di $\mathrm{F}$:

$$\begin{aligned} x^* = \mathrm{F}\left(x^*\right) &= (\mathbb{1} - A)\,x^* + b = x^* - Ax^* + b \\ &\underset{\text{sottr. } x^*}{\Rightarrow} -Ax^* + b = 0 \Rightarrow Ax^* = b \end{aligned}$$

Quindi la successione è:

$$\begin{aligned} &x^{(0)} \\ &x^{(1)} = Ex^{(0)} + q \\ &x^{(2)} = Ex^{(1)} + q = E^2x^{(0)} + Eq + q \\ &\vdots \\ &x^{(k)} = E^kx^{(0)} + \sum_{j=0}^{k-1} E^jq \end{aligned}$$

Supponiamo che $E$ è diagonalizzabile, per **nota 2**:

$$E = P^{-1}\Lambda P \quad \text{con} \quad \Lambda = \begin{pmatrix} \lambda_1 & \ldots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \ldots & \lambda_n \end{pmatrix}$$

Di conseguenza la successione diventa:

$$x^{(k)} = \left(P^{-1}\Lambda P\right)^k x^0 + \sum_{j=0}^{k-1} \left(P^{-1}\Lambda P\right)^j q$$

$$E^2 = P^{-1}\Lambda \underbrace{P \cdot P^{-1}}_{\mathbb{1}} \Lambda P = P^{-1}\Lambda^2 P = P^{-1} \begin{pmatrix} \lambda_1^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n^2 \end{pmatrix} P$$

$$E^j = \overbrace{P^{-1}\Lambda \underbrace{P \cdot P^{-1}}_{\mathbb{1}} \Lambda P \dots P^{-1}\Lambda P}^{j\text{-volte}} = P^{-1} \overbrace{\Lambda \dots \Lambda}^{j\text{-volte}} P$$

Quindi

$$x^{(k)} = P^{-1}\Lambda^k P x^{(0)} + \sum_{j=0}^{k-1} P^{-1}\Lambda^j P q$$

$$Px^{(k)} = \Lambda^k P x^{(0)} + Pq \left(\sum_{j=0}^{k+1} \Lambda^j\right)$$

$$y^{(k)} := Px^{(k)} \quad s = Pq$$

$$y^{(k)} = \Lambda^k y^{(0)} + \left(\sum_{j=0}^{k-1} \Lambda^j\right) s$$

$$\begin{pmatrix} y_1^{(k)} \\ \vdots \\ y_n^{(k)} \end{pmatrix} = \begin{pmatrix} \lambda_1^k y_1^{(0)} \\ \vdots \\ \lambda_n^k y_n^{(0)} \end{pmatrix} + \begin{pmatrix} \sum_{j=0}^{k+1} \lambda_1^j \cdot s_1 \\ \vdots \\ \sum_{j=0}^{k+1} \lambda_n^j \cdot s_n \end{pmatrix}$$

$$= \lambda_i^k y_i^{(0)} + \underbrace{\boxed{\frac{1-\lambda_i^k}{1-\lambda_i}}}_{\text{serie geom.}} s_i$$

Se $|\lambda_i| < 1 \; \forall i = 1 \dots n$, allora il limite di questa espressione per $k \to +\infty$ è

$$0 \cdot y_i^{(0)} + \frac{1}{1-\lambda_i} s_i$$

Dimostriamo che $y^{(k)}$ tende a:

$$\begin{pmatrix} \frac{1}{1-\lambda_1} s_1 \\ \vdots \\ \frac{1}{1-\lambda_n} s_n \end{pmatrix} =: y^*$$

$$\begin{aligned}
\left\|y^{(k)}-y^*\right\|_\infty &= \max_i \underbrace{|\lambda_i^k y_i^{(0)} + \frac{1-\lambda_i^k}{1-\lambda_i}s_i}_{y^{(k)}} - \underbrace{\frac{1}{1-\lambda_i}s_i}_{y^*}| \\
&= \max_i \left|\lambda_i^k y_i^{(0)} - \frac{\lambda_i^k}{1-\lambda_i}s_i\right| \\
&\le \max_i \left(\left|\lambda_i^k\right| \cdot \left|y_i^{(0)}\right| + \frac{\left|\lambda_i^k\right|}{|1-\lambda_i|}\left|s_i\right|\right) \\
&\le \left(\max_i |\lambda_i|\right)^k \cdot \underbrace{\left(\max_i \left|y_i^{(0)}\right|\right)}_{\text{costante } C} + \frac{\max_i \left|\lambda_i^k\right|}{\min_i \underbrace{|1-\lambda_i|}_{<0}} \underbrace{\max_i |s_i|}_{\text{costante } C}
\end{aligned}$$

$$C := \left(\max_i \left|y_i^{(0)}\right|\right) + \frac{\max_i |s_i|}{\min_i |1-\lambda_i|}$$

$$\left\|y^{(k)}-y^*\right\|_\infty \le \left(\max_i |\lambda_i|\right)^k \cdot C$$

Dato che $\lambda_i < 1 \ \forall i$, allora $\max_i |\lambda_i| < 1$ e se faccio il limite:

$$\lim_{k\to+\infty} \left\|y^{(k)}-y^*\right\|_\infty = \boxed{\lim_{k\to+\infty} \left(\max_i \left|\lambda_i^k\right|\right) \cdot C = 0}$$

Ossia $y^{(k)} \to y^*$. Avevamo però fatto un cambio di variabile.

Ora dobbiamo ridefinire $x^* =: P^{-1}y^*$ perchè $y^{(k)} = Px^{(k)}$, così possiamo determinare il limite con le variabili iniziali. Quindi calcoliamo la distanza:

$$\left\|x^{(k)}-x^*\right\| = \left\|P^{-1}y^{(k)} - P^{-1}y^*\right\| \le \left\|P^{-1}\right\| \cdot \underbrace{\left\|y^{(k)}-y^*\right\|}_{\Rightarrow 0 \ \ k\to+\infty}$$

Quindi dato che $P^{-1}$ è una matrice fissa, allora la sua norma è una costante. Ciò implica che

$$\lim_{k\to+\infty} \left\|x^{(k)}-x^*\right\| = 0 \quad \checkmark$$

Ho dimostrato che la successione iniziale **converge**.

Osservazione :

$$y^* = \begin{pmatrix} \frac{1}{1-\lambda_1} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \frac{1}{1-\lambda_n} \end{pmatrix} \cdot s = (\mathbb{1}-\Lambda)^{-1} s$$

allora $x^* = P^{-1}(\mathbb{1}-\Lambda)^{-1} s = P^{-1}(\mathbb{1}-\Lambda)^{-1} Pq \quad \circledast$.

Prediamo, quindi, $\lambda_i$ autovalore di $E = \mathbb{1} - A$, quindi $v_i$ è il suo autovettore tale che:

$$\begin{aligned}
&(\mathbb{1}-A)\, v_i = \lambda_i v_i \\
&v_i - Av_i = \lambda_i v_i \Rightarrow \quad Av_i = (1-\lambda_i)\, v_i
\end{aligned}$$

In questo modo abbiamo dimostrato che $v_i$ è autovettore di $A$ per la definizione di autovettore. Gli autovalori di $A$ sono $1-\lambda_i$ e definiamo $\lambda_i := 1-\sigma$.

Se $A$ è diagonalizzabile $Q^{-1}\Sigma Q$ con $\Sigma = \begin{matrix} \sigma_1 \\ & \ddots \\ & & \sigma_n \end{matrix}$ allora:

$$\mathbb{1} - A = Q^{-1}Q - Q^{-1}\Sigma Q = Q^{-1}(\mathbb{1}-\Sigma)\, Q$$

Quindi abbiamo dimostrato che se $Q$ diagonalizza $A$, diagonalizza anche $E \Rightarrow P = Q$.

Dato che $\lambda_i = 1 - \sigma_i$ allora $\Lambda = \mathbb{1} - \Sigma$.
Riprendiamo $\circledast$, ossia $x^* = P^{-1}\left(\mathbb{1} - \Lambda\right)^{-1} Pq \quad \circledast$:

$$\circledast \Rightarrow x^* = P^{-1}\left(\mathbb{1} - \underbrace{\left(\mathbb{1} - \Sigma\right)}_{\Lambda}\right)^{-1} Pb = P^{-1}\Sigma^{-1}Pb$$
$$= A^{-1}b$$
$$\text{Se } A = P^{-1}\Sigma P \Rightarrow A^{-1} = P^{-1}\Sigma^{-1}P$$

Questo dimostra per matrici:

A) Diagonalizzabili

B) $\rho(E) < 1$ dove $\rho(E)$ è il **raggio spettrale** e $\rho(E) = \max\{|\lambda_i|, \lambda_i \text{ autovalore}\}$, ossia il massimo autovalore

**Definizione 19: Serie di Neumann**

È la serie

$$\sum_{j=0}^{+\infty} E^j \overset{*}{=} \left(\mathbb{1} - E\right)^{-1}$$

La serie è sempre convergente se $\rho(E) < 1$.

Significa che:

$$\lim_{N \to +\infty} \left\| \sum_{j=0}^{N} E^j - \left(\mathbb{1} - E\right)^{-1} \right\| = 0 \quad \forall \|\cdot\| \text{ Norma di matrici}$$

L'ipotesi A) è "inutile". Si può replicare la dimostrazione usando

$$A = P^{-1} \begin{pmatrix} J_1 & & 0 \\ & \ddots & \\ 0 & & J_n \end{pmatrix} P \quad \text{con } J_i = \begin{pmatrix} \lambda & 1 & & 0 \\ & \ddots & \ddots & \\ 0 & & \lambda & 1 \end{pmatrix}$$

Si calcola $J^k$ e $\left(\mathbb{1} - J\right)^{-1}$ come sono fatti e si ripete la stessa dimostrazione fatta con le matrici Diagonalizzabili.

Corollario:
Se $\rho(E) < 1$ prendo $\epsilon < 1 - \rho(E)$ $\exists \|\cdot\|$ su $\mathbb{R}^n$ che induce $\|\cdot\|_*$ con $\|E\|_* \leq \rho(E) + \epsilon < \rho(E) + 1 - \rho(E) = 1$.

## 5.7 Splitting Classico

Per risolvere i sistemi $Ax = b$, dato che è difficile fare in modo che la matrice di iterazione ottenuta da Richardson soddisfi $\rho(E) < 1$, si usa quindi la notazione

$$\boxed{A = L + D + U}$$

Dove $L$ è una matrice diagonale inferiore, $U$ una matrice diagonale superiore e $D$ la diagonale principale.
L'idea alla base dei metodi iterativi basati su questa scomposizione, è di scrivere $A$ come $A = P - N$ dove $P$ è la matrice **precondizionata** scelta dal metodo. Si deve calcolare la matrice di **iterazione** $E$ e il vettore $q$.
L'equazione iterativa sarà $x^{(k+1)} = Ex^{(k)} + q$.

### 5.7.1 Metodo di Jacobi

Si sceglie di isolare solo la diagonale. Se $D_{ii} \neq 0 \; \forall i = 1, \ldots, n$ (invertibile), $P = D$, $E = \left(\mathbb{1} - D^{-1}A\right)$ e $q = D^{-1}b$. Quindi la successione diventa:

$$\begin{cases} x^0 \\ x^{k+1} = \underbrace{\left(\mathbb{1} - D^{-1}A\right)}_{E} x^k + \underbrace{D^{-1}b}_{q} \end{cases}$$

Se gli elementi diagonali hanno ordini di grandezza molto diversi tra loro, il metodo può risultare instabile (problema di **scaling**).

### 5.7.2 Metodo di Gauss-Seidel

Si pone $P = D + L$, $E = \mathbb{1} - (D+L)^{-1} \cdot A$ e $q = (D+L)^{-1} \cdot b$, solo se $D + L$ è invertibile.
$\det(D+L) = \prod_i D_{ii} \neq 0$, come per Jacobi, tutti gli elementi della diagonale di $A$ devono essere $\neq 0$.

L'iterazione diventa quindi:

$$\begin{aligned} x^{(k+1)} &= \underbrace{\left(\mathbb{1} - (D+L)^{-1} A\right)}_{E} x^{(k)} + \underbrace{(D+L)^{-1} b}_{q} \\ &= \left(\mathbb{1} - (D+L)^{-1} \underbrace{(D+L+U)}_{A}\right) x^{(k)} + (D+L)^{-1} b \\ &= \left(\mathbb{1} - \mathbb{1} - (D+L)^{-1} U\right) x^{(k)} + (D+L)^{-1} b \\ &= \left(-(D+L)^{-1} U\right) x^{(k)} + (D+L)^{-1} b \\ &= (D+L)^{-1} \cdot \left(b - U x^{(k)}\right) \end{aligned}$$

Quindi $x^{(k+1)}$ è soluzione di $(D+L)\, x^{(k+1)} = \left(b - U x^{(k)}\right)$ e si calcola tramite la **sostituzione in avanti**.

### 5.7.3 I Teoremi di Gershgorin

**Definizione 20: Cerchio di Gershgorin**

Sia la matrice $A \in M_{n\times n}(\mathbb{R})$, il cui spettro (l'insieme di tutti i suoi autovalori) è l'unione della serie di cerchi:

$$\bigcup_{i=1}^{n} B\left(E_{ii}, \sum_{j\neq i} |E_{ij}|\right)$$

ossia il **cerchio di Gershgorin**.

Spiegazione: Per ogni riga $i$ della matrice, si costruisce un cerchio. Dove $B(x,r)$ è l'insieme: $\{z \in \mathbb{C} : |z-x| < r\}$, ossia l'intorno circolare con raggio $r = \sum_{j=1, j\neq i}^{n} |A_{ij}|$ e centro $x$, ossia l'elemento $i$-esimo della diagonale principale.

Si utilizza per localizzare gli autovalori di una matrice e garantire la convergenza di metodi iterativi (come Jacobi e Gauss).

**Esempio 10: Cerchio di Gershgorin**

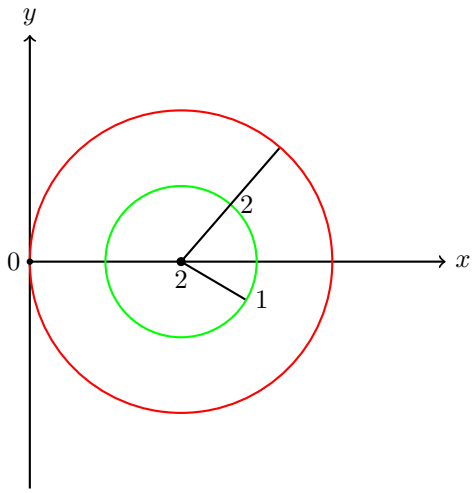
Prendiamo la matrice:

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$$

Se $\lambda$ è nello spettro di $A$.

Allora $\lambda \in B(\underset{A_{11}}{2}, \underset{|-1|+|0|}{1}) \cup B(2,2) \cup B(2,1)$

Grafico




**Definizione 21: Matrice Strettamente dominante**

Una matrice si dice strettamente diagonalmente dominante per righe, se:

$$|A_{ii}| > \sum_{j \neq i}^{n} |A_{ij}| \quad \forall i = 1, \dots, n$$

Per ogni riga, il valore assoluto dell'elemento sulla diagonale è strettamente maggiore della somma dei valori assoluti di tutti gli altri elementi della stessa riga.

Per queste matrici possiamo stimare lo spettro di $E$ per il metodo di Jacobi, dato che sono sicuramente invertibili.

$$E = \mathbb{1} - D^{-1}A \quad D_{ii} = A_{ii} \quad \delta_{ij} = 0 \text{ se } i \neq j \text{ altrimenti } 1$$

$$\begin{aligned} E_{ij} &= \delta_{ij} - \sum_{k=1}^{n} \left(D^{-1}\right)_{ik} A_{kj} \\ &= \delta_{ij} - \sum_{k=1}^{n} \frac{\delta_{ik}}{A_{ii}} A_{kj} \\ &= \delta_{ij} - \frac{A_{ij}}{A_{ii}} \begin{cases} \text{se } i = j \text{ vale } 0 \\ \text{se } i \neq j \text{ vale } -\frac{A_{ij}}{A_{ii}} \end{cases} \end{aligned}$$

Ora applichiamo i **cerchi di Gershgorin**. Dato che la diagonale di $E$ è composta da soli zeri, il centro dei cerchi è sempre $0$. mentre il raggio $r = \sum_{j \neq i} \frac{|A_{ij}|}{|A_{ii}|}$. Quindi i cerchi sono:

$$\lambda_E \in \bigcup_{i=1}^{n} B\left(0, \sum_{j \neq i} \frac{|A_{ij}|}{|A_{ii}|}\right)$$

Se $A$ è strettamente diagonalmente dominante allora ogni cerchio ha raggio $< 1$ perchè:

$$|A_{ii}| > \sum_{j \neq i}^{n} |A_{ij}| \quad = \quad 1 > \sum_{j \neq i}^{n} \frac{|A_{ij}|}{|A_{ii}|}$$

Di conseguenza dato che gli autovalori $\lambda$ stanno dentro il cerchio di raggio $< 1$ allora $\rho(E) < 1$. **Jacobi converge**.

Proposizione: Se $A \in M_{n \times n}(\mathbb{R})$ è simmetrica e definita positiva allora il metodo Gauss-Seidel è convergente $\forall x^0 \in \mathbb{R}^n$, ossia $\rho(E) < 1$.

Dimostrazione:

$$\begin{aligned} E &= \mathbb{1} - (L+D)^{-1} A \qquad \text{se } A \text{ è simmetrica } U = L^T \text{, se è definita positiva allora } A_{ii} > 0 \\ &= \mathbb{1} - (L+D)^{-1} \left(L + D + L^T\right) \\ &= \mathbb{1} - \mathbb{1} - (L+D)^{-1} L^T \end{aligned}$$

Sia $v$ un autovettore di $E$ con autovalore $\lambda \in \mathbb{R}$.

$$\begin{aligned} &Ev = \lambda v \quad \Rightarrow \quad -(L+D)^{-1} L^T \cdot v = \lambda v \\ &-L^T v = \lambda (L+D) v \\ &-v^H L^T v = \lambda \left(v^H L v + v^H D v\right) \\ &v^H L^T v = l \in \mathbb{C} \\ &v^H D v = r \in \mathbb{R} > 0 \end{aligned}$$

Osservazione: $v^H L^T v \neq v^H L v$, oppure $v^H L^T v = \overline{v^H L v}$.

$$\begin{aligned} \lambda &= \frac{-l}{\overline{l} + r} \\ |\lambda|^2 &= \frac{|l|^2}{|\overline{e} + r|^2} \quad \text{scriviamo } l = x + iy \\ &= \frac{x^2 + y^2}{|x - iy + r|^2} = \frac{x^2 + y^2}{(x+r)^2 + y^2} < 1 \end{aligned}$$

Quindi Gauss-Seidel converge grazie al lemma delle contrazioni e all'esistenza di una norma $\|\cdot\|$ tale che:

$$\|E\|_* \leq \rho(E) + \epsilon < 1$$

## 5.8 Prodotto Scalare

**Definizione 22: Prodotto Euclideo**

Dati due vettori $u, v$ su base canonica $e_i$:

$$u = \sum_{i=1}^{n} u_i e_i \quad \text{e} \quad v = \sum_{j=1}^{n} v_j e_j$$

allora

$$(u, v) = \sum_{i=1}^{n} u_i v_i$$

Linearità: ossia proprietà distibutiva rispetto alla somma

$$(u, v + w) = \sum u_i (v_i + w_i) = \sum u_i v_i + \sum u_i w_i$$

Se uso una base generica qualsiasi $b$, allora i vettori hanno nuove componenti $\widetilde{u}_i, \widetilde{v}_i$:

$$u = \sum_{i=1}^{n} \widetilde{u}_i b_i \quad \text{e} \quad v = \sum_{j=1}^{n} \widetilde{v}_j b_j \quad b_1, \ldots, b_n \text{ Base di } \mathbb{R}^n$$

$$(u, v) \neq \sum_{i=1}^{n} \widetilde{u}_i \widetilde{v}_i$$

**Definizione 23: Prodotto Scalare**

Sia la funzione $a(.\ ,\ .): \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$, si dice **prodotto scalare** se:

1. $a(u,v) = a(v,u)$ (**simmetrica**)
2. $a(u,u) \geq 0$ e $a(u,u) = 0 \Rightarrow u = 0$ (**definita positiva**)
3. $a(\alpha u + \beta v, w) = \alpha a(u,w) + \beta a(v,w) \quad a(u, \alpha v + \beta w) = \alpha a(u,v) + \beta a(u,w)$ (**bilineare**)

Si può scrivere anche come $u^T \mathbb{1} v = u^T v$.

Osservazione: Se $a(.\ ,\ .)$ è un prodotto scalare, allora:

$$\|u\|_a := \sqrt{a(u,v)} \quad \forall u \in \mathbb{R}^n$$

è una norma che si dice **indotta** da $a(.\ ,\ .)$.
Non tutte le norme derivano da un prodotto.

### 5.8.1 Rapporto tra prodotti e matrici

Se hai una funzione bilineare $a(\ .,\ .)$ che prende due vettori e restituisce un numero reale, e scegli una base $(b_1, \ldots, b_n)$ di riferimento per lo spazio vettoriale, esiste sempre una e una sola matrice che rappresenta completamente questa funzione.

Sia $a$ funzione bilineare $\mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$, fisso la base $b_1, \ldots, b_n$ in $\mathbb{R}^n$. Allora:

$$u = \sum_{i=1}^{n} u_i b_i \quad v = \sum_{j=1}^{n} v_j b_j$$

$$a(u,v) = a\left(\sum_{i=1}^{n} u_i b_i, \sum_{j=1}^{n} v_j b_j\right) \underset{\text{linearità 1 termine}}{=}$$

$$= \sum_{i=1}^{n} u_i\ a\left(b_i, \sum_{j=1}^{n} v_j b_j\right) \underset{\text{linearità 2 termine}}{=} \sum_{i=1}^{n} u_i \sum_{j=1}^{n} v_j\ a(b_i, b_j)$$

$$= \sum_{i=1}^{n}\sum_{j=1}^{n} u_i v_j\ a(b_i, b_j)$$

$$A := (a(b_i, b_j))_{i,j=1,\ldots,n} \in M_{n\times n} \quad u := \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} \quad v := \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$$

$$\underset{\text{vett riga}}{u^T} Av = u^T \begin{pmatrix} \sum A_{1,j} v_j \\ \vdots \\ \sum A_{n,j} v_j \end{pmatrix} = u_1 \cdot \sum A_{1,j} v_j + \cdots + u_n \cdot \sum A_{n,j} v_j = \sum_{i=1}^{n}\sum_{j=1}^{n} u_i A_{i,j} v_j = a(u,v)$$

Si arriva, quindi, alla conclusione che:

$$\boxed{u^T A v = a(u,v)}$$

Se $a(\ .,\ .)$ è **simmetrica**, allora:

$$a(u,v) = u^T A v = a(v,u) = v^T A u$$

Implica che $A$ è simmetrica.

Nello stesso modo se $a(\ .,\ .)$ è **definita positiva** allora anche $A$ lo è. Nota: tutti questi sono se e solo se, indipendentemente dalla base.

## 5.9 Sistemi Lineari Sovradeterminati

**Problema**: Trovare $x^* \in \mathbb{R}^n : \ Ax^* = b$ con $A \in M_{m\times n}(\mathbb{R}) b \in \mathbb{R}^m$ con $\boxed{m > n}$.

- Se $b \in \operatorname{Im} A$, ossia appartiene allo spazio generato dalle colonne di $A$, allora $\exists x^*$ tale che $Ax^* = b$.
- Se $\operatorname{rk}(A)$ è massimo ossia $n$, allora se $\exists x^*$ è **unico**.

Supponiamo che $b \in \operatorname{Im} A$ e $\operatorname{rk}(A) = n$, allora l'unica soluzione $x^*$ tale che $Ax^* = b$ è anche l'unico minimo di $\mathrm{F} : \ \mathbb{R}^n \to \mathbb{R}$ definita come $\mathrm{F}(x) = \|Ax - b\|^2$.

### 5.9.1 Soluzione ai minimi quadrati

L'obiettivo è quindi trovare $x^* \in \mathbb{R}^n$ tale che

$$\|Ax^* - b\|^2 = \min_{x\in\mathbb{R}^n} \|Ax - b\|^2$$

**Esempio 11: Considero il caso**

$m = 2, n = 1$ quindi $A \in M_{2,1}(\mathbb{R})$ e ottengo:

$$A = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} \quad b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

**Svolgimento**:

$$\begin{aligned}
&\min_{x\in\mathbb{R}} \|Ax - b\|^2 = \min_{x\in\mathbb{R}} \left\| \begin{pmatrix} a_1 x - b_1 \\ a_2 x - b_2 \end{pmatrix} \right\|^2 \\
&= \min_{x\in\mathbb{R}} \left( \sqrt{(a_1 x - b_1)^2 + (a_2 x - b_2)^2} \right)^2 \\
&= \min_{x\in\mathbb{R}} (a_1 + a_2) x^2 - 2 (a_1 b_1 + a_2 b_2) x + b_1^2 + b_2^2 = \min_{x\in\mathbb{R}} \mathrm{F}(x)
\end{aligned}$$

La funzione è quindi una parabola **convessa** (il coefficiente di $x^2$ è positivo) **strettamente** (esiste un minimo unico). Di conseguenza $x^*$ soddisfa $\mathrm{F}'(x^*) = 0$, ossia:

$$\begin{aligned}
&2a_1(a_1 x - b_1) + 2a_2(a_2 x - b_2) = 0 \\
&2a_1^2 x - 2a_1 b_1 + 2a_2^2 x - 2a_2 b_2 \\
&2\left(a_1^2 + a_2^2\right) x - 2 (a_1 b_1 + a_2 b_2) \\
&\left(a_1^2 + a_2^2\right) x = a_1 b_1 + a_2 b_2
\end{aligned}$$

Se trasformiamo questo risultato in forma di matrice abbiamo:

$$\begin{pmatrix} a_1 & a_2 \end{pmatrix} \cdot \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} x = \begin{pmatrix} a_1 & a_2 \end{pmatrix} \cdot \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

Questo è esattamente $A^T Ax = A^T b$ (**equazioni normali**) ossia:

$$\boxed{A^T (Ax^* - b) = 0}$$

e si verifica quando $Ax^* - b$ è ortogonale ad $A$.

### 5.9.2 Teorema delle Proiezioni Ortogonali

È un teorema utilizzato per dimostrare l'esistenza e l'unicità della soluzione ai minimi quadrati di un sistema sovradeterminato, ossia con più equazioni che incognite.

**Teorema 4: Proiezioni Ortogonali**

Sia $A \in M_{m,n}(\mathbb{R}) \quad b \in \mathbb{R}^n \quad m > n \quad \mathrm{rk}(A) = n$ ed esiste $x^* \in \mathbb{R}$ tale che:

$$\|Ax^* - b\|^2 = \min_{x \in \mathbb{R}^n} \mathrm{F}(x) := \min_{x \in \mathbb{R}^n} \|Ax - b\|^2$$

Inoltre $x^*$ è l'unica soluzione delle equazioni normali $A^T A x^* = A^T b$, ossia il residuo $Ax^* - b$ è ortogonale allo spazio generato dalle colonne di A.

Dimostrazione: per farlo bisogna dimostrare due aspetti principale, ossia che esiste una e una sola soluzione per il sistema ed essa è il minimo assoluto della funzione.

Le equazioni normali sono $n \times n$ perchè $A$ è $m \times n$ e $A^T$ $n \times m$, quindi $A^T A$ è $n \times n$. Perchè il sistema abbia soluzione unica $A^T A$ deve essere invertibile.
Ipotizzo $\mathrm{rk}(A) = n$ e considero l'equazione $A^T A x = 0$:

$$0 = x^T \underbrace{A^T A}_{G} x \underset{\text{prod scalare}}{=} (Ax, Ax) = \|Ax\|^2 = 0$$

$$\Rightarrow Ax = 0 \;\Rightarrow\; x = 0 \text{ perchè le colonne di } A \text{ sono lin. ind. (rango pieno)}$$

$$\Rightarrow G = A^T A \text{ è invertibile}$$

Quindi esiste una sola $\widehat{x}$ tale che $A^T A \widehat{x} = A^* b$, cioè $\widehat{x} = G^{-1} A^T b$.

Per la seconda parte voglio mostrare che $\widehat{x}$ è minimo per $\mathrm{F}$ ed è anche l'unico minimo, quindi corrisponde a $x^*$.

Prendiamo $v \in \mathbb{R}^n \setminus \{0\}$ e definisco $f_{\widehat{x},v} : \mathbb{R} \to \mathbb{R}$

$$f_{\widehat{x},v}(t) := \mathrm{F}(\widehat{x} + tv)$$

Aggiungo quindi a $\widehat{x}$ una perturbazione in modo da vedere cosa succede alla funzione:

$$f_{\widehat{x},v}(t) = \underbrace{(A(\widehat{x} + tv) - b, A(\widehat{x} + tv) - b)}_{\text{Prodotto scalare tra vettori}} =$$

$$= (A(\widehat{x} + tv) - b)^T \cdot (A(\widehat{x} + tv) - b)$$

$$= \left[(\widehat{x} + tv)^T A^T - b^T\right] \cdot (A(\widehat{x} + tv) - b)$$

$$= (\widehat{x} + tv)^T A^T A(\widehat{x} + tv) + b^T b - (\widehat{x} + tv)^T A^T b - b^T A(\widehat{x} + tv)$$

$$= tv^T A^T A tv + \underbrace{tv^T A^T A\widehat{x} + \widehat{x}^T A^T A tv}_{\text{uno il trasposto dell'altro}} -$$